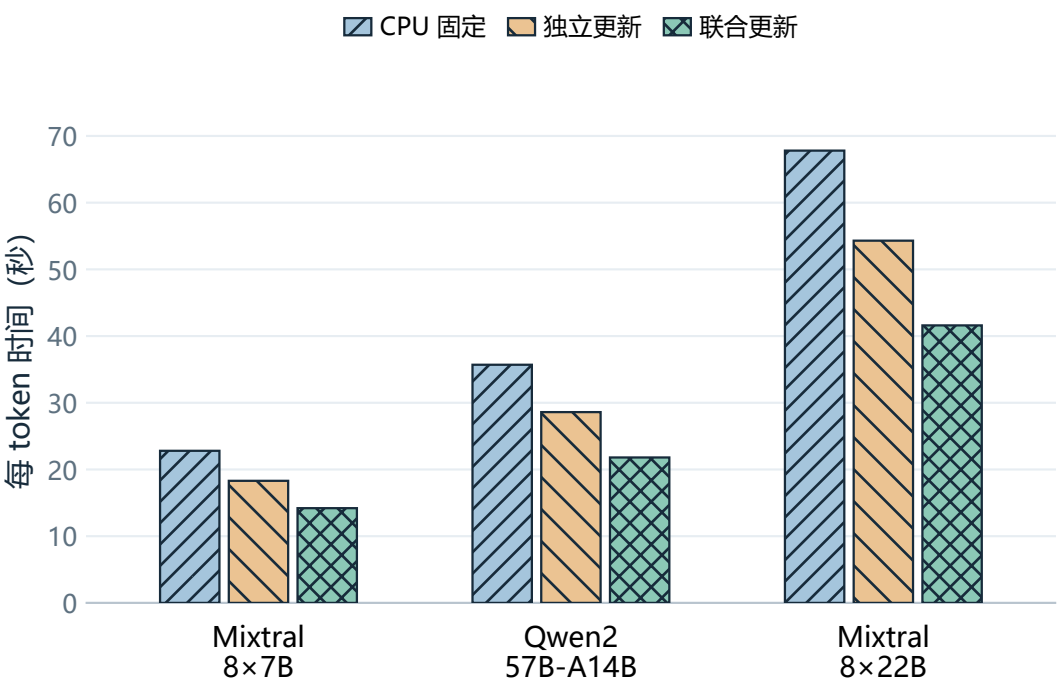
CPU 固定
独立更新
联合更新
每 token 时间（秒）
0
10
20
30
40
50
60
70
Mixtral
8×7B
Qwen2
57B-A14B
Mixtral
8×22B