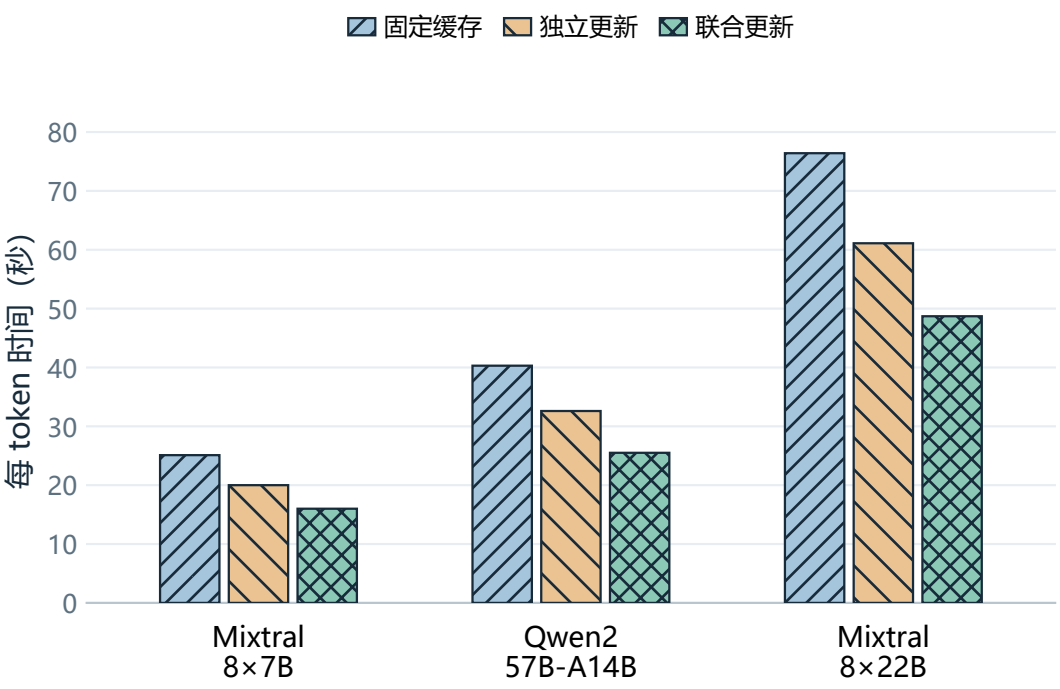
固定缓存
独立更新
联合更新
每 token 时间（秒）
80
70
60
50
40
30
20
10
0
Mixtral
8×7B
Qwen2
57B-A14B
Mixtral
8×22B