Research Problem: 单卡 MoE 推理的存储需求

- **MoE 每次仅激活少数专家，但不同输入可能激活不同专家。单个推理任务可用的显存和 CPU 内存有限，无法容纳全部专家；当所选专家位于 HDD 时，必须读取并传输权重后才能计算。**

单卡仍需支持模型中的全部专家

本次路由	E1	E2	E3	E4	E5	E6	E7	E8

蓝色 E8 为本次激活的专家；其存储位置决定读取开销。

GPU 显存	E1	E2		直接计算
CPU 内存	E3	E4	E5	传输至显存
HDD	E6	E7	E8	从 HDD 读取并传输

E8：从 HDD 读取 → 经 CPU 内存传输 → 在 GPU 上计算

应用场景与研究任务

共享 GPU 服务器
任务仅分配一张 GPU 和部分内存

离线生成
问答、代码生成允许更长响应时间

单卡工作站
权重规模超过任务可用内存

MECC 的三项设计
初始放置 · 缓存更新 · 动态调整

研究目标：在单卡上运行完整 MoE 模型，降低专家权重读取造成的延迟。

Related Work: 现有方法与 MECC 的对比

- 现有方法支持跨显存、CPU 内存和 HDD 读取专家，并缓存常用专家。在共享服务器中，还需要根据任务的内存预算确定初始放置、提前加载常用专家，并适应任务变化。

方法	显存/内存/HDD 三级存储	完整专家计算	按内存预算安排专家	提前加载常用专家	预测 HDD 读取需求	任务变化时更新缓存
SwapMoE[1]	✗	✗	✗	✓	✗	✓
Fiddler[2]	✗	✓	✗	✗	✗	✗
MoE-Infinity[3]	✗	✓	✗	✗	✗	✓
MoE-Lightning[4]	✗	✓	✗	✗	✗	✗
SSD-LLaMA[5]	✓	✓	✗	✗	✗	✓
MECC	✓	✓	✓	✓	✓	✓

Our Approach: MECC 的三项设计

- **部署前统计专家的使用频率，据此确定显存和 CPU 内存中的初始专家。推理过程中根据实际路由更新缓存。下图依次展示三项设计如何减少 HDD 读取。**

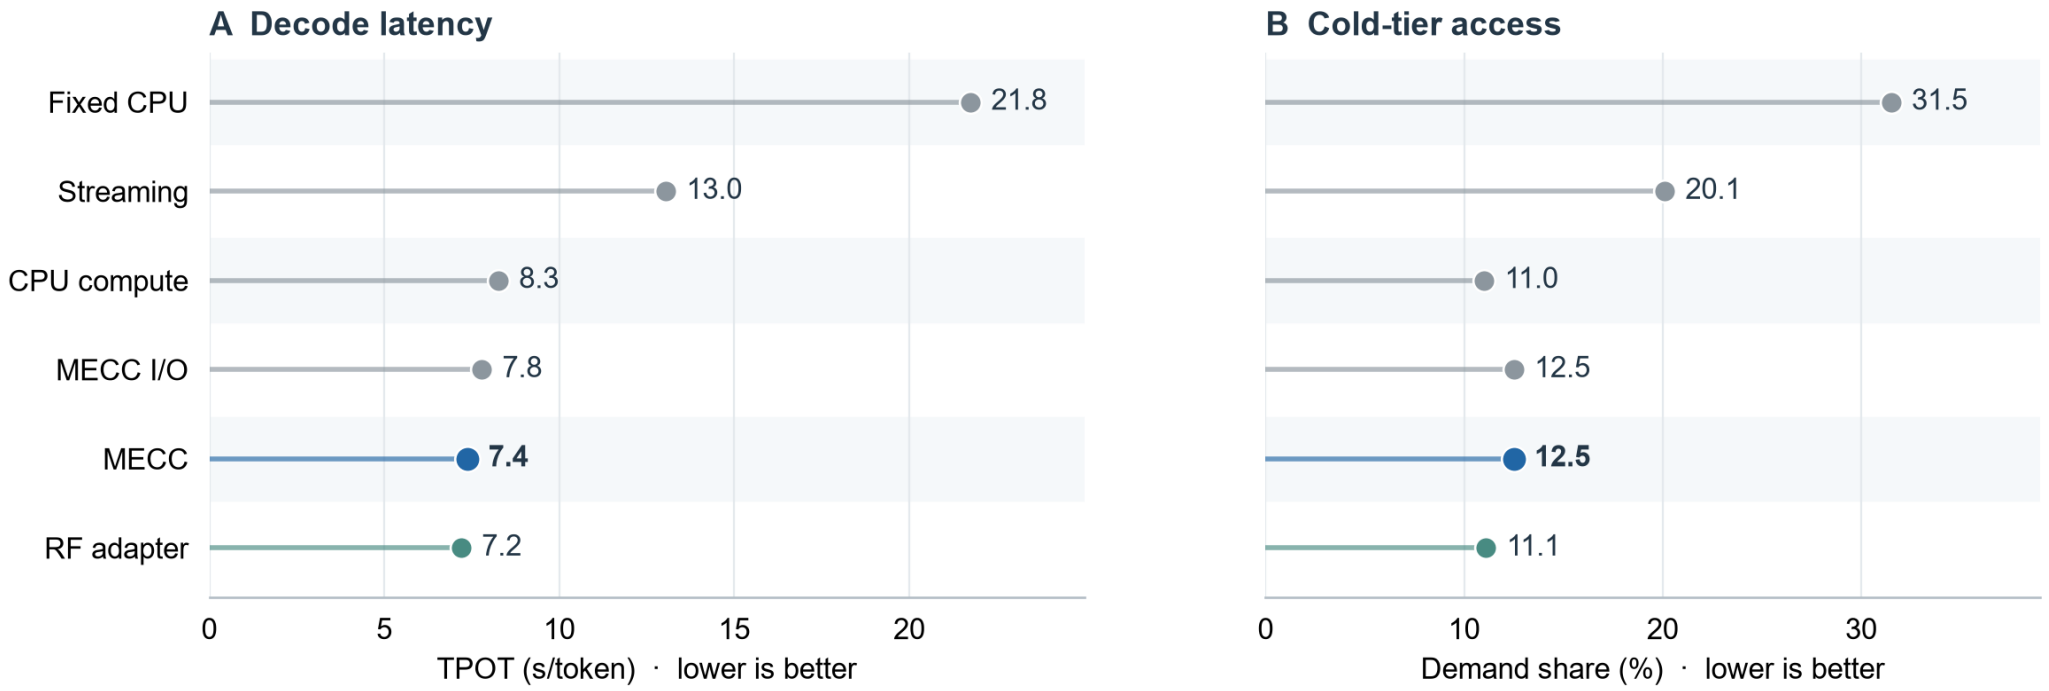


深蓝表示当前高频访问或被选中的专家；其他方块表示专家所在的存储层级。

HDD 保存完整专家权重；显存与 CPU 内存缓存当前更可能访问的专家。

Motivation: 冷存储访问进入解码路径

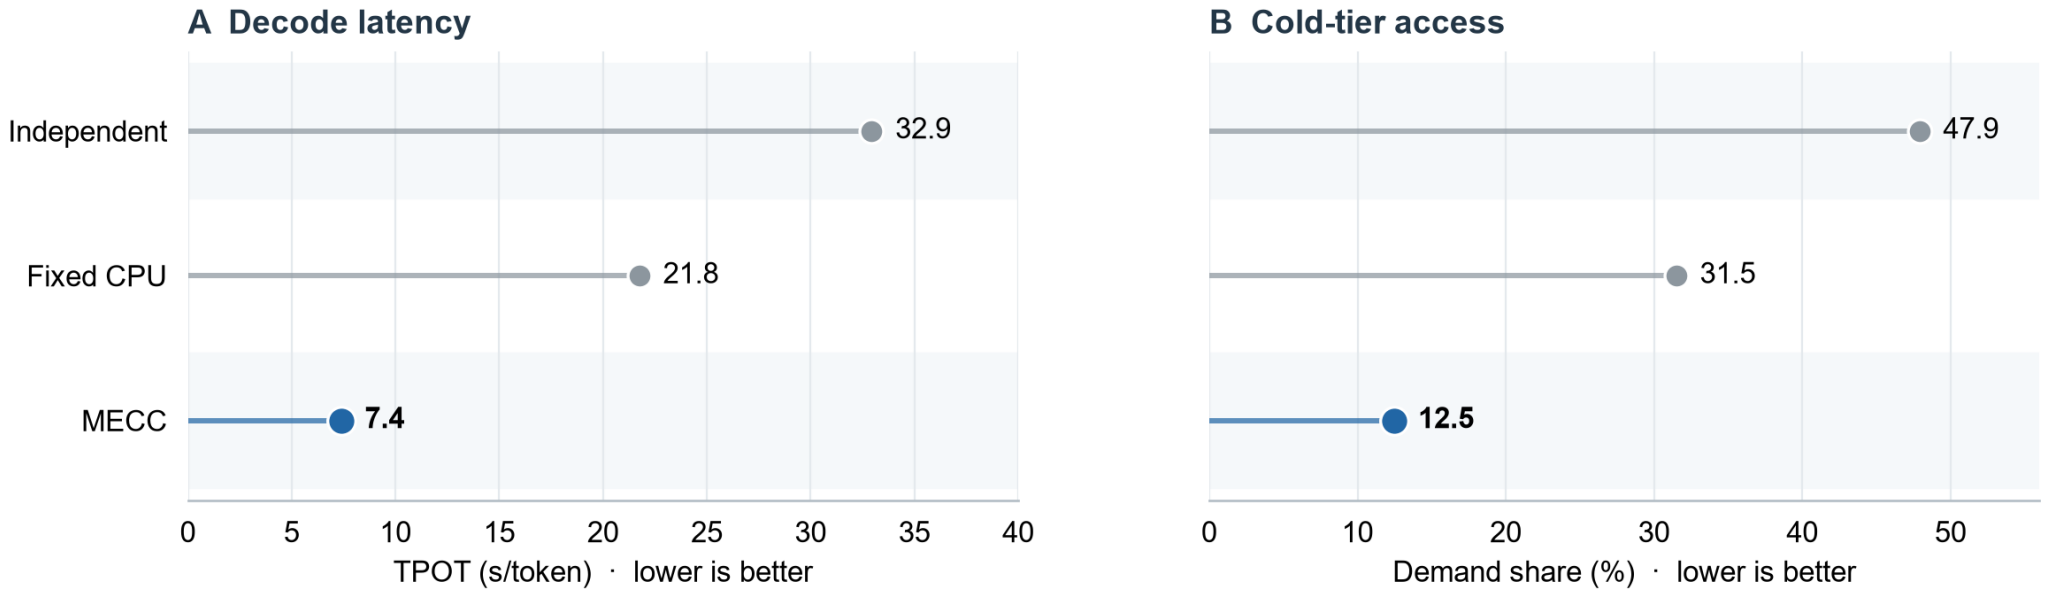
- **单卡运行时，所选专家若不在显存或 CPU 内存，就要从冷存储读取。**
  相同模型与输入下，不同缓存策略的访问比例和每 token 延迟同时变化。



主对比：六种本地策略均使用一张 A100；右图为全阶段需求比例。

Insight: 联合更新两级缓存

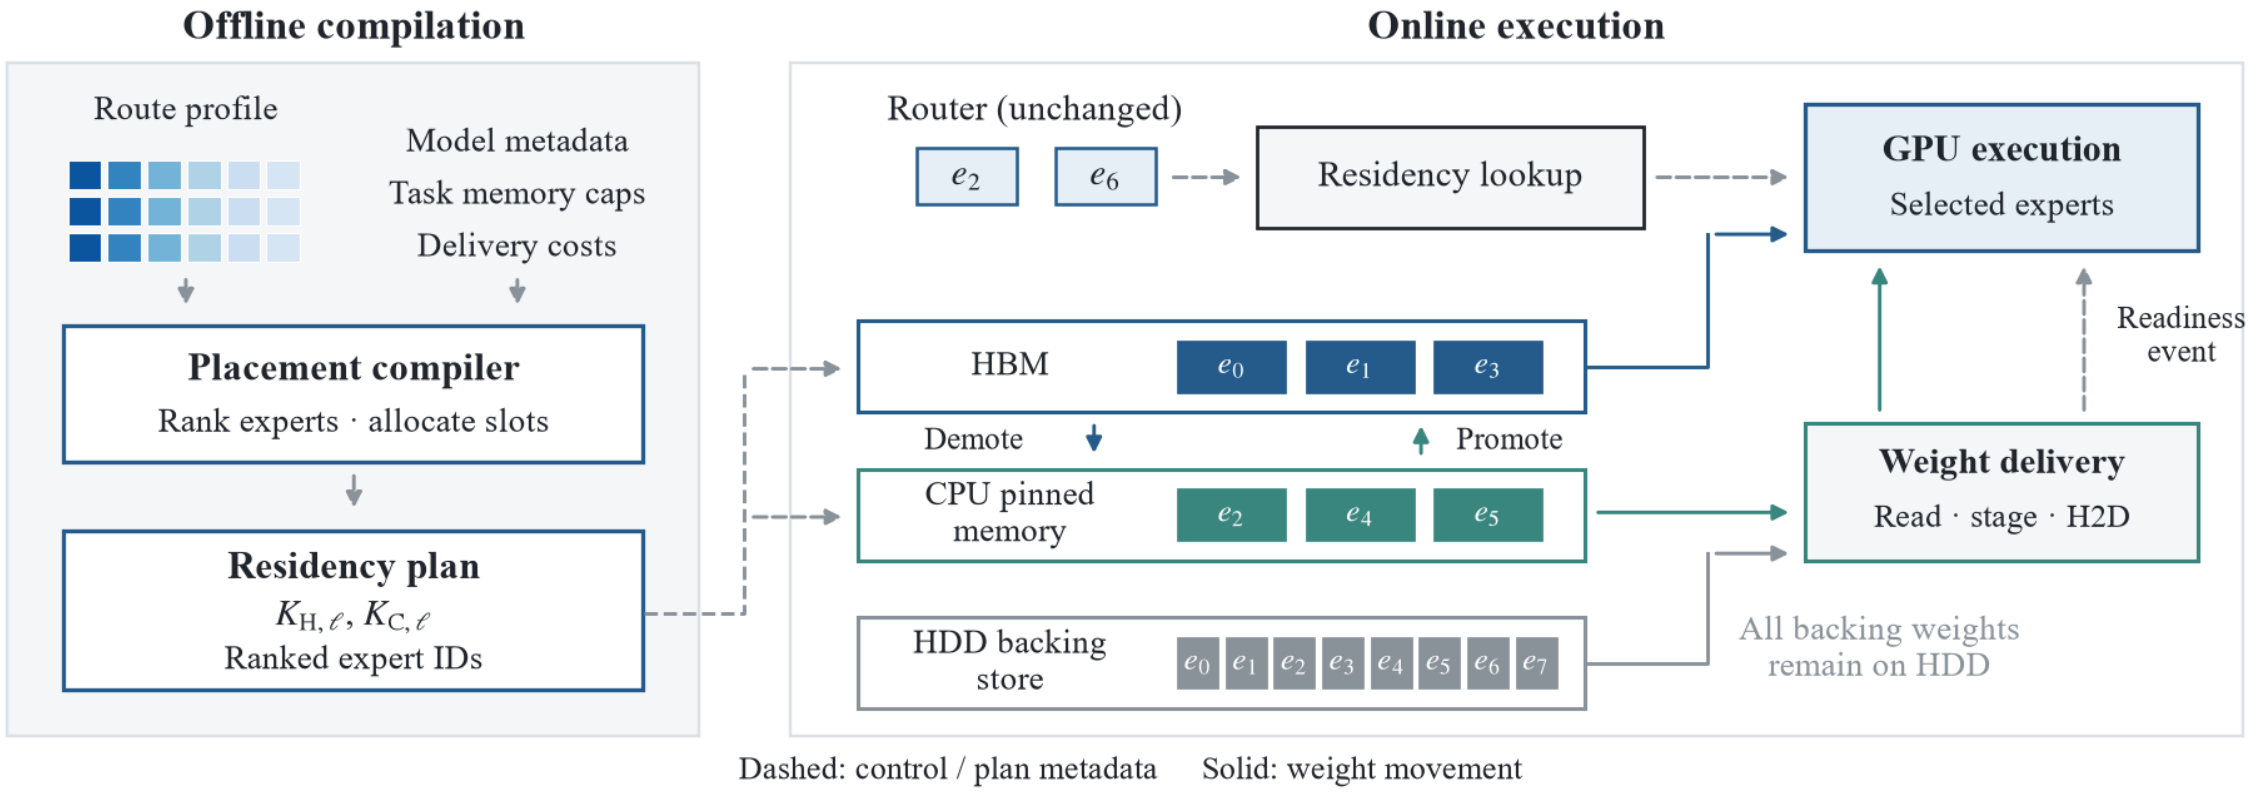
- 访问 CPU 内存中的专家后，MECC 将其提升至显存，并把显存中被替换的专家保留在 CPU 内存。同配置实验比较独立缓存、固定 CPU 缓存和联合更新。



联合更新的 TPOT 为 7.38 秒/token；独立缓存为 32.94 秒/token。

System Overview: MECC 系统总览

- MECC 在部署前确定专家的初始位置，在推理时根据实际路由访问并更新缓存。HDD 保存完整的专家权重；显存和 CPU 内存只缓存部分专家。所选专家的权重到达显存后执行计算。



部署前确定初始位置；推理时根据路由访问和更新缓存。

Evaluation Setup: 单卡真实推理

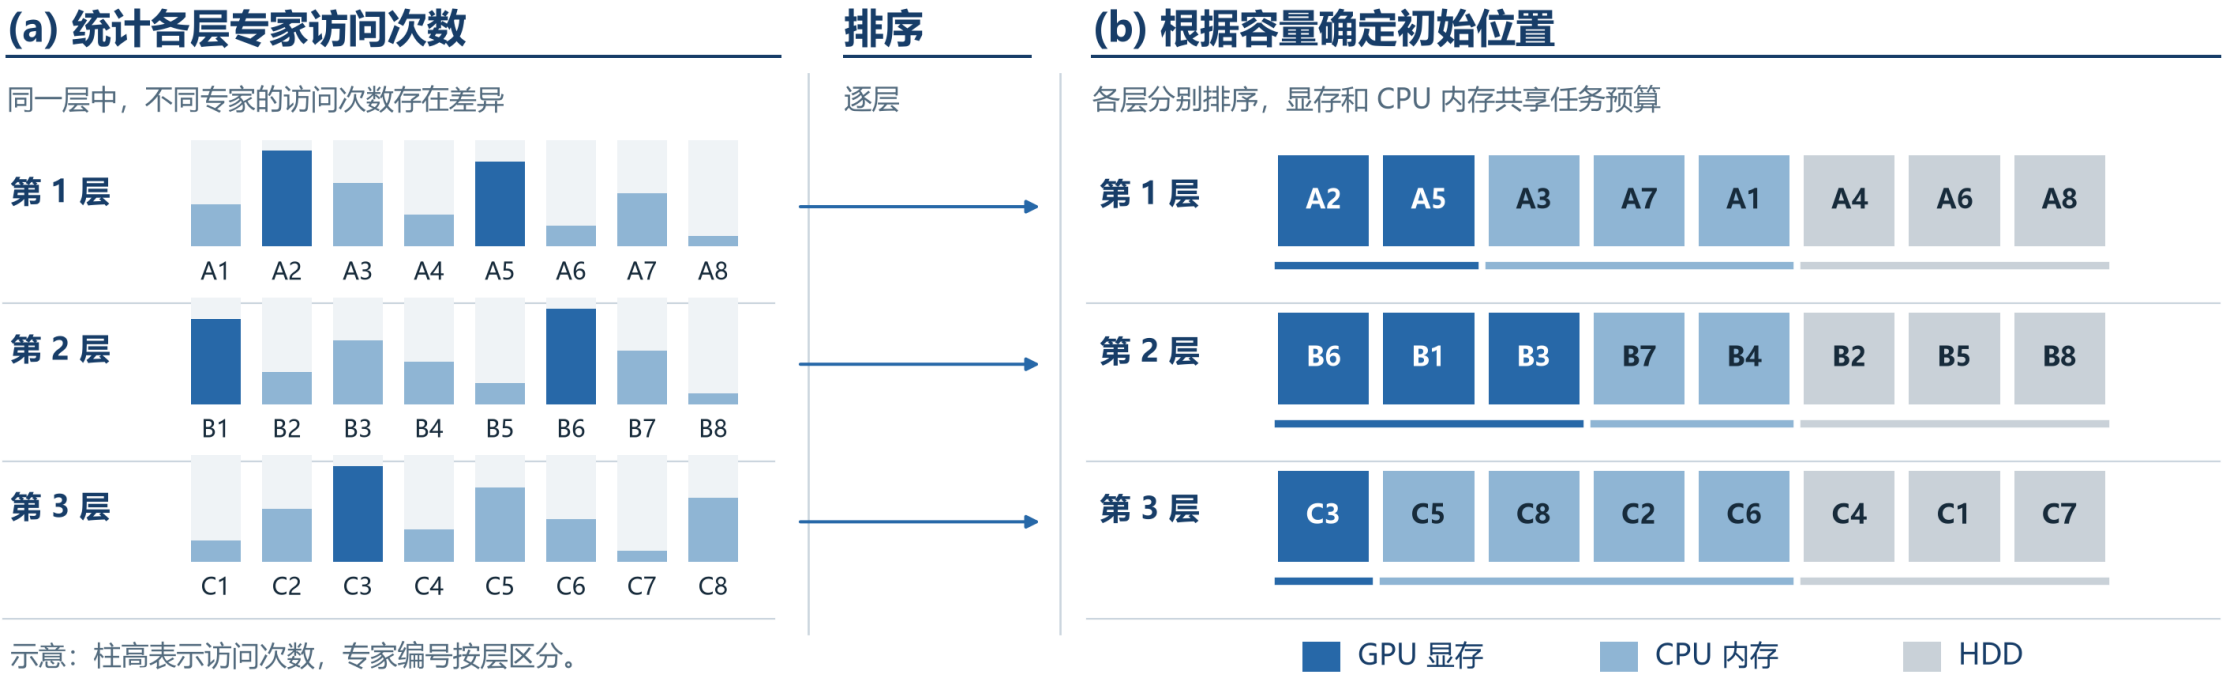
- **主对比使用 Mixtral-8×7B、A100 80 GB 和系统报告为旋转介质的 RAID 逻辑盘。六种策略在相同模型、相同名义缓存槽位和相同输入规模下各运行一次。**

模型与设备	Mixtral-8×7B · 单张 A100 · FP16 权重
输入与输出	WikiText-2 测试集 · 8 条输入 · 每条生成 64 token
缓存配置	每层显存 4 个槽位 · CPU 内存 3 个槽位 · 其余冷存储
对比方案	流式读取 · 固定 CPU 缓存 · 独立缓存 · MECC · RF 适配版

下列图只使用已提交的 A100 result.json；每个柱子对应一次完整运行。

Method I: 确定专家的初始存储位置

- **部署前使用代表性输入统计每层专家的访问频率，并记录权重大小及任务的内存预算。编译器按层排序，在显存和 CPU 内存预算内确定初始位置；HDD 保存完整权重。**



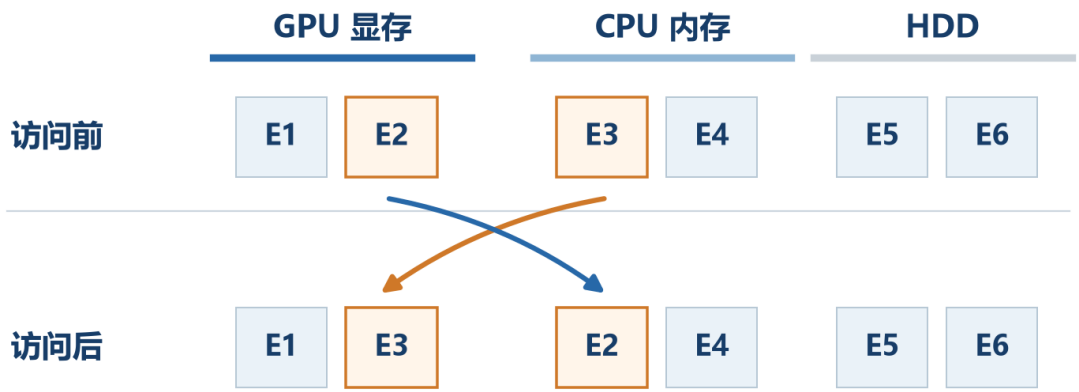
编译结果记录各层的缓存容量和专家编号；推理时继续根据实际请求更新缓存。

Method II: 更新缓存并执行专家计算

- **推理时先根据路由查找所选专家。CPU 内存命中时将专家传输到显存，并把被替换的专家保留在 CPU 内存；访问 HDD 时，等待权重到达显存后再执行计算。**

(a) 一次 CPU 内存访问如何更新缓存

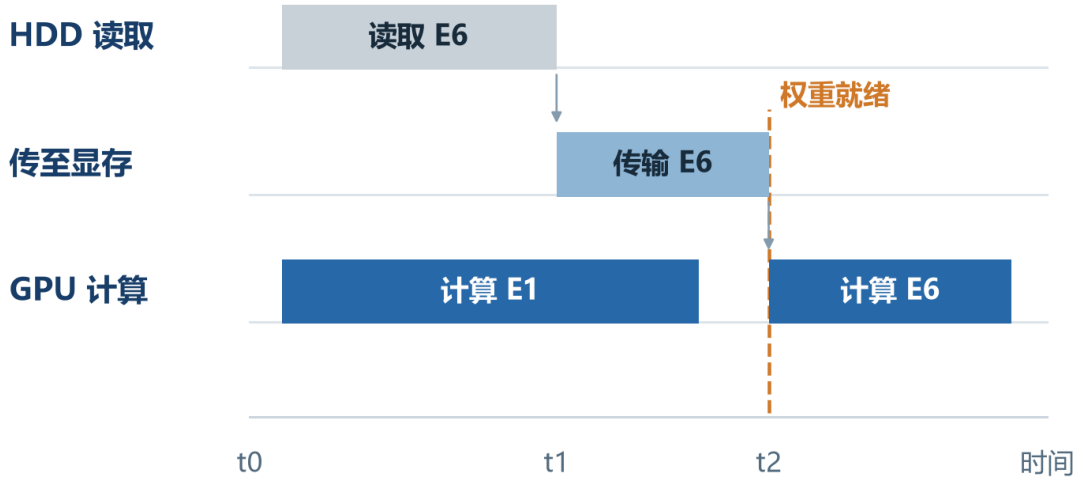
访问 E3 后，E3 进入显存；被替换的 E2 保留在 CPU 内存



E2 保留在 CPU 内存，后续访问无需再次读取 HDD。

(b) 所选专家何时可以计算

已在显存的 E1 先计算；E6 的权重到达后再执行

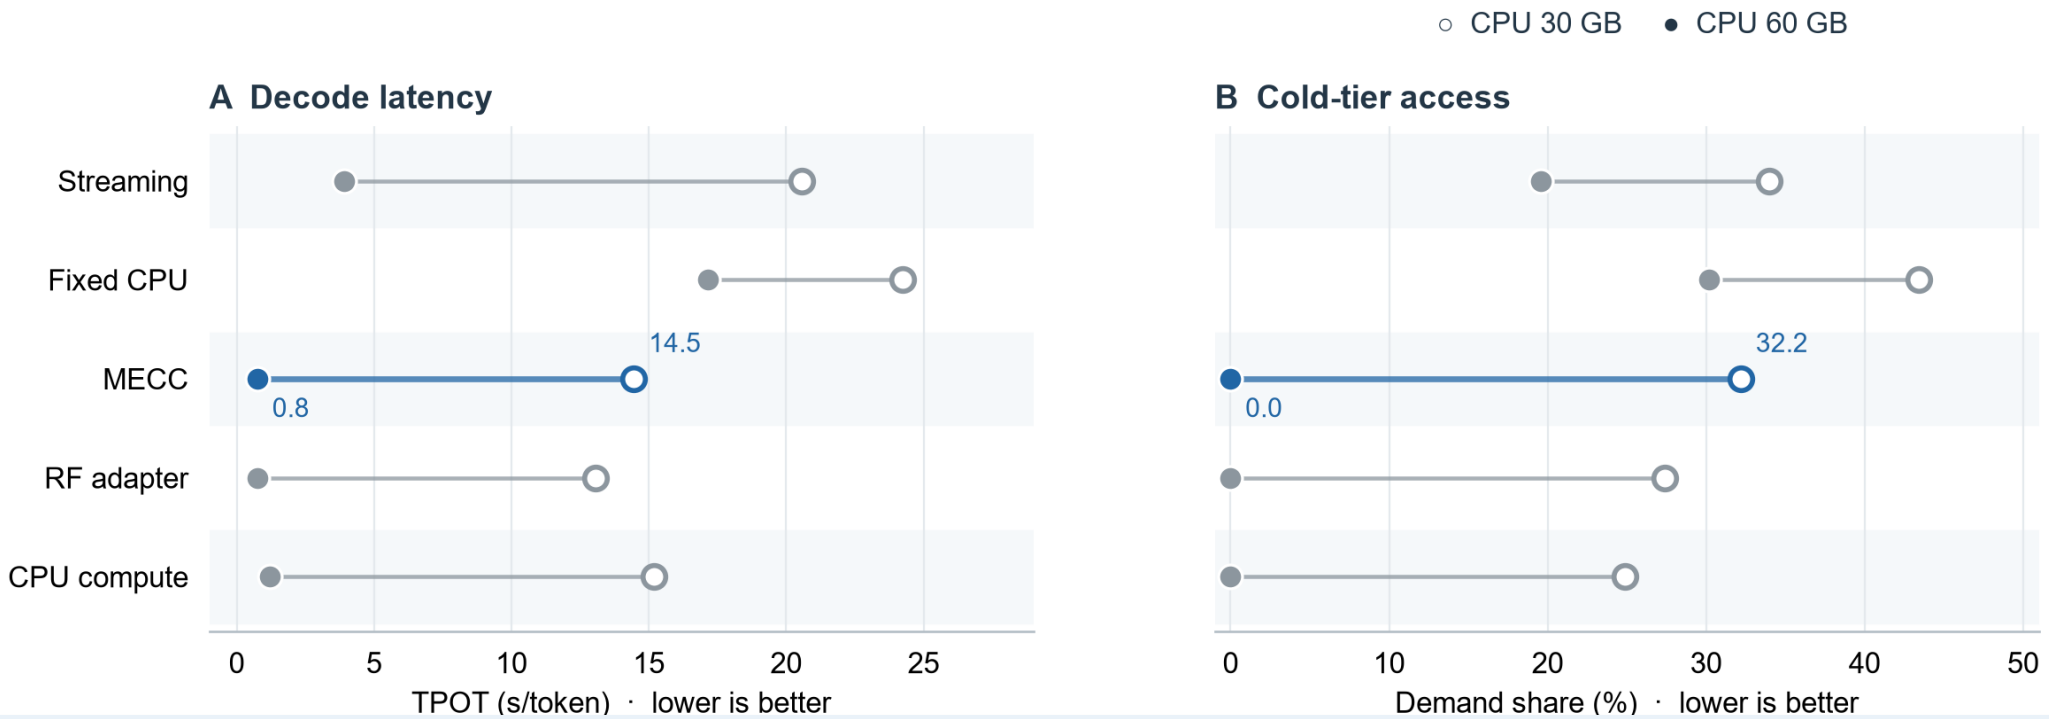


同一请求中，权重读取与已有专家的计算可以重叠。

两级缓存更新减少重复读取；已在显存的专家可先计算，其他专家在权重到达后计算。

Results: CPU 内存槽位的影响

- **同一组 WikiText-2 输入下，将名义 CPU 预算从 30 GB 增至 60 GB，每层可缓存的专家从 2 个增至 4 个；五种策略的解码延迟与冷存储访问随之变化。**



30/60 GB 为同输入规模；20 GB 的输入来源不同，未并入这张图。

Conclusion: 单卡缓存更新的实测收益

- **在本次单卡 Mixtral-8×7B 测试中，MECC 的联合缓存更新减少了冷存储访问，解码延迟低于流式读取和固定 CPU 缓存；RF 适配版在同一主测试中略快。**

2.95×

相对固定 CPU 缓存的 TPOT 比

1.77×

相对未优化流式读取的 TPOT 比

12.5%

MECC 的全阶段冷存储需求比例

结果基于统一初始放置；逐层画像和跨任务切换仍需独立实验。