Research Problem: 单卡 MoE 推理的存储需求

- **MoE 每次仅激活少数专家，但不同输入可能激活不同专家。单个推理任务可用的显存和 CPU 内存有限，无法容纳全部专家；当所选专家位于 HDD 时，必须读取并传输权重后才能计算。**

单卡仍需支持模型中的全部专家

本次路由	E1	E2	E3	E4	E5	E6	E7	E8

蓝色 E8 为本次激活的专家；其存储位置决定读取开销。

GPU 显存	E1	E2		直接计算
CPU 内存	E3	E4	E5	传输至显存
HDD	E6	E7	E8	从 HDD 读取并传输

E8：从 HDD 读取 → 经 CPU 内存传输 → 在 GPU 上计算

应用场景与研究任务

共享 GPU 服务器
任务仅分配一张 GPU 和部分内存

离线生成
问答、代码生成允许更长响应时间

单卡工作站
权重规模超过任务可用内存

MECC 的三项设计
初始放置 · 缓存更新 · 动态调整

研究目标：在单卡上运行完整 MoE 模型，降低专家权重读取造成的延迟。

Related Work: 现有方法与 MECC 的对比

- 现有方法支持跨显存、CPU 内存和 HDD 读取专家，并缓存常用专家。在共享服务器中，还需要根据任务的内存预算确定初始放置、提前加载常用专家，并适应任务变化。

方法	显存/内存/HDD 三级存储	完整专家计算	按内存预算安排专家	提前加载常用专家	预测 HDD 读取需求	任务变化时更新缓存
SwapMoE[1]	✗	✗	✗	✓	✗	✓
Fiddler[2]	✗	✓	✗	✗	✗	✗
MoE-Infinity[3]	✗	✓	✗	✗	✗	✓
MoE-Lightning[4]	✗	✓	✗	✗	✗	✗
SSD-LLaMA[5]	✓	✓	✗	✗	✗	✓
MECC	✓	✓	✓	✓	✓	✓

Our Approach: MECC 的三项设计

- **部署前统计专家的使用频率，据此确定显存和 CPU 内存中的初始专家。推理过程中根据实际路由更新缓存。下图依次展示三项设计如何减少 HDD 读取。**



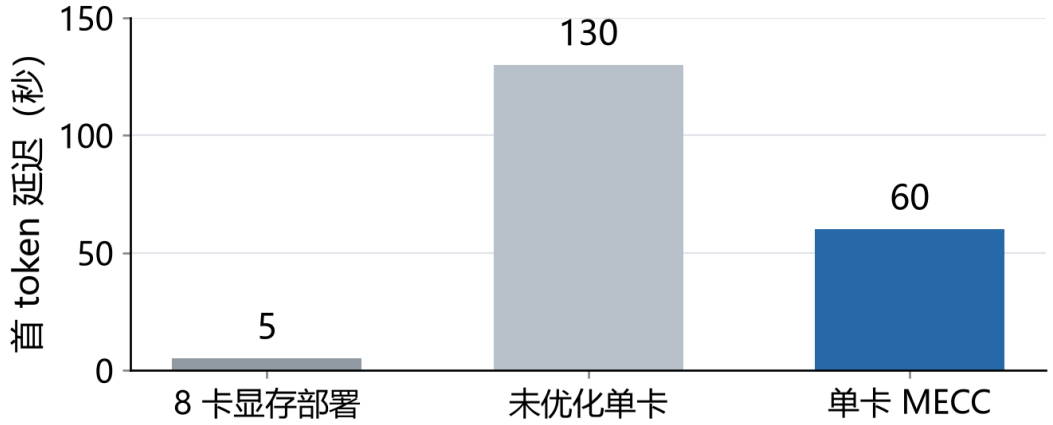
深蓝表示当前高频访问或被选中的专家；其他方块表示专家所在的存储层级。

HDD 保存完整专家权重；显存与 CPU 内存缓存当前更可能访问的专家。

Motivation I: 首次访问带来的读取延迟

- 多卡部署可将全部专家分布在各 GPU 显存中，激活后直接计算。单卡显存容量有限，首次请求可能激活 HDD 上的专家。左图比较首 token 延迟，右图说明专家权重的读取路径。

(a) 首 token 延迟



首次访问 HDD 上的专家增加首 token 延迟。

(b) 两种部署的专家读取路径

多卡：全部专家已分布在 GPU



选中 E8 → GPU 显存命中 → 执行

单卡：E8 仍在 HDD



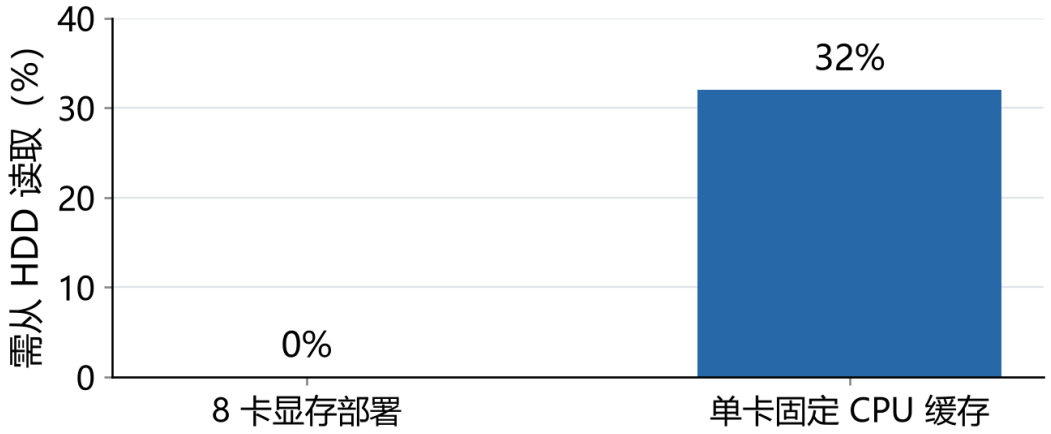
HDD 读取与权重传输均发生在专家计算之前。

问题①：推理开始前，哪些专家应优先进入显存和 CPU 内存?

Motivation II: 重复访问导致多次 HDD 读取

- **多卡部署中，全部专家均在显存，再次访问同一专家无需读取 HDD。单卡的显存和 CPU 内存容量有限：E6 从 HDD 载入后可能被替换；再次访问 E6 时仍需读取 HDD。**

(a) HDD 读取比例



专家被缓存替换后，重复访问仍需读取 HDD。

(b) 重复访问 E6 的读取路径

多卡：全部专家分布于 GPU 显存



E6 → 其他专家 → E6：两次均命中显存

单卡：显存与 CPU 内存容量有限



读取 E6 → E6 被替换 → 再次读取 E6

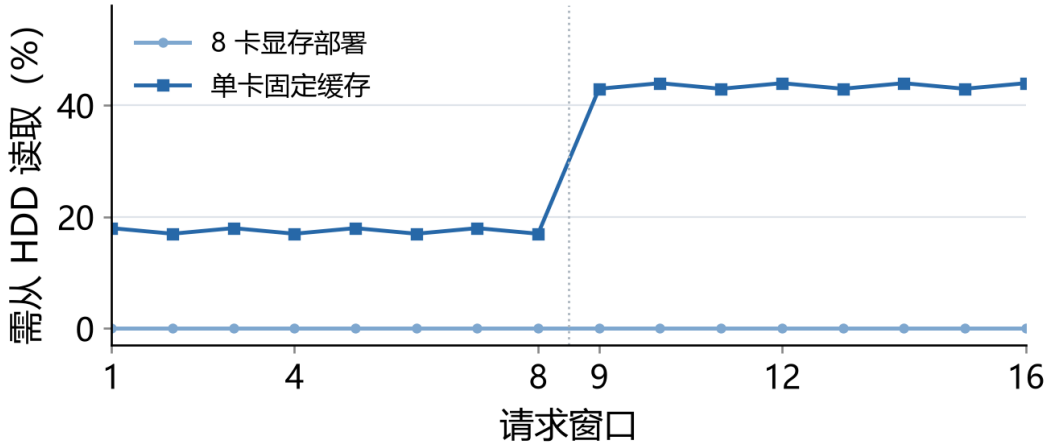
固定的 CPU 缓存无法保留被替换的 E6。

问题②：如何利用显存与 CPU 内存减少重复读取?

Motivation III: 任务变化引起专家访问变化

- **多卡部署将全部专家保存在显存，任务变化只影响激活的专家。单卡依据先前任务安排缓存；若后续任务频繁访问另一组专家，而缓存未及时更新，HDD 读取比例将持续升高。**

(a) 任务变化后的 HDD 读取比例



第 9 组请求切换任务后，固定缓存仍保留旧任务的常用专家。

(b) 新任务常用专家的存储位置

多卡：新任务常用专家仍在显存



任务 A → 任务 B：E6–E8 直接从显存读取

单卡：缓存仍保留旧任务的常用专家



任务 B 频繁访问 E6–E8，却仍需从 HDD 读取。

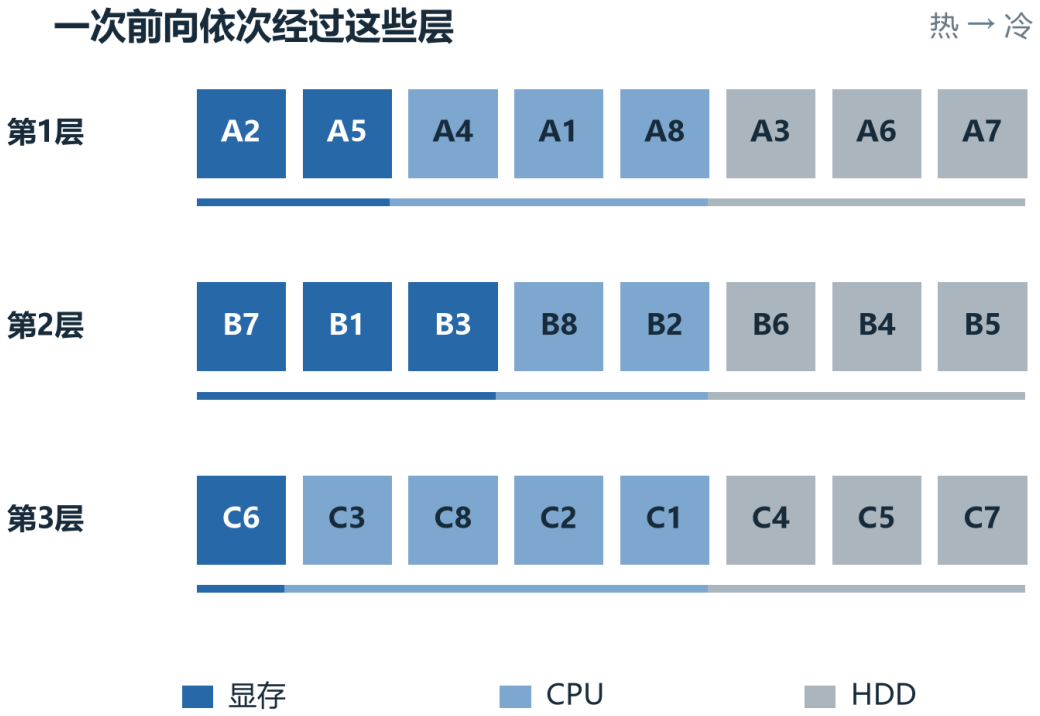
常用专家已改变，但缓存内容没有更新。

问题③：任务变化后，如何更新显存与 CPU 内存中的专家?

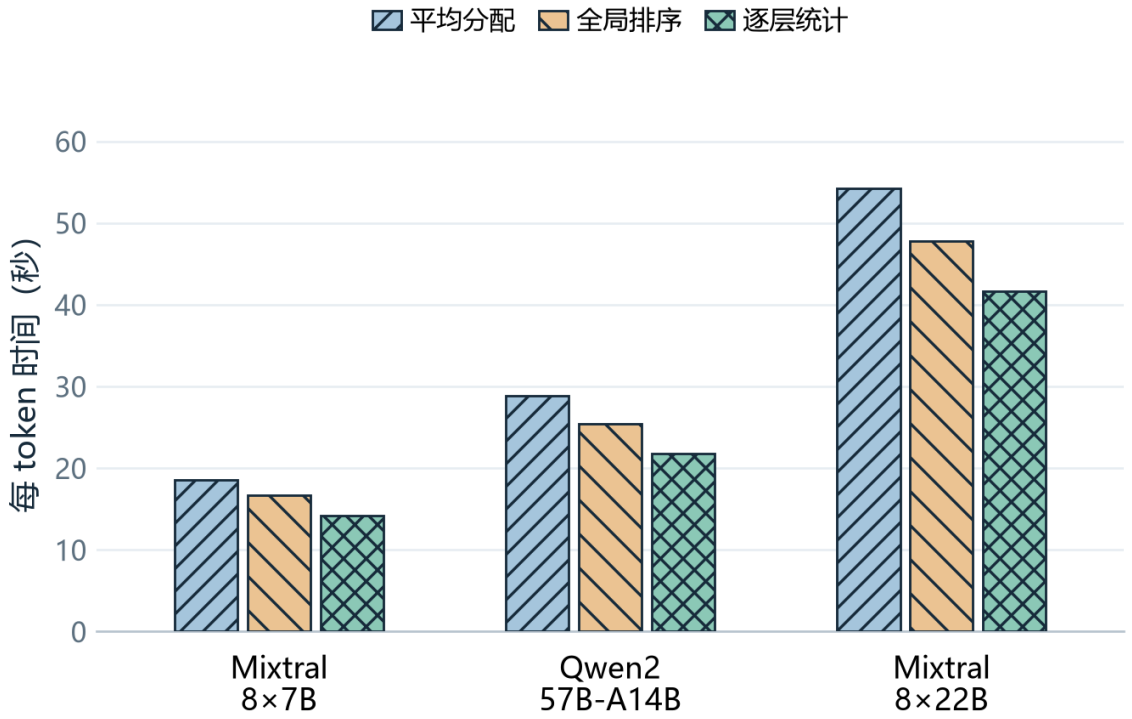
Insight I: 按专家访问频率确定初始位置

- 用代表性输入运行模型，统计每一层各专家被激活的次数。部署时分别对每层专家排序，在显存和 CPU 内存预算内优先缓存高频专家，其余权重保存在 HDD。

设计示意：分别统计每层专家



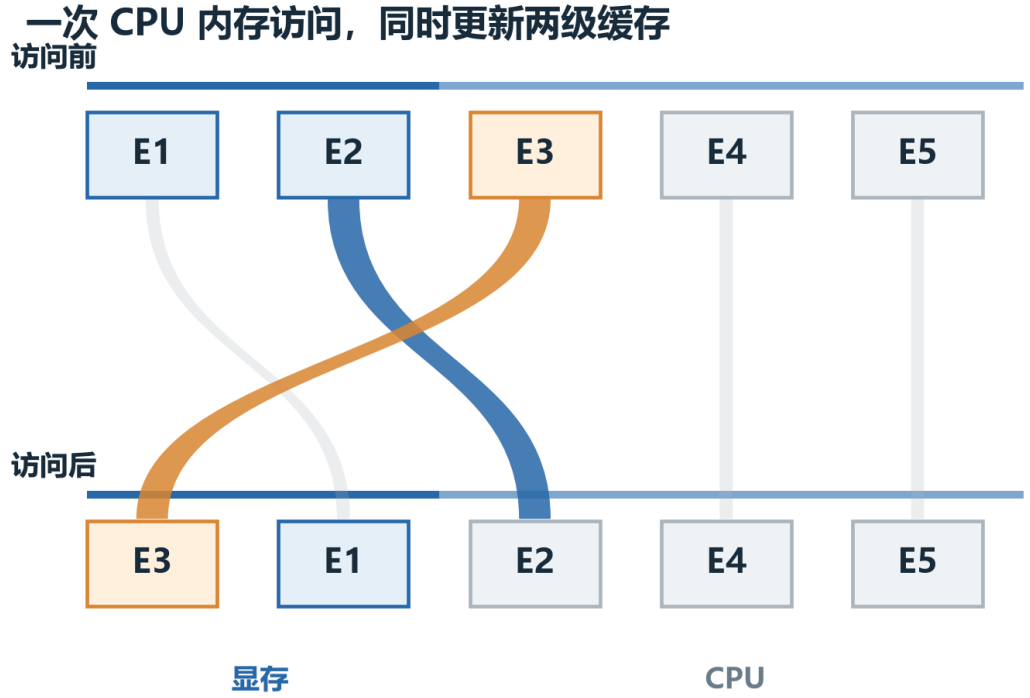
消融实验：比较不同初始放置方法



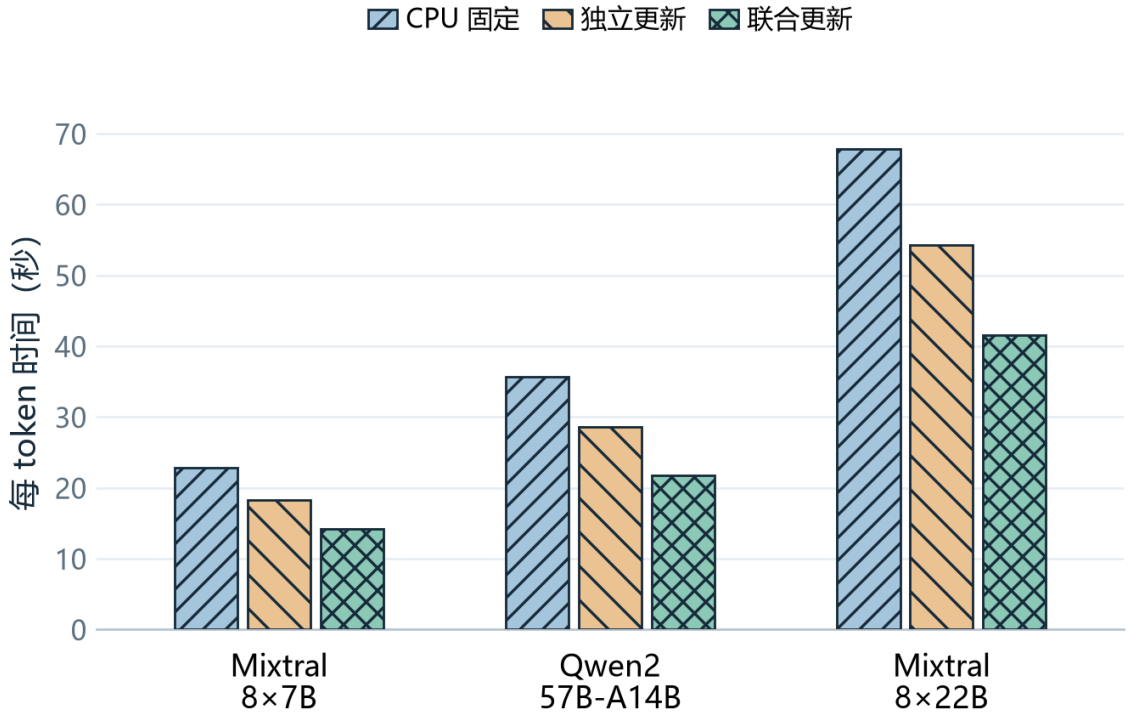
Insight II: 显存与 CPU 内存联合更新缓存

- 从 CPU 内存访问专家时，将其传输至显存；被替换的显存专家则保留在 CPU 内存中。
  这样可以同时更新两级缓存，降低再次访问该专家时读取 HDD 的概率。

设计示意：一次访问更新两级缓存



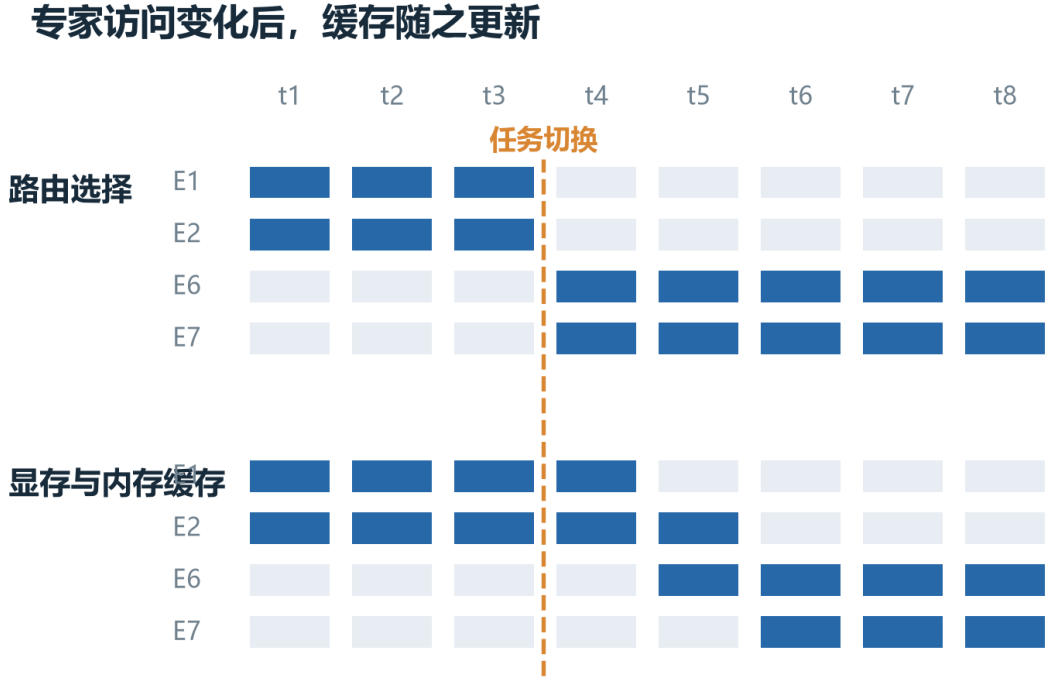
消融实验：比较不同缓存更新方法



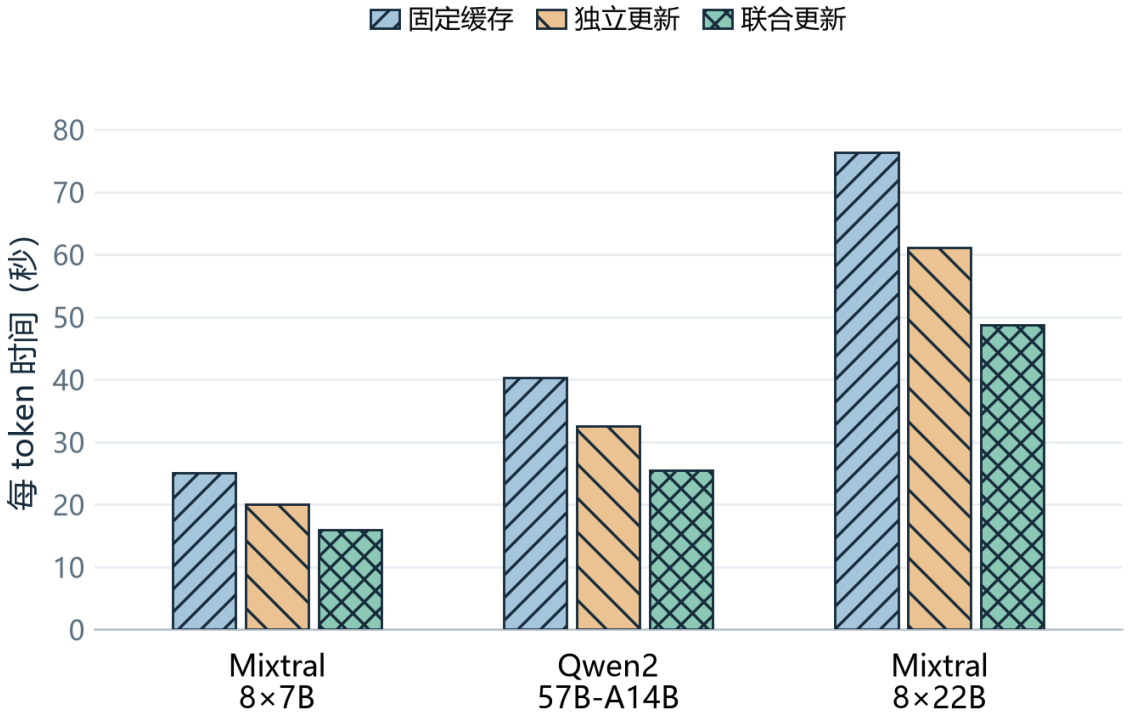
Insight III: 根据实际访问调整专家缓存

- 部署前的统计结果用于确定初始位置；推理时根据实际访问更新显存和 CPU 内存的缓存顺序。任务变化后，新任务频繁访问的专家逐步进入缓存，从而减少后续 HDD 读取。

设计示意：根据实际访问更新缓存

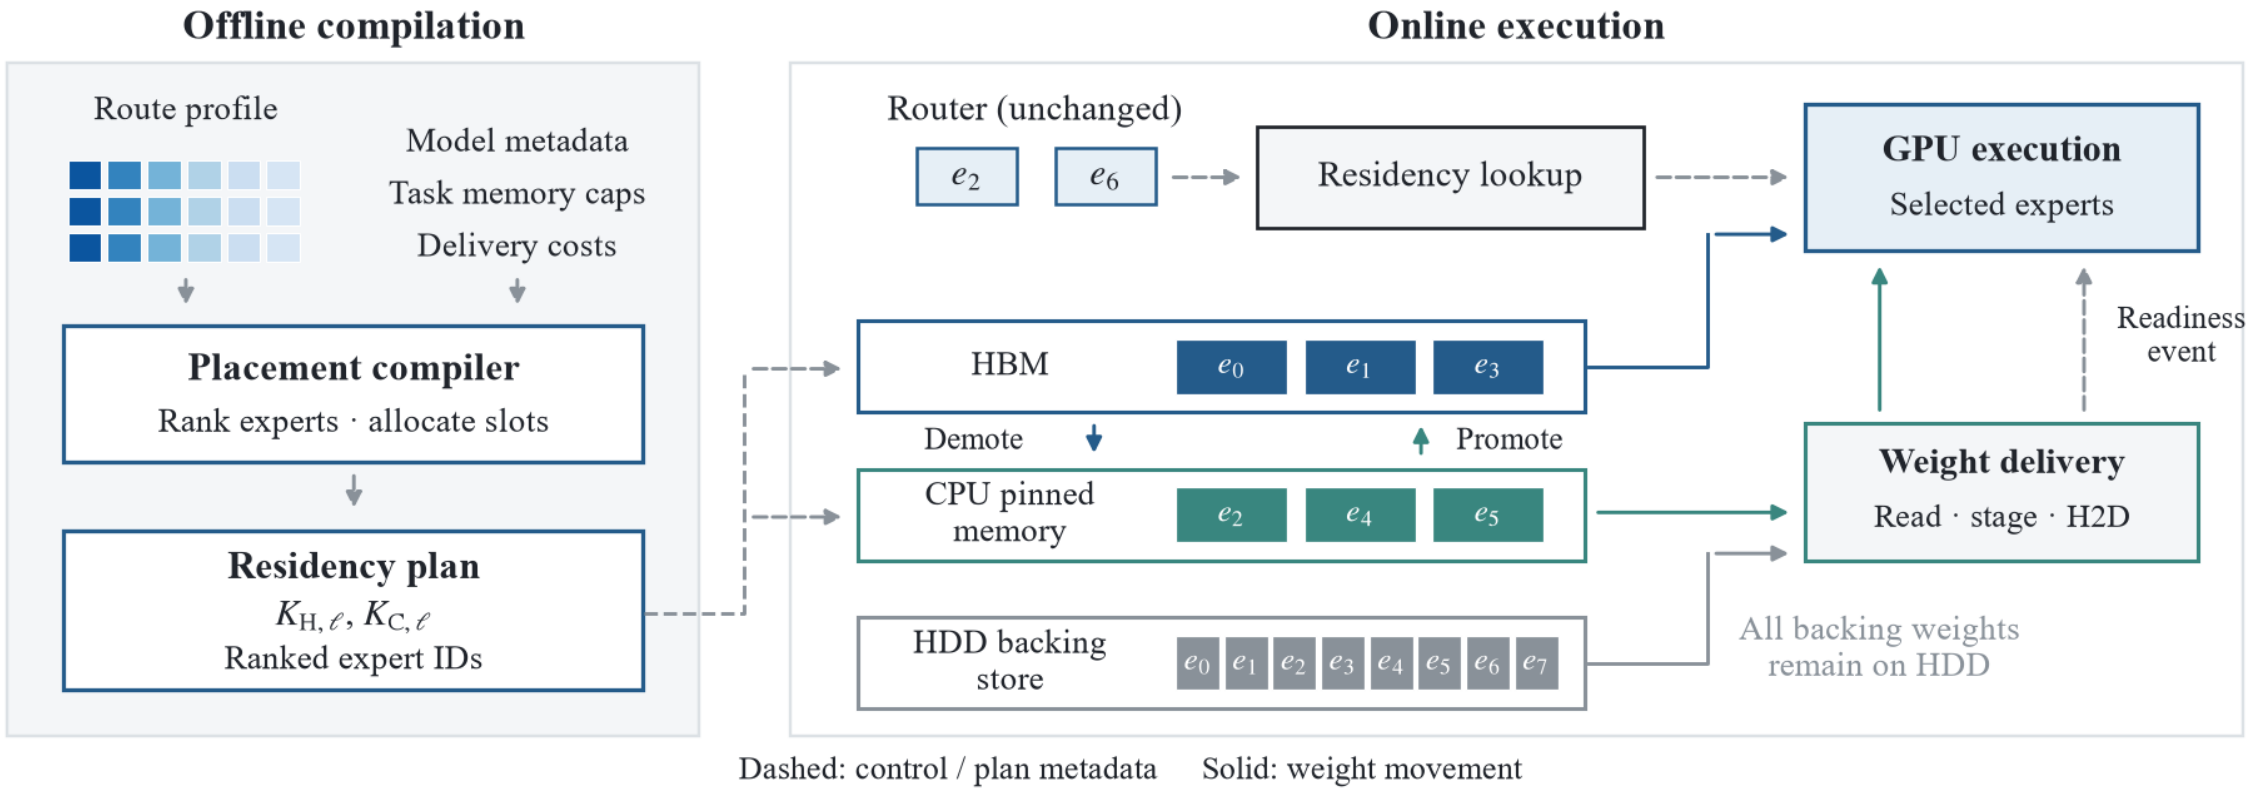


消融实验：比较任务变化后的表现



System Overview: MECC 系统总览

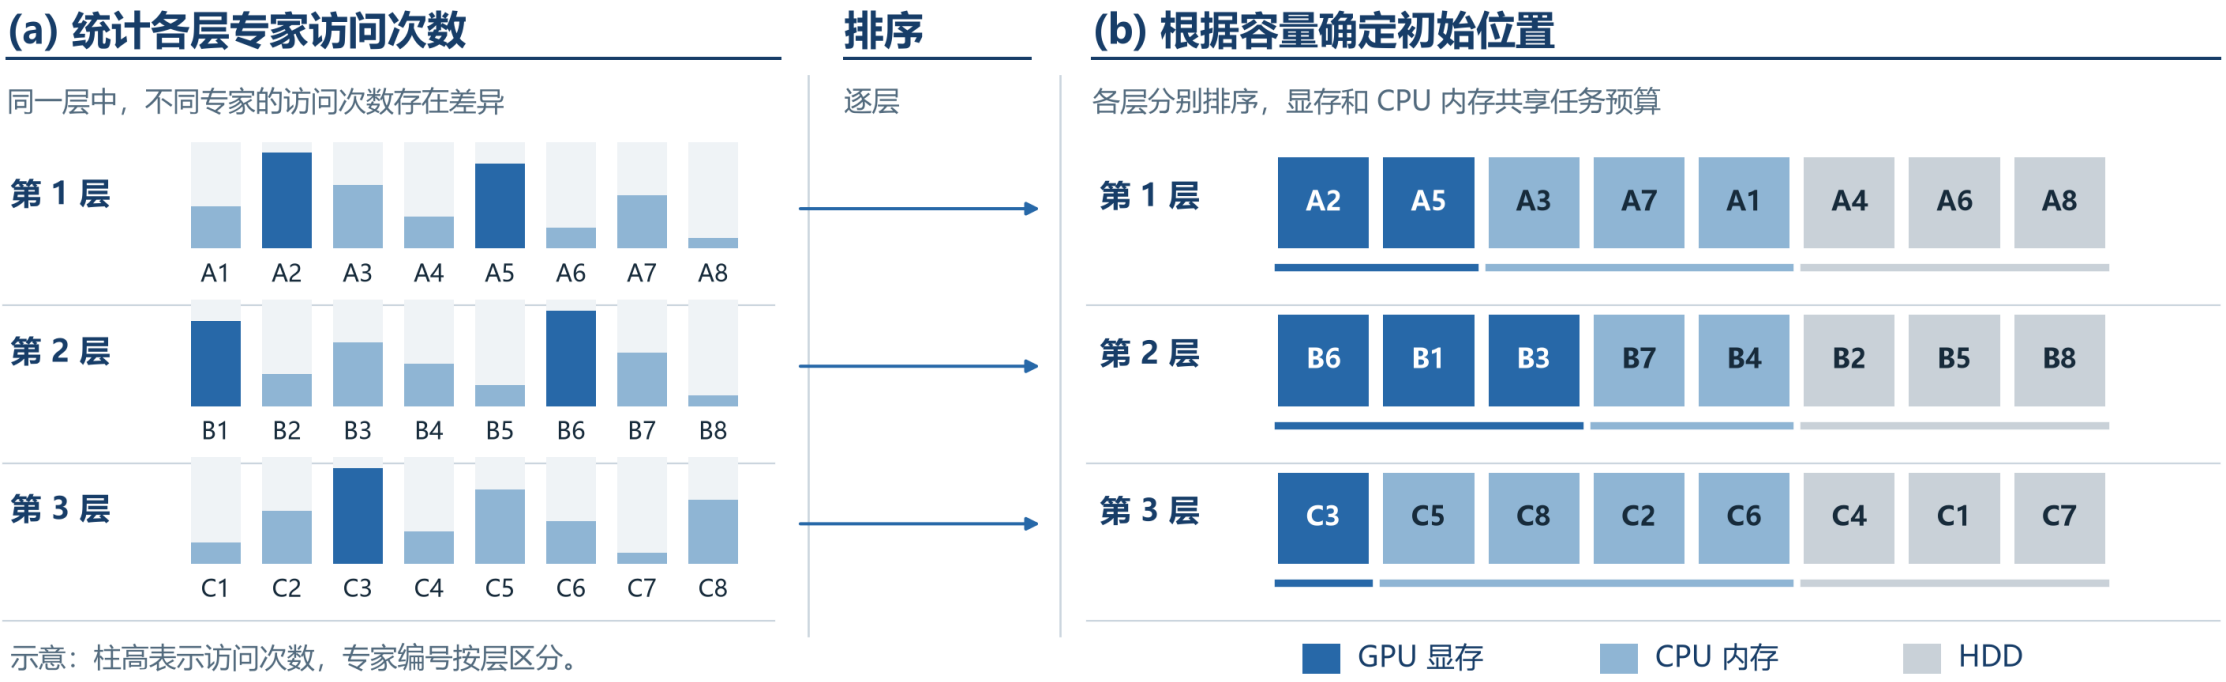
- MECC 在部署前确定专家的初始位置，在推理时根据实际路由访问并更新缓存。HDD 保存完整的专家权重；显存和 CPU 内存只缓存部分专家。所选专家的权重到达显存后执行计算。



部署前确定初始位置；推理时根据路由访问和更新缓存。

Method I: 确定专家的初始存储位置

- **部署前使用代表性输入统计每层专家的访问频率，并记录权重大小及任务的内存预算。编译器按层排序，在显存和 CPU 内存预算内确定初始位置；HDD 保存完整权重。**



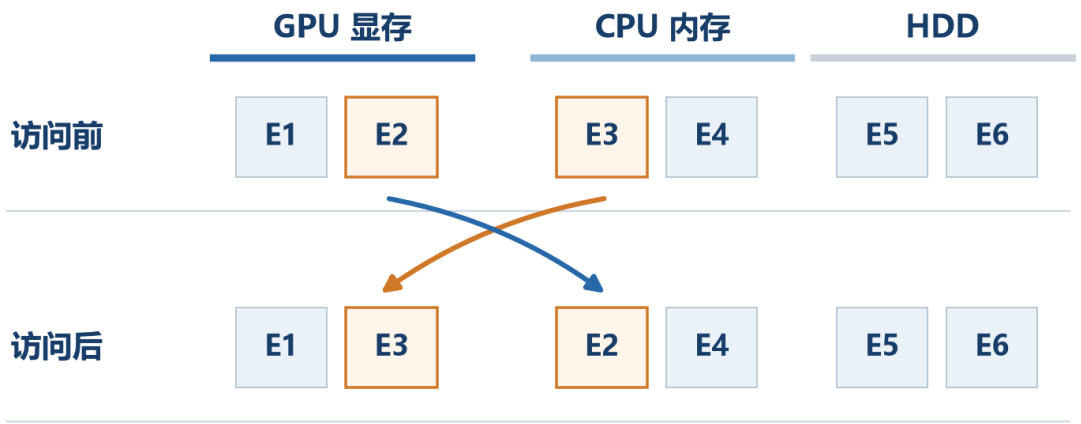
编译结果记录各层的缓存容量和专家编号；推理时继续根据实际请求更新缓存。

Method II: 更新缓存并执行专家计算

- **推理时先根据路由查找所选专家。CPU 内存命中时将专家传输到显存，并把被替换的专家保留在 CPU 内存；访问 HDD 时，等待权重到达显存后再执行计算。**

(a) 一次 CPU 内存访问如何更新缓存

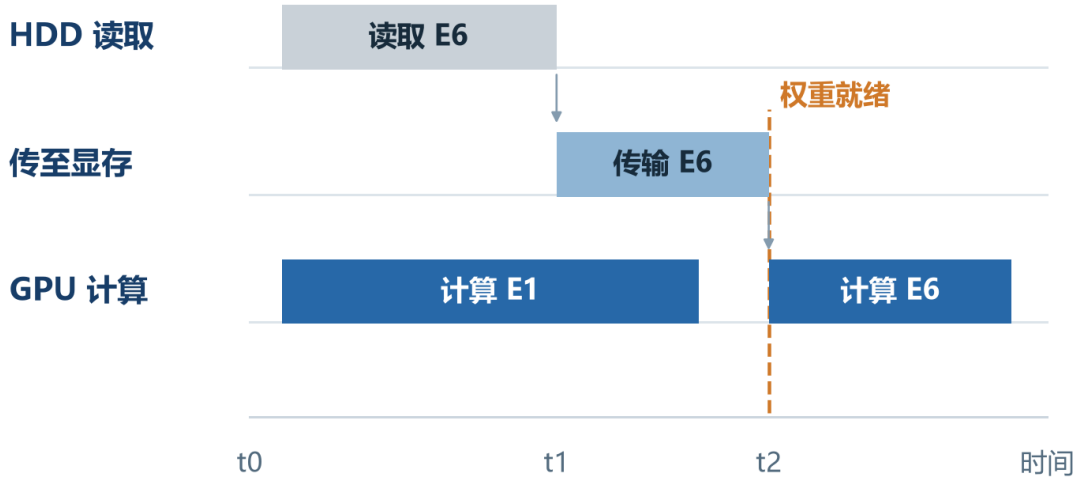
访问 E3 后，E3 进入显存；被替换的 E2 保留在 CPU 内存



E2 保留在 CPU 内存，后续访问无需再次读取 HDD。

(b) 所选专家何时可以计算

已在显存的 E1 先计算；E6 的权重到达后再执行

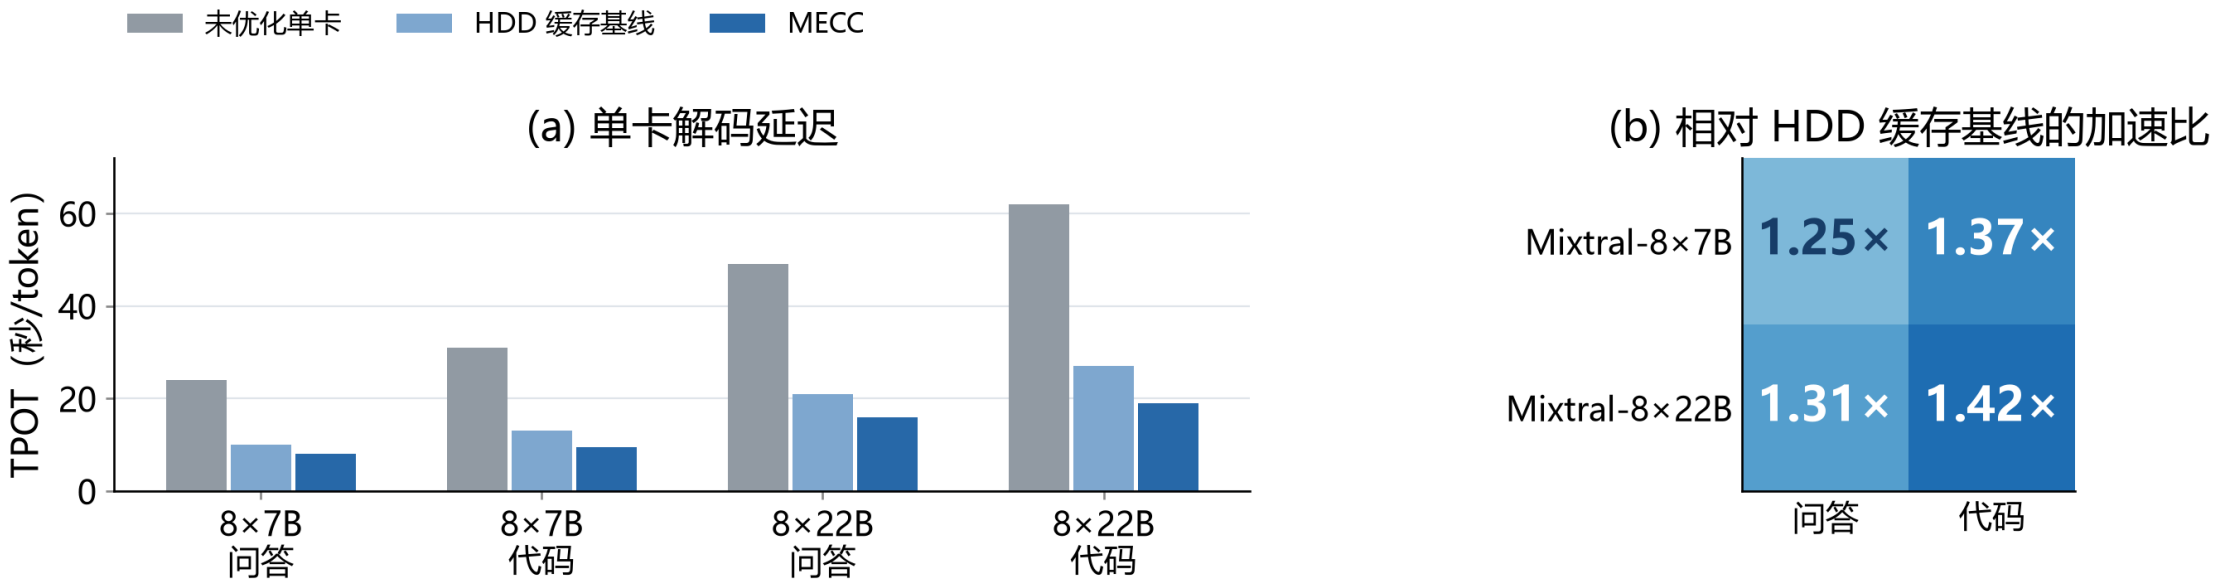


同一请求中，权重读取与已有专家的计算可以重叠。

两级缓存更新减少重复读取；已在显存的专家可先计算，其他专家在权重到达后计算。

Results: 单卡解码延迟

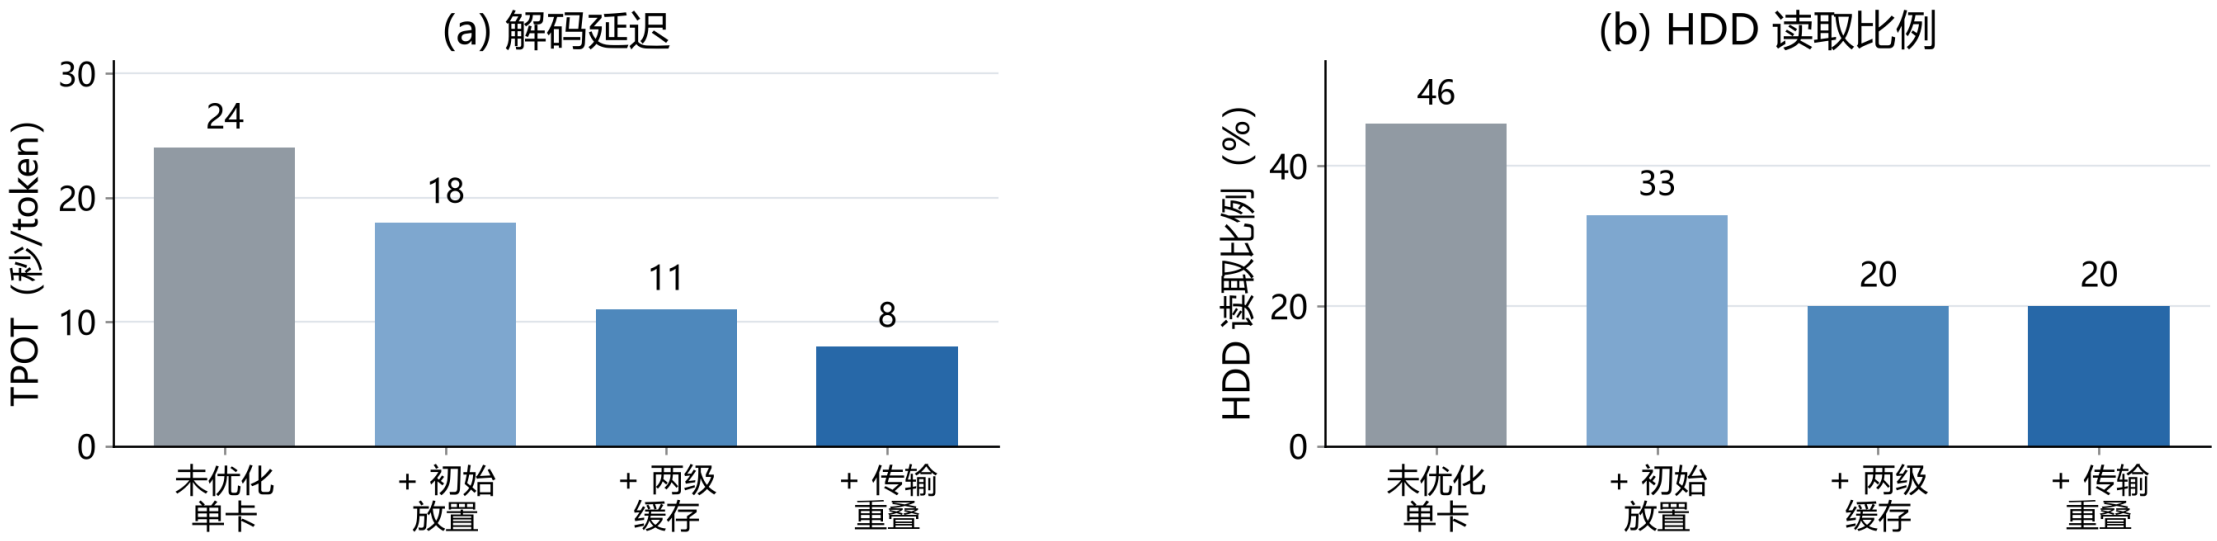
- **左图比较四组模型与任务中，未优化单卡方案、HDD 缓存方案和 MECC 的每 token 解码延迟。右图给出 MECC 相对 HDD 缓存方案的加速比。**



同一任务内存额度下，MECC 与 HDD 缓存基线相差 1.25–1.42×。

Ablation: 各项设计的效果

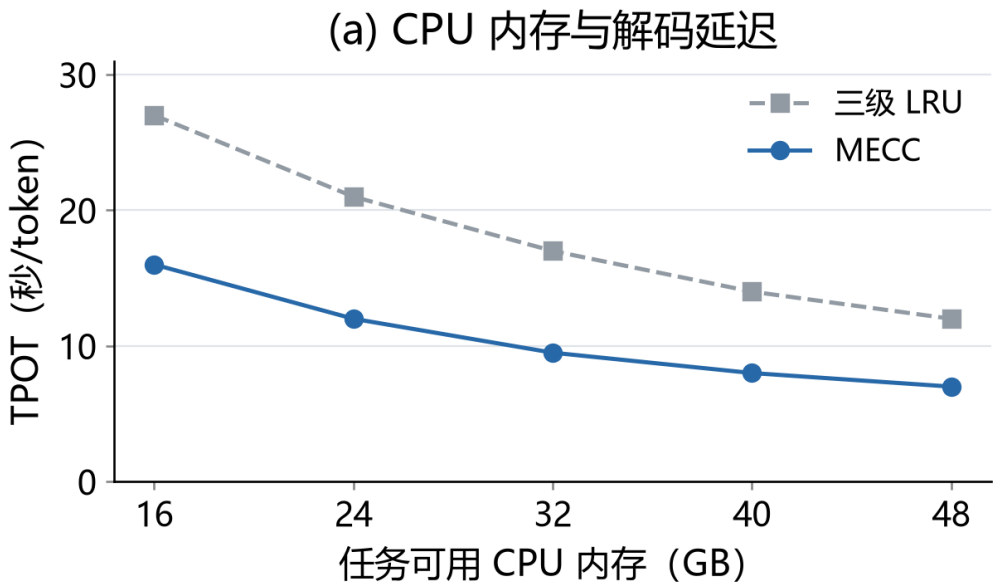
- 从基础方案开始，依次加入初始放置、两级缓存更新和计算与传输重叠。左图比较解码延迟，右图比较 HDD 读取比例，以区分各项设计对读取次数和等待时间的影响。

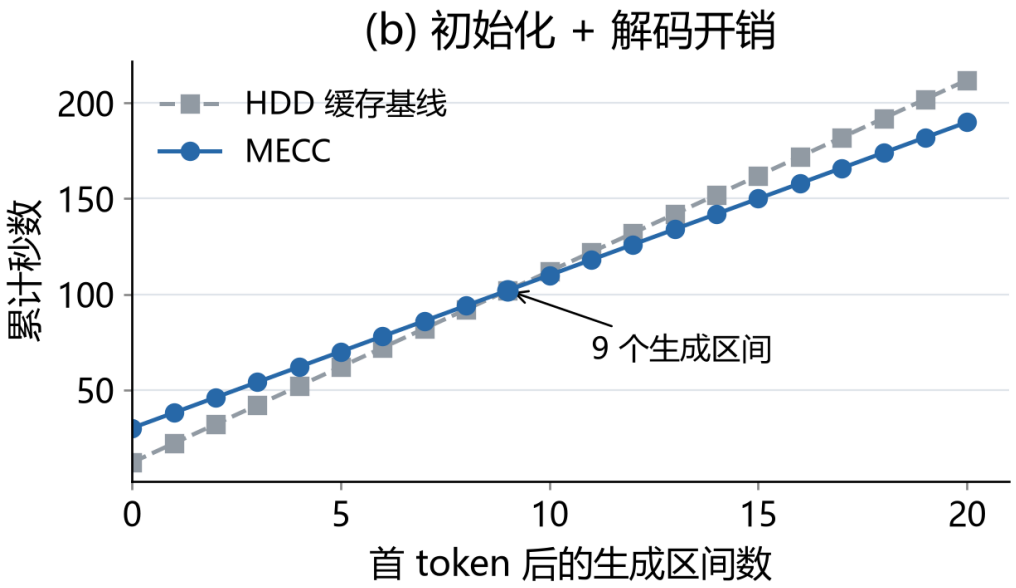


首组任务：24 → 18 → 11 → 8 秒/token；HDD 请求比例：46% → 33% → 20%。

Resource Sensitivity: CPU 内存与生成长度

- 任务可用的 CPU 内存越大，可缓存的专家越多。生成的 token 越多，初始加载开销对平均延迟的影响越小。两张图分别改变 CPU 内存预算和生成长度。

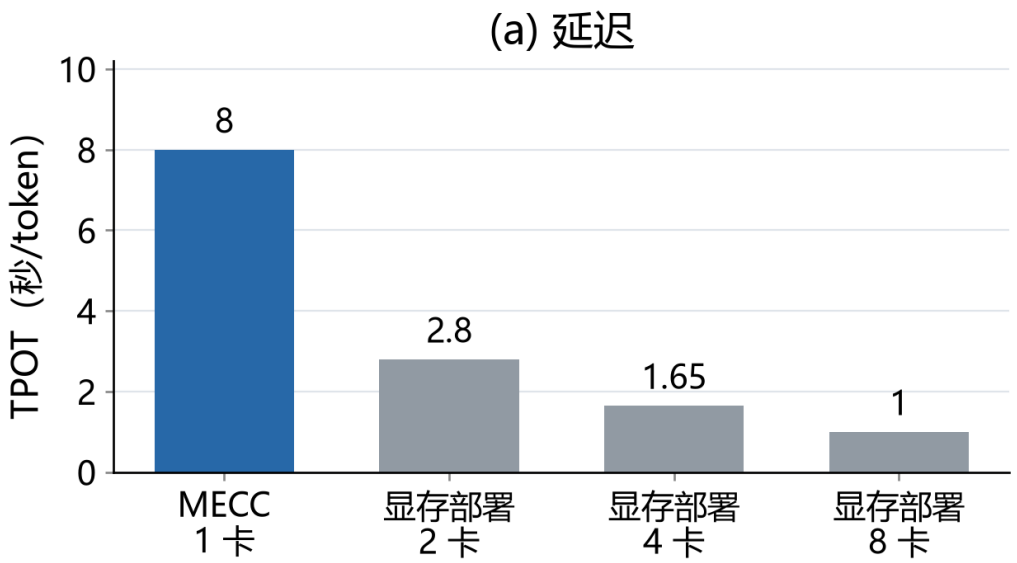


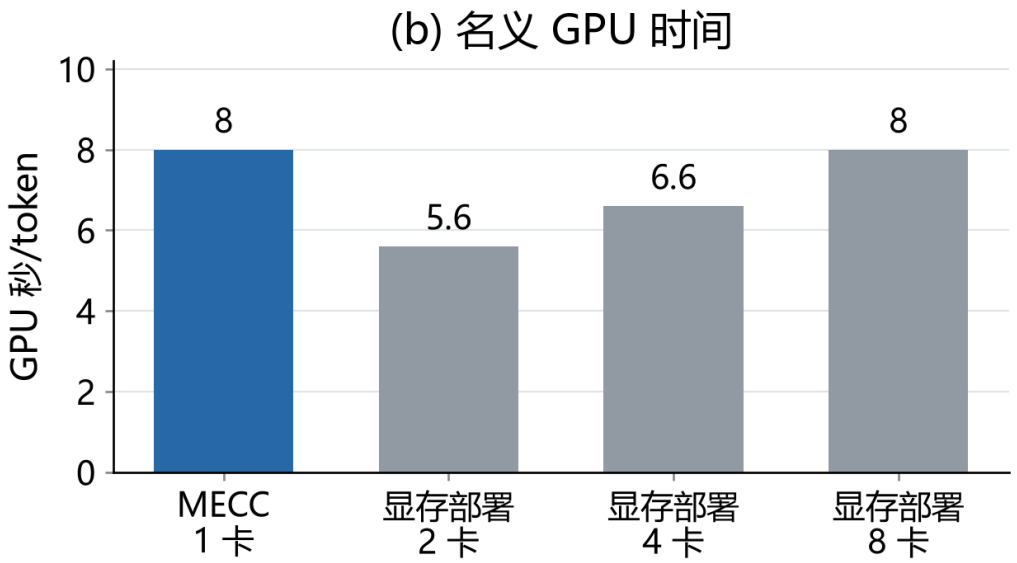


单卡推理性能受到 CPU 内存预算和生成长度共同影响。

Deployment Trade-off: 单卡与多卡部署

- 多卡部署将全部专家分布在 GPU 显存中，因此单 token 延迟更低；MECC 使用一张 GPU 运行完整模型。右图以 GPU 数量乘以延迟，比较两种部署的 GPU 资源开销。





单卡方案适用于 GPU 数量受限、可以接受较长推理延迟的任务。

Conclusion: 单卡运行完整 MoE 模型

- **当任务可用的 CPU 内存无法容纳全部专家时，部分权重需要保存在 HDD。MECC 依据访问频率确定初始位置，联合更新显存和 CPU 内存缓存，并根据实际请求调整，以减少 HDD 读取。**

初始放置

优先缓存高频专家

减少首次读取

缓存更新

联合使用显存与 CPU 内存

减少重复读取

动态调整

根据实际访问更新缓存

适应任务变化

面向单卡、有限任务内存预算下的完整 MoE 推理。