Research Problem: Single-GPU MoE Deployment

- **MoE 的专家是按需调用的参数模块。每次只计算少数专家，但路由器可能选中任意一个。**
  单任务显存和 CPU 内存放不下全部专家时，部分权重留在 SSD；被选中后要先搬运才能计算。

单卡必须让完整专家集合保持可访问

本次路由	E1	E2	E3	E4	E5	E6	E7	E8

蓝色 E8 被选中；读取路径取决于其当前驻留层级。

GPU 显存	E1	E2		直接计算
CPU 内存	E3	E4	E5	搬至显存
SSD 冷驻留	E6	E7	E8	先冷读再搬运

E8：SSD 冷读 → CPU 缓冲 → GPU 执行

应用场景与研究任务

共享 GPU 服务器
任务仅分配一张 GPU 和部分内存

离线生成
问答、代码生成允许更长响应时间

单卡工作站
权重规模超过任务可用内存

MECC 的三项 Insight
初始放置 · 跨层留存 · 在线纠偏

目标：在单卡容量约束下部署完整 MoE，并减少专家权重进入计算路径时的等待。

Related Work: Deployment Gaps

- 现有系统已能跨显存、内存和 SSD 按需执行专家，并在推理时保留常用专家。
  共享服务器还需要回答：给定单任务预算如何安排驻留、如何减少初始冷读、
  以及部署前如何估计 SSD 压力。MECC 将这三项能力纳入同一方案。

方法	三级存储支撑	完整专家计算	按预算生成驻留方案	历史热点预热	冷读压力预估	在线适应热点变化
SwapMoE[1]	✗	✗	✗	✓	✗	✓
Fiddler[2]	✗	✓	✗	✗	✗	✗
MoE-Infinity[3]	✗	✓	✗	✗	✗	✓
MoE-Lightning[4]	✗	✓	✗	✗	✗	✗
SSD-LLaMA[5]	✓	✓	✗	✗	✗	✓
MECC	✓	✓	✓	✓	✓	✓

Overview: Three Insights, One Tiered Cache

- **MECC 将显存、CPU 内存和 SSD 视为同一驻留空间。三个 Insight 分别作用于启动前、服务中和任务变化后：先利用画像建立初态，再根据真实请求保留并更新专家。**



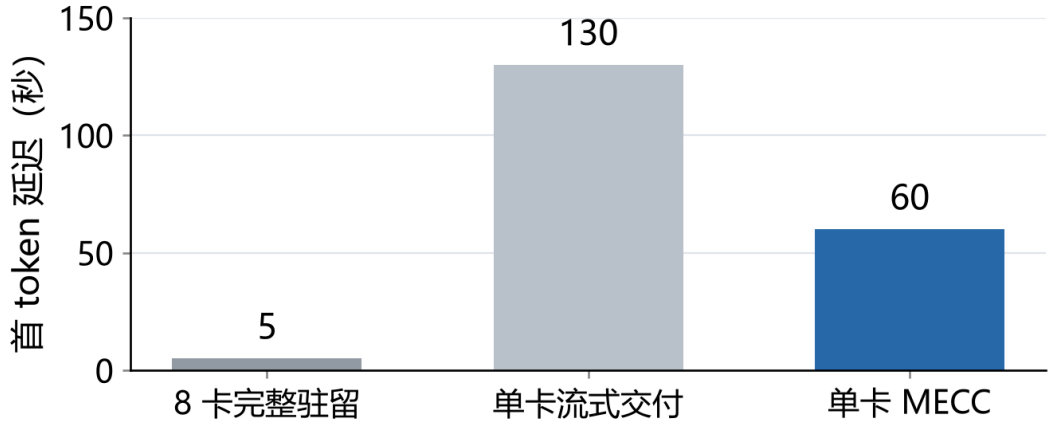
深蓝：此阶段频繁访问或当前被选中的专家；其余方块显示专家的最快驻留位置。

同一三级缓存：画像提供初始覆盖，联合保留承接再访，在线纠偏适应新热点。

Motivation I: The First Token Waits for Cold Experts

- 多卡完整驻留时，所选专家已在 GPU；单卡的快层容量有限，首个请求可能选中 SSD 上的专家。图中比较同一 8×7B 问答任务的首 token 延迟，并画出产生等待的权重交付路径。

(a) 首 token 延迟



单卡流式交付的首 token 等待显著更长。

(b) 同一次路由选择的两种部署

多卡：全部专家已分布在 GPU

E1 E2 E3 E4 E5 E6 E7 **E8**

选中 E8 → GPU 显存命中 → 执行

单卡：E8 仍在 SSD

SSD E8 → CPU 缓冲 → GPU 执行

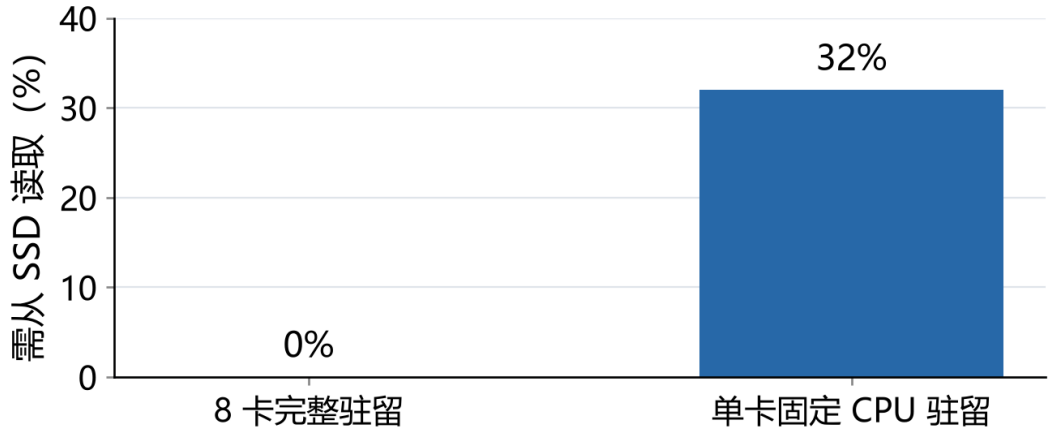
SSD 冷读和 CPU→GPU 搬运位于首 token 的关键路径。

设计问题①：启动前，怎样优先驻留最可能被选中的专家?

Motivation II: Repeated Cold Reads During Serving

- **多卡可把全部专家分布在显存中，服务时再次选中同一专家仍能直接命中。单卡的显存与 CPU 额度有限：专家从 SSD 加载后可能被后续访问挤出，再次选中时又要冷读。图比较服务期冷读占比。**

(a) 服务期 SSD 冷读占比



完整驻留避免重复冷读；有限快层产生反复 SSD 访问。

(b) 同一专家被再次选中的路径

多卡：全部专家分布于 GPU 显存



E6 → 其他专家 → E6：两次均命中显存

单卡：有限快层，部分专家位于 SSD



E6 → E7/E8 挤出 E6 → E6：再次从 SSD 读取

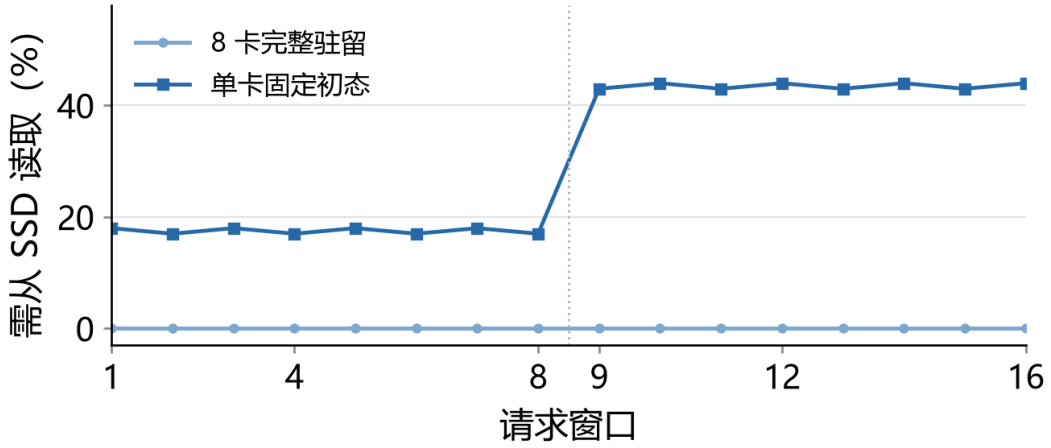
CPU 保留固定集合，无法承接被挤出的 E6。

设计问题②：单卡如何在有限显存和 CPU 额度内保留可能再次调用的专家?

Motivation III: Task Changes Shift Expert Demand

- **多卡完整驻留时，任务切换只改变访问哪些专家，所选专家仍在显存。单卡的初始驻留依据旧任务画像；若驻留集合不随路由更新，新任务频繁使用的专家仍在 SSD，冷读比例会持续升高。**

(a) 任务切换后的 SSD 冷读占比



第 9 个窗口切换任务；单卡固定初态持续错过新热点。

(b) 任务 B 的新热点位于何处

多卡：新热点仍在 GPU 显存



任务 A → 任务 B：E6–E8 直接从显存读取

单卡：固定初态仍保留旧热点



任务 B 频繁访问 E6–E8，却仍需从 SSD 读取。

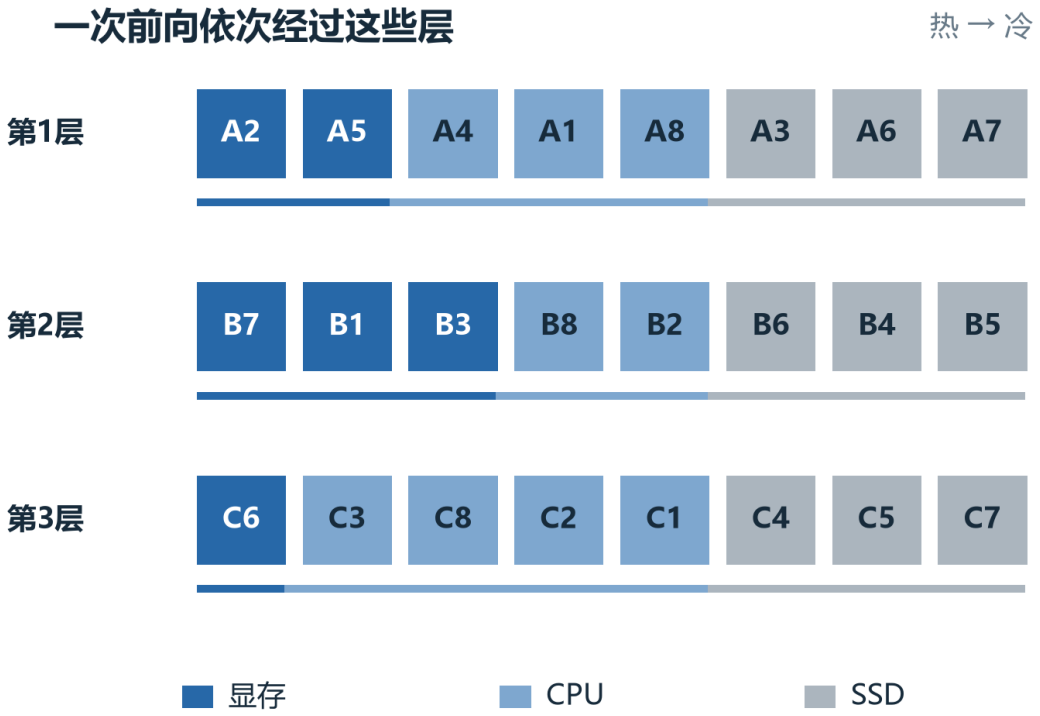
访问热点已改变；驻留集合没有改变。

设计问题③：任务变化后，单卡怎样依据真实路由修正专家驻留？

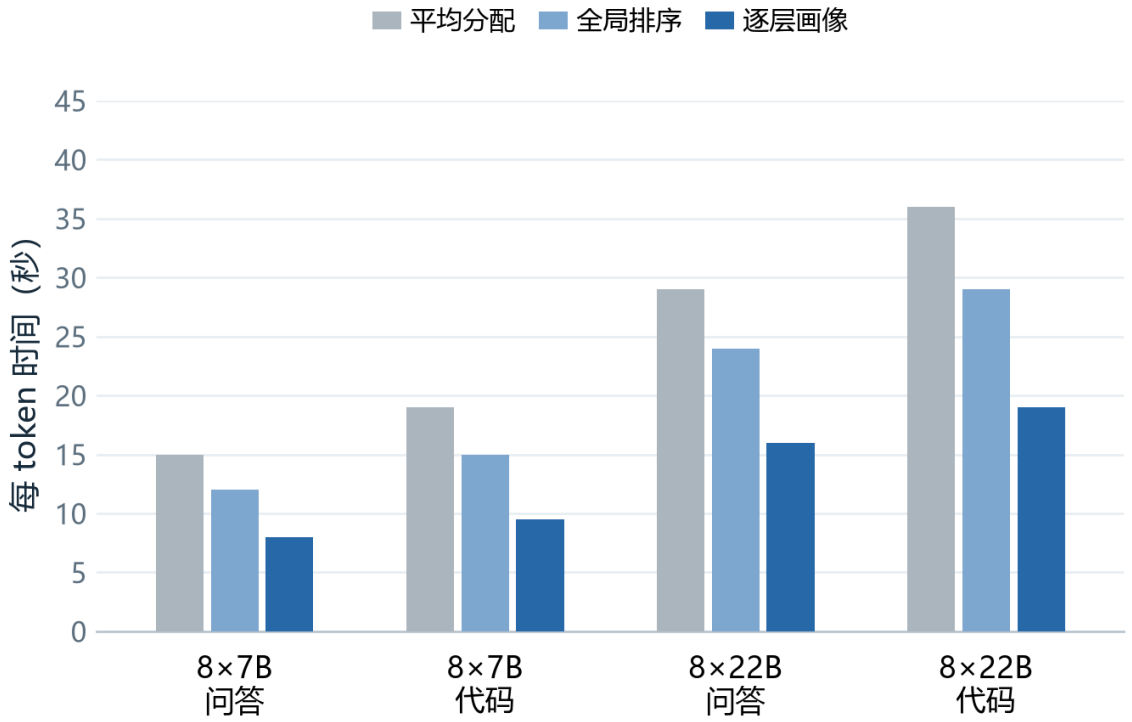
Insight I: Profile-Guided Tier Boundaries

- Insight：各层专家的调用次数可以指导初始放置。用代表性数据完整运行模型，记录每层路由选中了哪些专家；再分别对各层的全部专家排序，按容量放入显存、CPU 和 SSD。

方法示意：逐层确定驻留



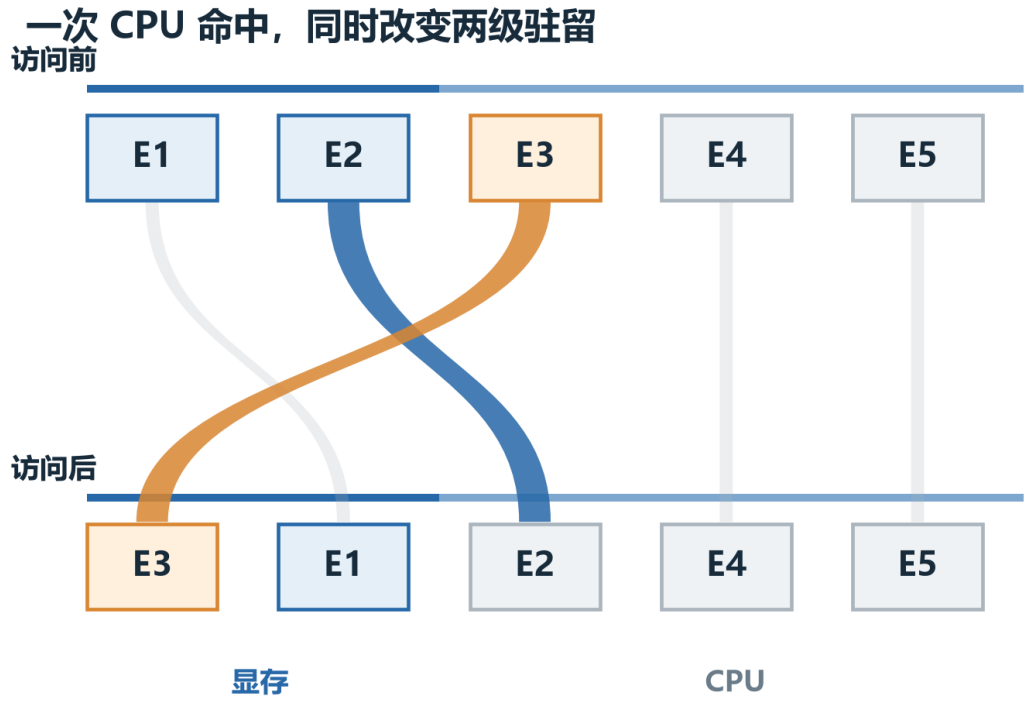
消融：只改变初始放置



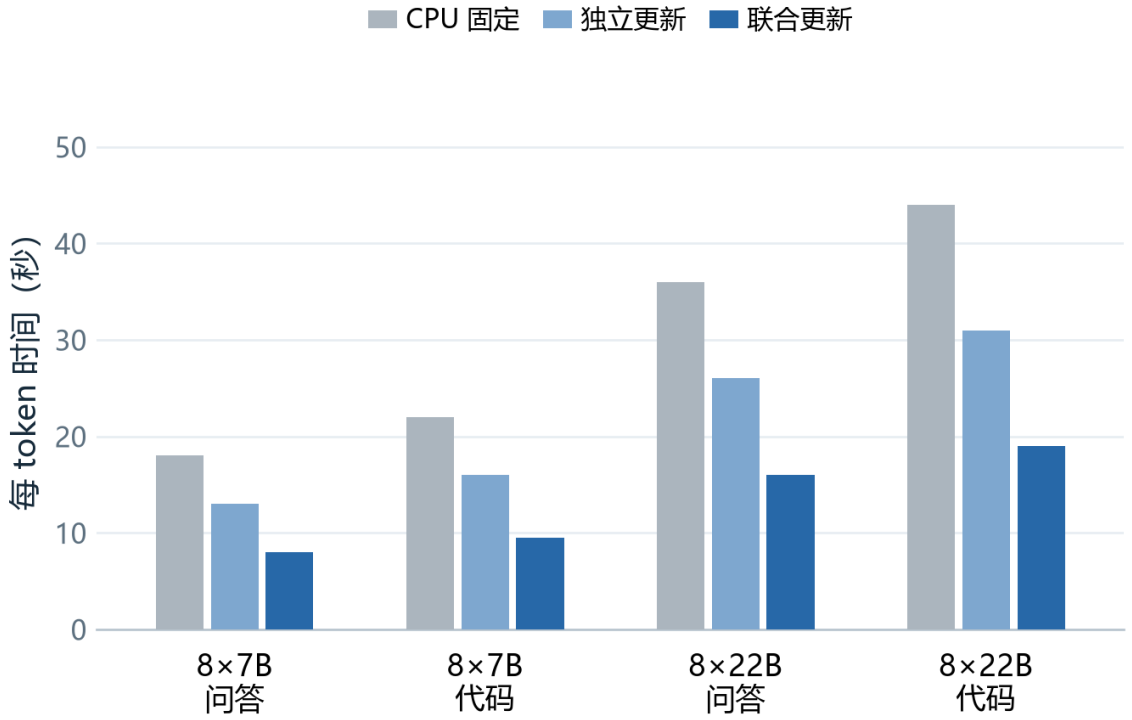
Insight II: One Hit, Two Cache Moves

- Insight：CPU 可以承接显存淘汰的专家，保留再次命中的机会。每次 CPU 命中时，我们把命中专家送入显存，并把被替换的专家降入 CPU，同步更新两级缓存。

方法示意：一次命中，两级更新



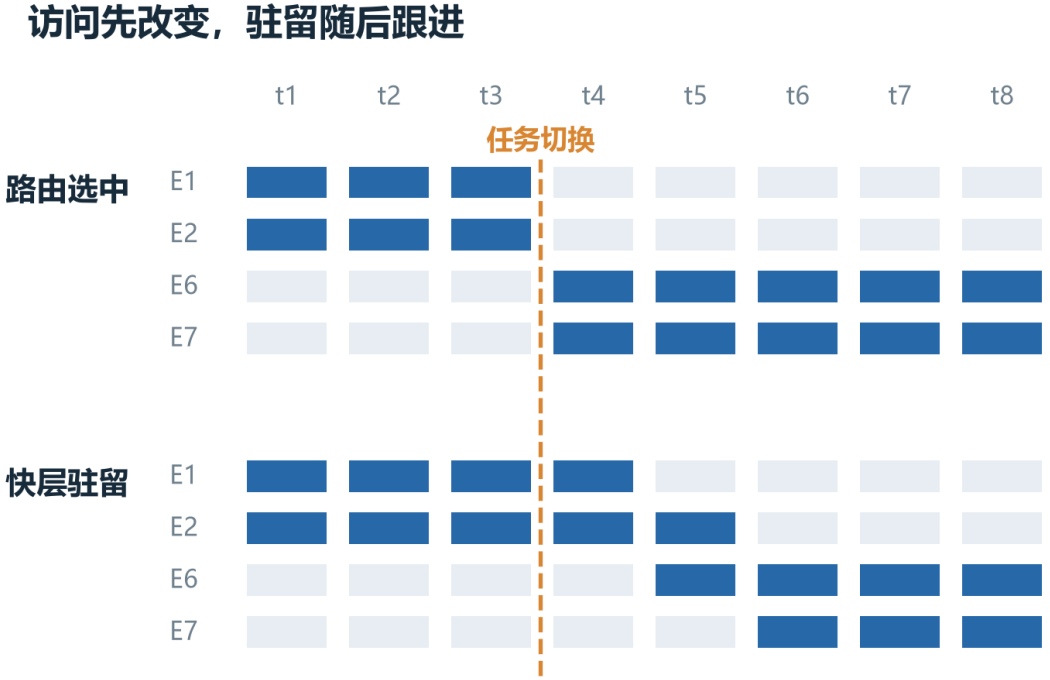
消融：只改变缓存更新



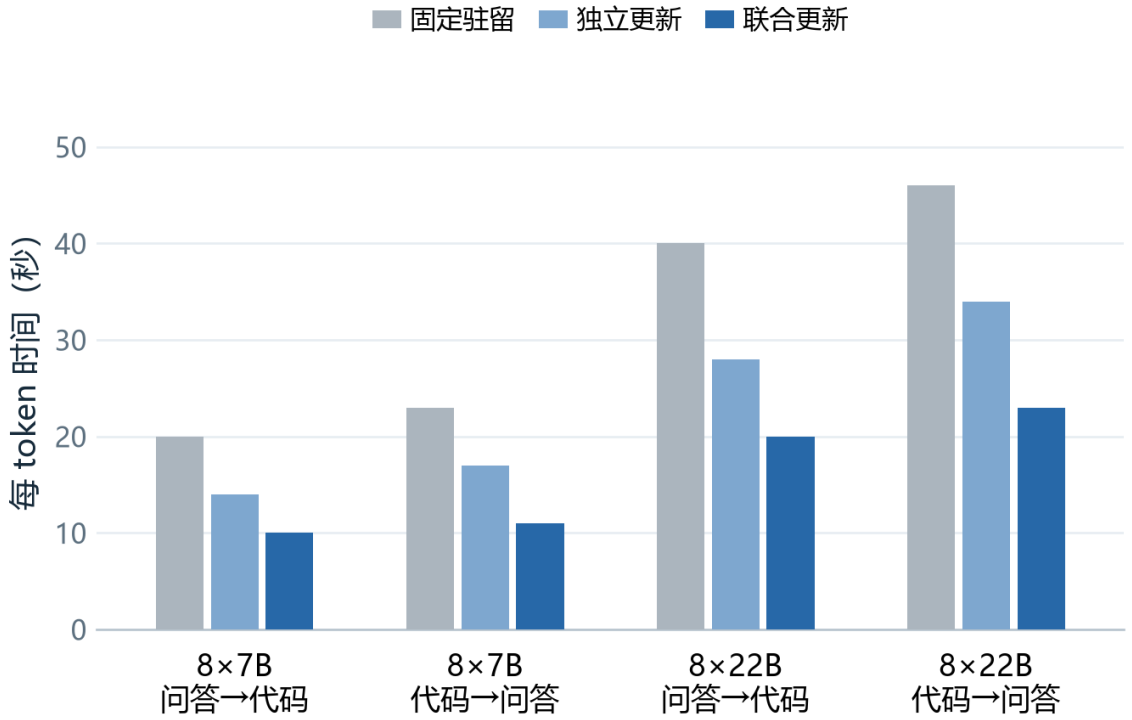
Insight III: Routes Reshape Residency

- Insight：真实路由可以持续修正部署前的放置计划。服务过程中，我们按实际访问更新显存和 CPU 的最近使用顺序，让新的常用专家逐步进入快层。

方法示意：按真实访问调整驻留



消融：任务切换后



System Overview: From Profile to Expert Execution

- **MECC 有两个阶段：部署前编译放置计划，服务时根据真实路由访问和更新缓存。**
  SSD 保存完整专家权重；显存和 CPU 只保留其中一部分，权重就绪后才执行所选专家。

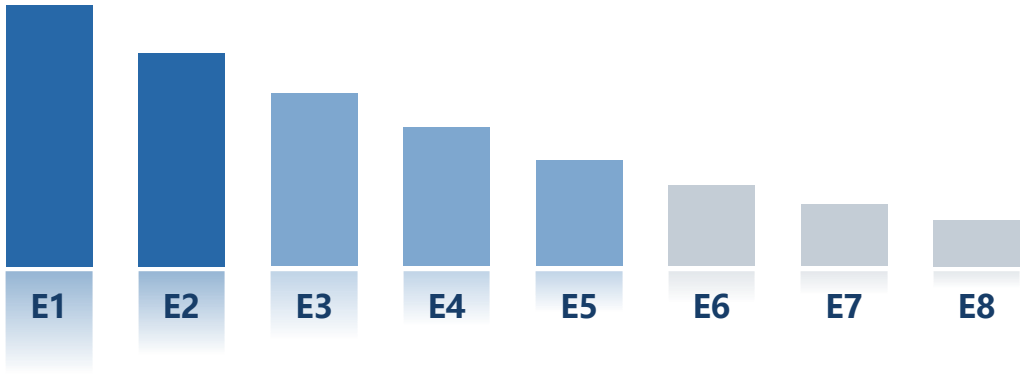


编译期提供起点；运行期不断纠偏；专家数值和路由选择不因搬运而改变。

Method I: Budget-Constrained Placement

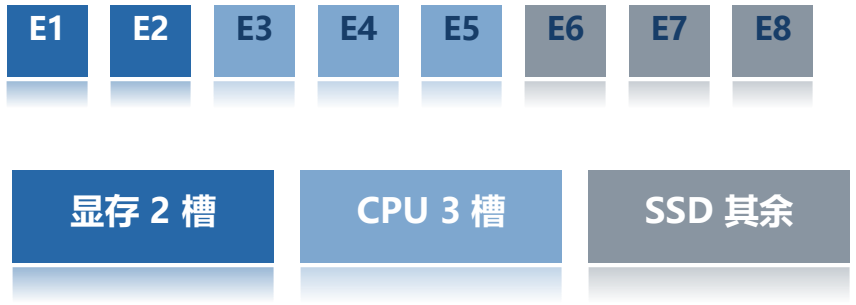
- 编译器读取每层专家访问画像、权重大小和单任务显存/CPU 额度。它先确定每层可放多少专家，再按访问热度填入显存、CPU 和 SSD，输出启动时的驻留计划。

输入：按访问频率排序的专家



访问越频繁，冷读的预期代价越高。

输出：每层的初始驻留

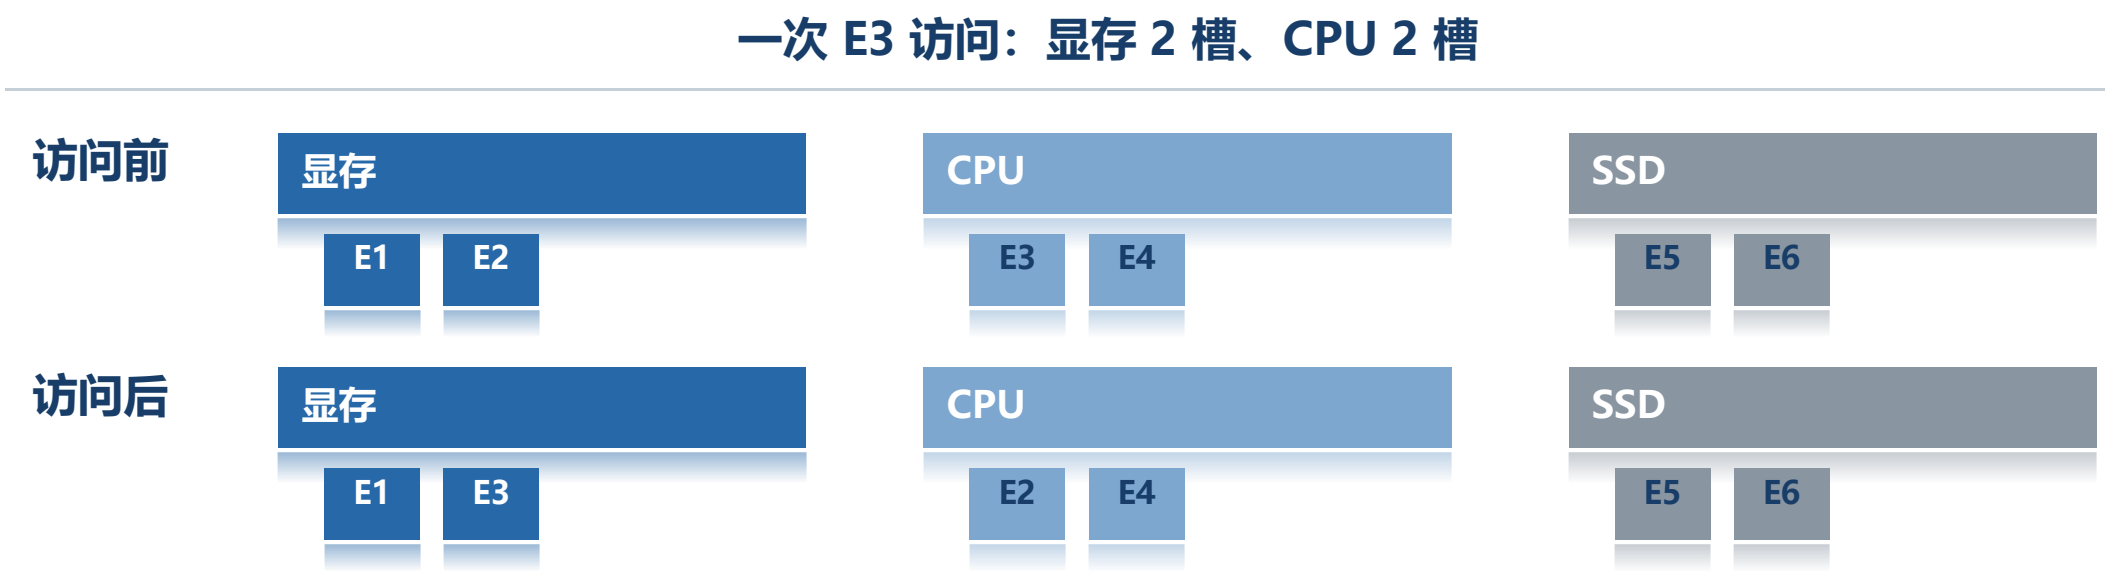


计划规定“先放哪里”；实际访问仍会在运行中改变这些位置。

目标：在给定容量下，降低所选专家的预期取数代价。

Method II: Joint HBM–CPU Retention

- 服务期间，每次路由选择都先查显存，再查 CPU；两层都没有时才读取 SSD。CPU 命中可以提升到显存，被替换的显存专家尽量留在 CPU。下图演示一次访问如何改变驻留状态。

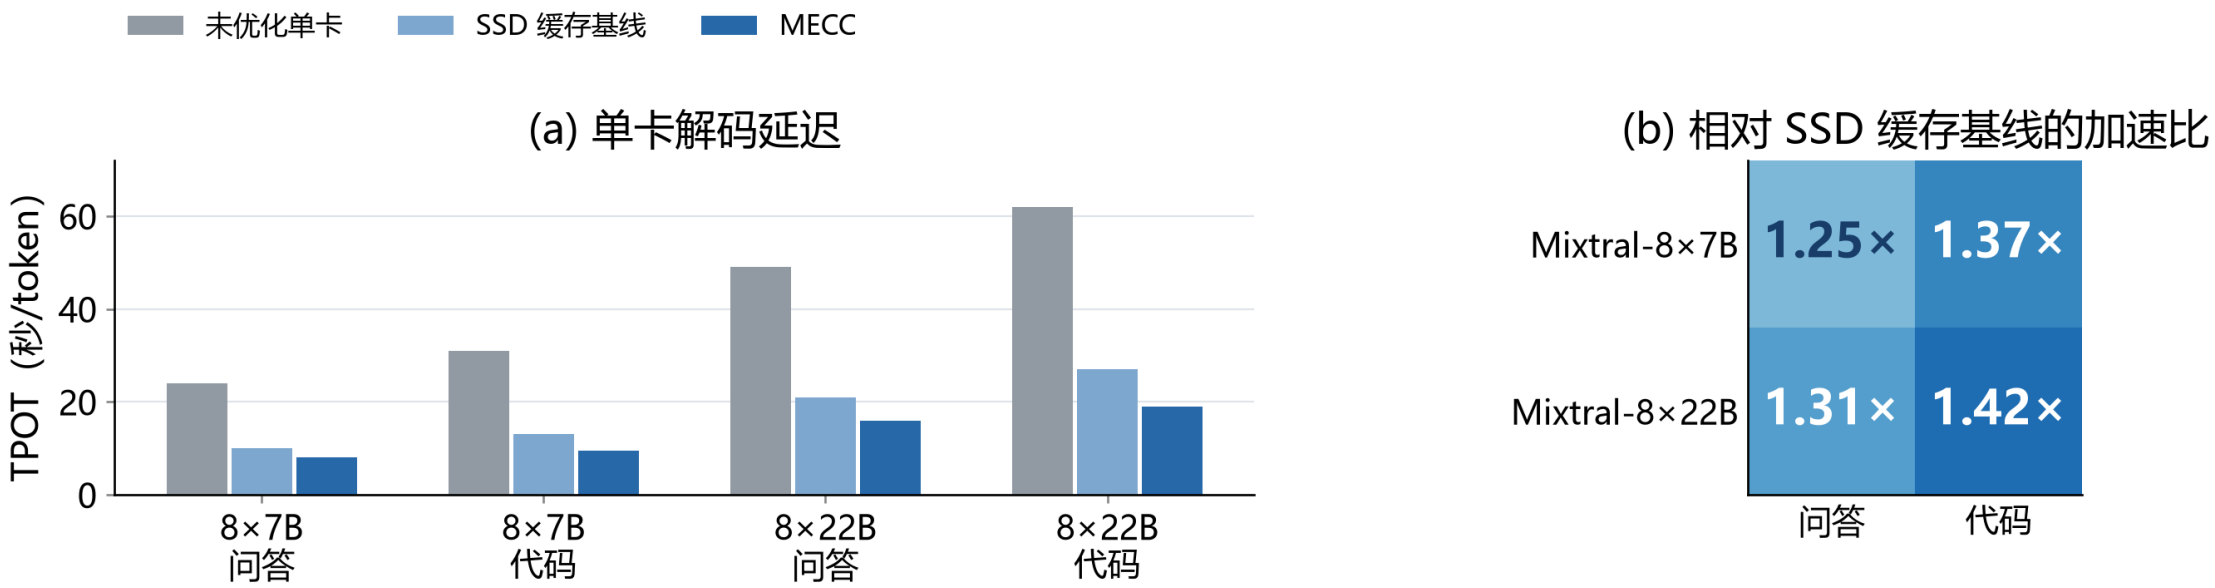


E3 从 CPU 升到显存；E2 降到 CPU。E2 后续再访时仍能避开 SSD。

搬运只改变权重所在位置；路由选择、权重数值与专家计算保持不变。

Results: Single-GPU Decode Latency

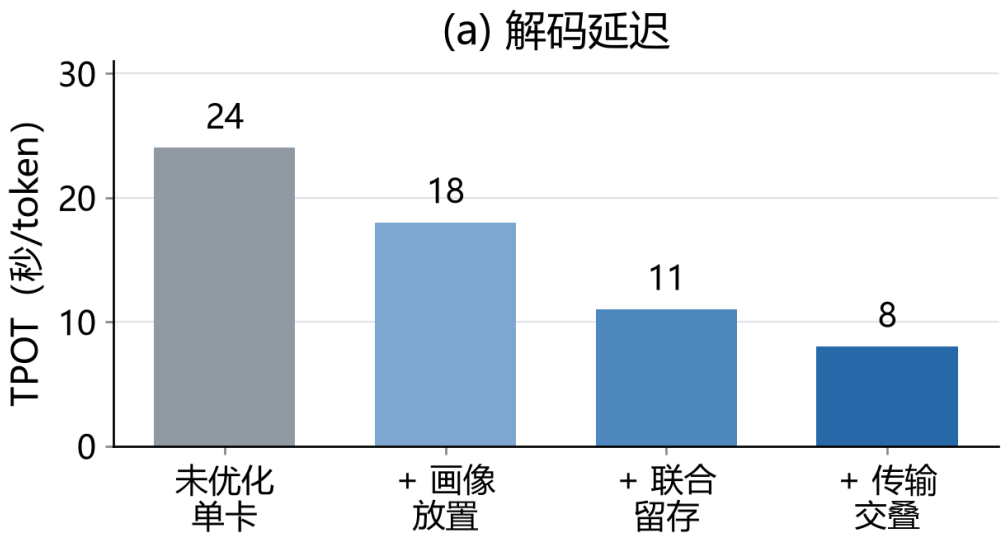
- **在四组模型与任务的理想结果中，MECC 的单卡解码延迟低于未优化流式执行和本地 SSD 缓存基线。左侧柱状图报告每 token 延迟；右侧热图报告相对较接近基线的加速比。**

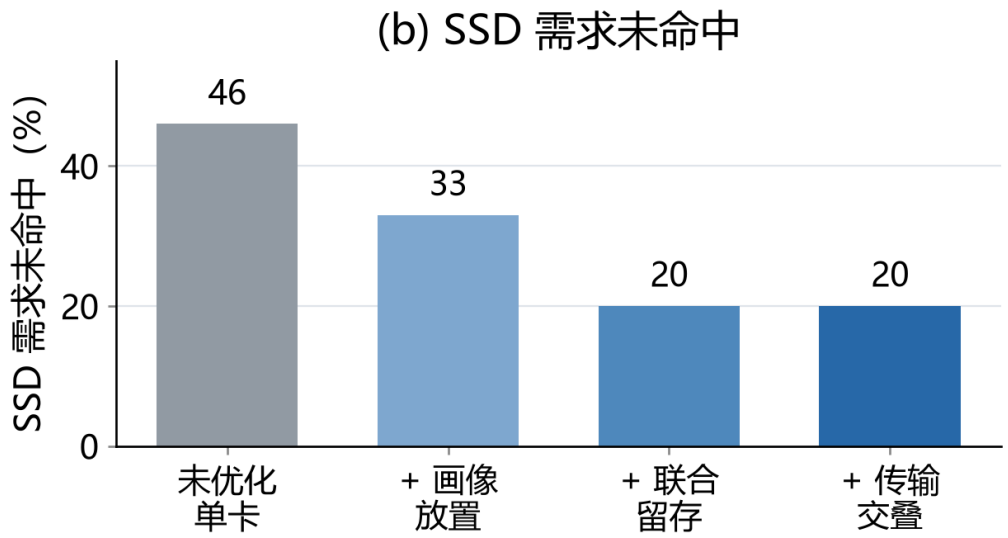


同一任务内存额度下，MECC 与 SSD 缓存基线相差 1.25–1.42×。

Ablation: Placement, Retention, Delivery

- **逐项加入画像放置、跨层联合留存和交叠交付，区分每项设计的贡献。左图显示解码延迟，右图显示真正落到 SSD 的请求比例；只有交付优化进一步减少了暴露等待。**

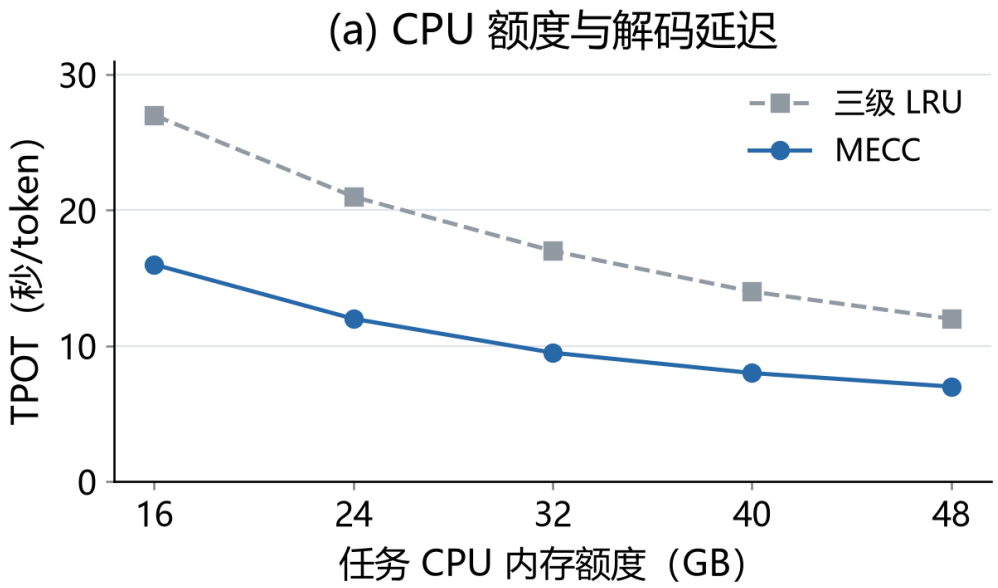


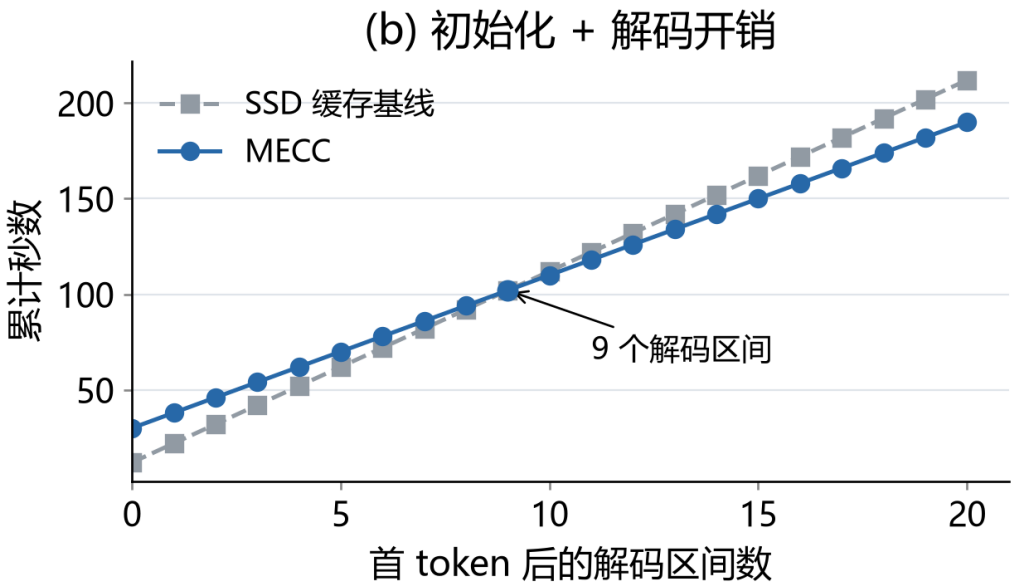


首组任务：24 → 18 → 11 → 8 秒/token；SSD 请求比例：46% → 33% → 20%。

Resource Sensitivity: CPU Cap and Service Length

- **可分配给任务的 CPU 内存越多，能够保留的专家越多；服务越长，启动时的画像和加载开销越容易被后续 token 摊薄。两张图分别改变内存额度和解码时域。**

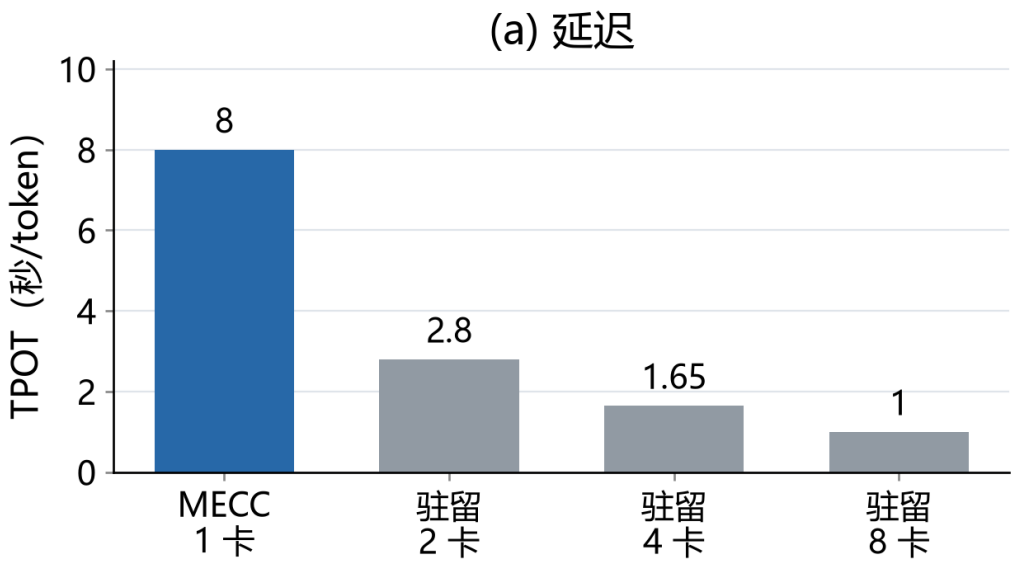


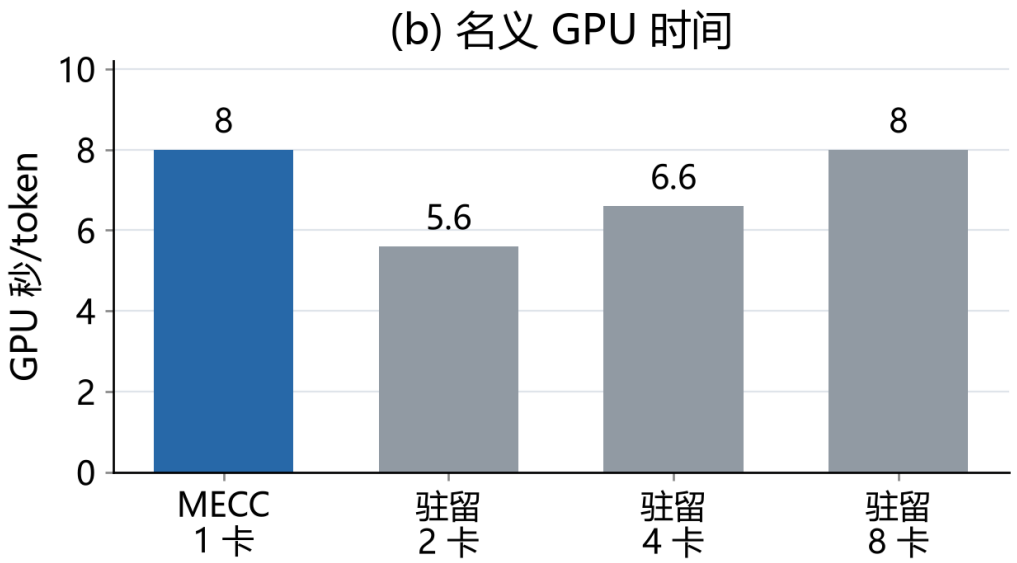


部署选择同时取决于 CPU 额度和请求长度。

One GPU versus Resident Multi-GPU

- **完整驻留的多卡方案拥有更短的单 token 延迟；MECC 用一张 GPU 执行完整模型。右图把 GPU 张数乘以延迟，仅作为名义 GPU 时间的比较。**





单卡方案适用于 GPU 配额受限、能够接受较长单请求延迟的任务。

Conclusion: Single-GPU SSD-Active MoE

- **当单任务 CPU 内存不能容纳全部专家时，SSD 会进入 MoE 推理路径。MECC 用画像引导初态，以跨层保留承接再访，并依据真实路由修正驻留，减少冷专家访问造成的等待。**

放置

画像确定初始位置

回应冷启动

留存

显存与 CPU 联合更新

回应重复冷读

纠偏

按真实路由修正驻留

回应热点漂移

面向一张 GPU、有限 CPU 额度、允许一定响应延迟的完整 MoE 部署。