MECC：让一张 GPU 服务完整的 MoE 模型

从专家路由、单卡部署，到 MECC 的编译与运行机制

配套展示：17 页组会 PPT · 阅读时间：约 5 小时 · 讨论与代码走读：约 3 小时

> **一句话认识这项工作：** MoE 每次只计算少数专家，完整模型却包含大量专家权重。MECC 根据一项推理任务可用的显存和主存，预先安排常用专家的位置，再利用实际路由持续更新缓存，使一张 GPU 也能访问并执行完整模型的专家。

这一天会学到什么

读完后，你应能从一个 prompt 出发，讲清楚路由器如何选择专家、专家权重为什么需要跨 HDD / CPU / GPU 移动、MECC 如何生成初始放置计划，以及推理过程中缓存如何变化。你也会知道 SwapMoE、Fiddler、MoE-Infinity、MoE-Lightning、SSD-LLaMA、FlashMoE 和 MoE-CORE 各自解决了哪一部分问题，如何阅读它们的实验。

时间	主题	对应 PPT
09:00—10:15	MoE 的计算机制与单卡部署问题	1
10:15—12:00	七项相关工作的动机、机制和实验	2
13:00—14:00	从冷启动、重复读取到任务变化	3—6
14:00—16:00	MECC 的三个设计、系统总览和完整生命周期	7—12
16:00—17:00	A100 实验、消融与资源配置	13—16
17:00—18:00	顺着代码和结果文件复盘	17

1. 一个 token 如何经过 MoE

Transformer 的普通前馈层对所有 token 使用同一组参数。MoE 层则准备多个前馈网络，称为**专家**；路由器针对当前 token 的隐藏状态给专家打分，只选择其中 `top-k` 个。若第 `l` 层的隐藏状态为 `h_l`，计算可写为：

```
分数:        score[l, e] = router_l(h_l)[e]
选中专家:    S_l = top-k(score[l, :])
层的输出:    y_l = Σ_(e∈S_l) gate[l, e] × expert[l, e](h_l)
```

这产生了 MoE 的关键特征：**本次计算稀疏，模型权重仍然庞大。**当前 token 只用两三个专家，不代表下一 token、下一层或下一个问题也用它们。服务系统必须随时能取到被路由器选中的原专家。Mixtral-8×7B 是这个问题的直观例子：32 个 MoE 层，每层 8 个专家，专家对象总数为 256。Mixtral 模型论

文

专家的唯一名字是“层号 + 专家号”。下表把三层分别记为 A、B、C，避免把不同层同编号的专家误认为同一块权重。

当前前向位置	路由结果	权重所在位置	本层怎么做
第 1 层	`A2`、`A5`	GPU、CPU	`A2` 直接算；`A5` 传到 GPU 后算
第 2 层	`B1`、`B7`	GPU、HDD	`B1` 直接算；`B7` 从 HDD 读取后再算
第 3 层	`C3`、`C6`	CPU、GPU	按这一层的缓存状态访问，再继续前向

每进入一层，都需要**查找**本次路由选中的专家；只有专家尚未在计算位置时才需要搬运。注意力、路由器、KV 缓存、激活和运行时工作区也占显存，不能把一张 A100 的全部显存都分配给专家。

1.1 为什么“一张卡”改变了问题

多卡部署可以把专家分布在多张 GPU 的显存里；单卡部署必须在一张卡上反复使用有限的专家缓存。一个任务通常还只分到服务器主存的一部分。假设任务的专家显存预算为 `B_H`，主存预算为 `B_C`，而专家集合总大小为 `W_E`。当快层无法覆盖所有专家时，HDD 保存完整权重，GPU 和 CPU 保留当前最可能使用的部分。

一次 HDD 未命中的访问路径是：

```
路由器选中专家 → 查找 GPU 缓存 → 查找 CPU 缓存
                                      ↓ 均未命中
                    HDD 读取 → CPU 缓冲 → GPU 传输 → 原专家计算
```

因此单卡推理的目标不是改变模型答案，而是让**等待专家权重**尽量少地出现在生成路径上。共享服务器尤其适合这个问题：宿主机即使有约 1 TB 主存，单个推理任务也可能只获分配几十 GB。MECC 根据任务额度做计划，而不是假设整台服务器只运行这一项任务。

把问题压缩成一句话： 一张 GPU 如何在有限显存和主存下，持续执行路由器选中的完整 MoE 专家，并尽量减少 HDD 读取？

2. 已有工作分别从哪里切入

这一领域有几条互补路线：控制模型占用、选择 CPU/GPU 执行位置、预测未来要用的专家、提高批处理流水效率、优化磁盘到显存的数据交付，以及设计专家替换规则。下面统一按**研究动机** → **核心机制** → **原论文实验**介绍。论文结果是在各自模型、硬件、精度和负载下得到的，读表时请把这四项一起记住。

SwapMoE：有限内存里保留一组可用专家

动机。 参数量增长快于设备内存；直接交换权重增加等待。**机制。** 维护一组 Virtual Experts，并管理其与实际专家的映射，让内存占用可以随预算调整。**实验。** 原论文以 Switch Transformer 的文本摘要为例，报告内存 **14.2→4.7 GiB**、延迟约减半，Rouge-2 同时下降 **0.041**。它展示了内存、速度和质量之

间的权衡。SwapMoE

MECC 的相应问题是：当专家完整权重保存在 HDD，CPU 里的一组专家如果固定不变，会怎样影响后续重复访问？我们的 A100 对照用 fp16 权重实现了“静态 CPU 池 + GPU 动态缓存”这一机制。

Fiddler：选择让 CPU 算，还是搬到 GPU 算

动机。 GPU 显存不足时，传输整个专家权重很贵；有时传输激活并在 CPU 上计算更合适。**机制。** 针对输入规模、生成方式和硬件，选择 CPU/GPU 专家执行方案。**实验。** ICLR 2025 版使用 Mixtral-8×7B，两套平台包括 Quadro RTX 6000 24 GiB + Xeon Gold 6126、RTX 6000 Ada 约 48 GiB + Xeon Platinum 8480+；论文对其所测基线报告单批 **1.26×**、长 prefill **1.30×**、beam search **11.57×** 加速。Fiddler

Fiddler 关注**在哪里计算**。MECC 关注在任务预算内**保留哪些专家权重**；这两个决策也可以共同设计。

MoE-Infinity：利用请求内反复出现的路由模式

动机。 个人设备上常见单请求、batch=1 的生成过程，专家激活具有可利用的稀疏性。**机制。** 从路由激活轨迹中选择代表模式，指导专家缓存替换和预取。**实验。** 论文使用 DeepSeek、Mixtral 及多类任务，对 vLLM、Ollama、DeepSpeed 和 BrainStorm 等系统报告 **3.1—16.7×** 的每 token 延迟改善。MoE-Infinity

这项工作让我们看到：路由历史本身是一种系统信号。MECC 把这类信号放进“部署前初态 + 运行时更新”的两阶段框架里。

MoE-Lightning：让 CPU、GPU 和 I/O 连续工作

动机。 离线批量生成时，计算与权重搬运如果交替等待，设备吞吐会很低。**机制。** CGOPipe 组织 CPU/GPU/I/O 流水，并用分层 Roofline 性能模型选择高吞吐配置。**实验。** ASPLOS 2025 版的单卡平台是 T4 16 GB 或 L4 24 GB，搭配 192 GB 主存，模型为 Mixtral-8×7B；多卡实验还覆盖 Mixtral-8×22B 和 DBRX。MTBench 输出长度为 32、64、128、256 token，另有 HELM 推理与摘要任务。论文对其批处理基线报告最高 **10.3× 吞吐**。MoE-Lightning

MoE-Lightning 的主要度量是**批吞吐**，MECC 的当前主实验主要考察单卡专家驻留和每 token 延迟。二者说明“让设备忙起来”和“减少冷读取”是两个可以叠加的问题。

SSD-LLaMA：从磁盘到显存的完整专家交付

动机。 超大 MoE 模型的完整专家池超出消费级显存与主存。**机制。** 原论文设计磁盘 I/O 管线、磁盘—主存—显存三级保留，以及 CPU/GPU 专家执行分工；每个被路由选中的专家都会执行。**实验。** 其测试机为 RTX 5090 32 GB、Intel Ultra5 230F、16 GB RAM 和 4 TB NVMe，batch=1；模型为量化的 DeepSeek-V4-Flash、Kimi-K2.7-Code 与 GLM-5.2，任务包括 MMLU 和 Alpaca。论文报告 prefill **1.52—4.19×**、decode **2.10—15.58×** 的所测基线加速，并在单张 RTX 5090 上报告万亿参数模型超过 1 token/s。SSD-LLaMA

这篇论文的名字和设备配置沿用原文。MECC 当前研究的是**HDD 场景下**，任务预算、逐层初始位置和两级热缓存联动如何影响冷读取。

FlashMoE：用访问特征决定谁离开缓存

动机。 简单 LRU 只记“最近使用”，不能充分利用专家访问频率。**机制。** 从最近性与频率构造特征，训练轻量预测器选择淘汰对象。**实验。** 论文使用 RTX 5070 Ti 16 GB、Ryzen 5 9600X 和 64 GB 装机主存，实验把可用主存压到约 1 GB；模型包括 OLMoE-1B-7B 与 Qwen3-30B-A3B。原文对所测系统报告最高 **2.6×** 加速，缓存命中率相对常见策略最高提升 **51%**。FlashMoE

它提示我们：专家替换策略是持续可优化的部分。项目里的 `flashmoe_rf_adaptation` 是把公开的最近性/频率特征移植到统一实验框架中的本地对照。

MoE-CORE：按层分配缓存并协调预取

动机。 不同 MoE 层的热点程度不同，统一分配专家槽位会浪费内存；传输也需要提前安排。**机制。** prefill 时交替装入整层专家；decode 时结合逐层容量、任务画像、路由历史与跨层预取。**实验。** 论文在 Ascend 950PR 上，将 NPU 内存限制为 84 GB、主存限制为 150 GB，评估 DeepSeek-V4-Flash-W4A8 与 GLM-5.2-W4A8C8，任务覆盖 GSM8K、HumanEval、MMLU 等；对按需加载对照，DeepSeek 的 TPOT 改善约 **1.39—1.75×**。MoE-CORE

这项工作说明**逐层差异**值得显式建模。MECC 的画像也按层记录，部署时为每层生成专家排序与缓存槽位。

看懂整个领域的速览表

系统	主要决策	原论文重点指标	与 MECC 的连接
SwapMoE	内存预算与专家映射	内存、延迟、质量	静态 CPU 池的对照
Fiddler	CPU/GPU 计算位置	单请求及特殊生成场景延迟	专家计算与搬运的取舍
MoE-Infinity	路由轨迹驱动的缓存和预取	每 token 延迟	路由历史作为决策信号
MoE-Lightning	CPU/GPU/I/O 流水	批吞吐	交付与计算重叠
SSD-LLaMA	原生三级交付与执行分工	prefill、decode 速率	完整专家磁盘交付
FlashMoE	学习式缓存替换	命中率、生成速度	最近性与频率的替换对照
MoE-CORE	逐层容量与跨层预取	TPOT、TTFT	按层处理不同热点

3. 单卡部署会连续遇到三个问题

这三个问题沿一次服务的时间线出现，对应 PPT 3—6 页。

① **第一次请求：热专家放在哪里？** 如果首次路由选中的专家位于 HDD，首 token 要等待读取和传输。多卡全显存部署通常能直接取得专家；单卡需要把有限快层留给最值得提前装载的专家。这是**初始放置**问题。

② **接下来生成：为什么同一个专家又从 HDD 读取？** 第一次访问把专家带进显存，后续访问又可能把它挤走。如果 CPU 缓存独立且固定，显存被替换的专家未必能留下；下一次路由再次选中它时，又产生一次 HDD 读取。这是**两级缓存协同**问题。

③ **请求类型改变：原本的热门专家还热门吗？** 问答任务与代码任务可能激活不同专家。部署前的热度画像提供好的起点；系统还需要根据当前请求更新驻留顺序，使新任务常用的专家逐步进入显存和主存。这是**在线适应**问题。

三者合起来就是 MECC 的设计线索：**先安排起点，再减少重复搬运，最后跟随路由变化。**

4. MECC 总览：编译一次，运行时持续更新

PPT 第 10 页的框架可以拆成两个阶段：

```
部署前
代表性输入 ─→ 逐层专家访问计数 ─→ 热度排序 ─┐
模型权重   ─→ 每个专家的大小与位置 ──────────┼─→ 编译计划
任务预算   ─→ 可用 GPU/CPU 专家缓存容量 ─────┘

运行时
输入 prompt ─→ 每层路由 ─→ 专家查找 ─→ HDD/CPU/GPU 交付
                                  └─→ 执行原专家 ─→ 更新缓存 ─→ 下一层/下一 token
```

编译计划包含每层的缓存容量 `K_H,l`、`K_C,l` 和按热度排列的专家编号。HDD 保存完整专家权重；GPU 与 CPU 保留热副本。计划决定**初态**，运行时状态则由每次实际路由推动。

4.1 Method I：从画像生成初始放置

用代表性输入运行模型，累计 `count[l,e]`，表示第 `l` 层专家 `e` 被激活的次数。编译器将各层专家排序，再在任务的显存和主存预算内确定初始驻留：高频专家先入 GPU，其后放 CPU，其他专家保留在 HDD。若有各层访问偏斜信息，编译器还可以给不同层分配不同数量的槽位。编译配置代码

为什么按层做？因为第 1 层的 `A2` 与第 2 层的 `B2` 互不相同，访问频率也不同。一个全模型的“专家 2”排名没有定义。用 Zipf 模型表示热度时，前 `k` 个专家的预计访问质量为 $H(k,\alpha)/H(N,\alpha)$；α 越大，热点越集中。这个公式帮助估算给一层多加一个缓存槽能节省多少读取。形式化说明

例子。 某层排序为 `A2 > A5 > A1 > A7 > …`，该层有两个 GPU 槽、两个 CPU 槽，那么初始位置为 GPU `{A2,A5}`，CPU `{A1,A7}`。每层都独立形成这样的排序。

4.2 Method II：一次专家访问如何更新两级缓存

MECC 的运行期核心是 GPU 与 CPU 的联合动态缓存。缓存策略代码

访问前的专家位置	本次动作	访问后的变化
GPU	直接计算	更新 GPU 最近使用顺序
CPU	传入 GPU 后计算	专家进入 GPU；被替换的 GPU 专家进入 CPU
HDD	读到 CPU 缓冲，再传入 GPU 计算	专家进入热缓存；容量满时逐级替换

联合更新的关键是**降级**：GPU 腾出的专家先进入 CPU，而不是立刻失去热副本。与之对称，CPU 命中的专家可以**升级**回 GPU。CPU 缓存容量满时，最旧的热副本被淘汰；HDD 中的完整权重仍可在下次需要时读取。缓存引擎代码

4.3 Insight III：让实际路由改写缓存顺序

部署前画像给出一份排序，在线路由不断提供新证据。MECC 不修改模型路由器，也不改路由器选择的专家；它根据真实访问更新最近使用顺序。任务变化后，新任务常用的专家经过若干次访问进入 GPU/CPU，旧热点逐步退出。这样，静态计划和动态访问各负责一个时间尺度。

5. 跟着一条 prompt，走完 MECC 的生命周期

假设用户输入：“请解释一段 Python 程序为什么超时。”我们用三层缩小模型说明全过程；实际 Mixtral 有更多层。

1. **部署前画像。** 在预先选定的请求集合上执行模型，记录 `A2`、`B7`、`C3` 等专家的路由次数。编译器按层排序，生成每层 `K_H,1/K_C,1` 和初始驻留名单。
2. **构造权重存储。** 每个专家以（层号，专家号）识别，完整权重写入 HDD store；manifest 记录模型与权重版本。GPU 和 CPU 装载初始热专家。
3. **第一个 token 的第 1 层。** 路由器选择 `A2,A7`。`A2` 已在 GPU，直接算；`A7` 在 CPU，传入 GPU。腾出的 GPU 专家降入 CPU。
4. **第 2 层。** 路由器选择 `B1,B6`。`B1` 在 GPU；`B6` 仅在 HDD。系统读入 `B6`，传到 GPU，运行它原有的前馈权重，按路由系数合并两位专家的输出。
5. **第 3 层与下一 token。** 每层重复“路由—查找—交付—计算—更新”。下一 token 再经过所有层，但缓存状态已因上一 token 改变，很多重复访问转为 GPU/CPU 命中。
6. **下一个任务。** 若后续请求变成数学问答，新的常用专家逐渐占据热层。系统继续使用同一份完整权重和同一套访问规则。

这条时间线回答了常见疑问：**每层都会查找专家，但并非每层都会搬运；编译期按层统计热度，运行期按实际路由更新位置。**

6. 怎么读实验结果

PPT 13—16 页分别组织主性能、逐项消融、资源预算和单卡/多卡取舍。下面先用已经落盘的 A100 结果建立尺度，再用同样的指标理解后续扩展实验。

6.1 单卡 A100：完整 Mixtral 的一次运行

主实验采用单张 A100 80 GB、Mixtral-8×7B、专家缓存显存预算 50 GB、CPU 预算 40 GB。输入为 8 条 WikiText-2 请求，每条最多生成 64 token；PPL 使用 1024-token 的 WikiText-2 片段。运行时完整专家由 HDD 逻辑存储提供。每个策略独立运行一次，以下是可直接从 `result.json` 复算的观测。主实验来源

本地策略	TPOT（秒/token）	TTFT（秒）	这行回答的问题
naive	13.04	156.86	朴素单卡权重交付需要多久?
swapmoe	21.75	174.19	CPU 专家池固定时会怎样?
ours	**7.38**	**139.14**	GPU/CPU 联合更新后的表现
ours_io	7.78	139.80	少了部分交付优化会怎样?
flashmoe_rf_adaptation	**7.19**	101.76	最近性 + 频率替换能达到什么水平?
fiddler	8.26	398.45	把部分专家放到 CPU 计算会怎样?

在这组单次运行中，MECC 的每 token 延迟相对本地静态 CPU 池对照约降低到 **1/2.95**，相对 naive 降到 **1/1.77**。最近性 + 频率的本地适配在本组数据中为 **7.19 秒/token**，表明替换策略仍有进一步研究空间。五个精确专家执行路径的 PPL 都约为 **3.427**；`fiddler` 路径为 **3.432**。

读这张表时把三个指标分开：**TTFT** 是首 token 等待，**TPOT** 是后续 token 平均间隔，**PPL** 是给定文本的语言建模指标。一次完整请求还应结合 prompt 长度、输出长度与生成 token 总数来评价。原始结果目录

6.2 为什么联合缓存有作用

本地独立缓存消融在同样的 50/40 GB 配置与 8×64 输入规模下，TPOT 为 **32.94 秒/token**；联合缓存的 MECC 为 **7.38 秒/token**。两者的全阶段冷层访问计数占比分别为 **47.9%** 和 **12.5%**。这张图最适合与第 4.2 节的“GPU 淘汰专家降入 CPU”状态转移一起看。消融来源

6.3 可用 CPU 内存决定冷读取有多频繁

同一 WikiText-2 输入来源、显存预算 50 GB 的两档单次观测中，MECC 的 CPU 预算从 **30 GB** 提高到 **60 GB**，TPOT 从 **14.46** 降到 **0.76 秒/token**。当热层足以容纳全部专家时，专家权重不再频繁访问 HDD。这个结果把“任务获得多少主存”与实际生成体验直接联系起来。预算实验来源

6.4 如何看 PPT 中的其余图

第 13 页关心**模型/任务变化时的延迟**；第 14 页关心**初始放置、联合缓存和交付重叠各贡献多少**；第 15 页关心**CPU 预算与生成长度**；第 16 页关心**一张卡与多张卡的资源取舍**。其中跨模型与多卡图使用展示用目标数值，后续实测应按同模型、同精度、同输入和同计时定义替换。这样四张图就构成一条完整论证链：**能运行 → 为什么快 → 资源变化后如何变化 → 为什么值得单卡部署。**

7. 给专家的三条主线

模型主线。 先看路由器为每层选了哪些原专家，再看这些权重怎样到达计算设备。稀疏激活解释了“为什么可以缓存”，完整专家集合解释了“为什么需要 HDD”。

系统主线。 部署前的画像决定缓存初态；运行时联合更新管理 GPU/CPU 驻留；真实路由推动任务变化后的缓存迁移。这三项分别作用于首次访问、重复访问和长期访问分布。

实验主线。 主性能看 TTFT/TPOT；机制解释看各阶段冷读取与缓存状态；质量看相同权重和输入的 PPL/logits；资源取舍看任务预算与 GPU 数量。把每个柱高对应到这条主线，图才容易读懂。

8. 17 页 PPT 的快速导览

页码	你要带走的一个概念
1	单卡 MoE 的核心矛盾：稀疏计算与庞大专家权重并存
2	现有系统分别优化容量、执行位置、预取、流水和替换
3	MECC 由初始放置、联合缓存、在线更新组成
4	首次访问的 HDD 权重读取进入首 token 路径
5	缓存替换决定同一专家会不会被再次读取
6	任务变化改变专家热度
7	对每一层独立统计专家热度
8	GPU 淘汰专家可以降到 CPU，CPU 专家可以升到 GPU
9	实际路由持续更新缓存顺序
10	框架分成部署前编译与运行时交付
11	编译产物是各层容量和专家排序
12	一次访问经历查找、搬运、计算与缓存更新
13	主性能比较单卡方案的解码延迟
14	消融分解三项设计的作用
15	CPU 预算与生成长度改变缓存收益
16	单卡与多卡在等待时间和 GPU 数量之间取舍
17	MECC 用受限热层服务完整 MoE 专家集合

9. 一小时动手走读

1. 打开 `compile_config.py`，找到读取逐层访问计数、计算 `K_H/K_C` 和输出 `placement` 的位置。用纸画出某一层 8 个专家在 2 个 GPU 槽、2 个 CPU 槽下的初态。

2. 打开 `policy_plugin.py` 的 `OursPolicy.access`，跟踪一个 GPU 命中、一个 CPU 命中和一个 HDD 未命中；再到 `tiered_engine.py` 看淘汰时的降级。
3. 打开 `run_e2e.py` 和主实验结果目录，选 `a100-main-ours-20261104` 与 `a100-main-swapmoe-20261104` 的 `result.json`，用 TPOT 计算 `21.75165/7.38198≈2.95`。
4. 再看实验溯源表与相关工作复现审计，把每个本地策略映射到它实际实现的机制。

最后做一次口头复述： 用三分钟解释“一个 token 穿过三层 MoE 时发生了什么”；再用三分钟解释“MECC 的部署前计划如何影响第一次请求，运行期缓存如何影响下一次请求”。如果能清楚说出这两段，你已经抓住单卡 MoE 部署的主线。