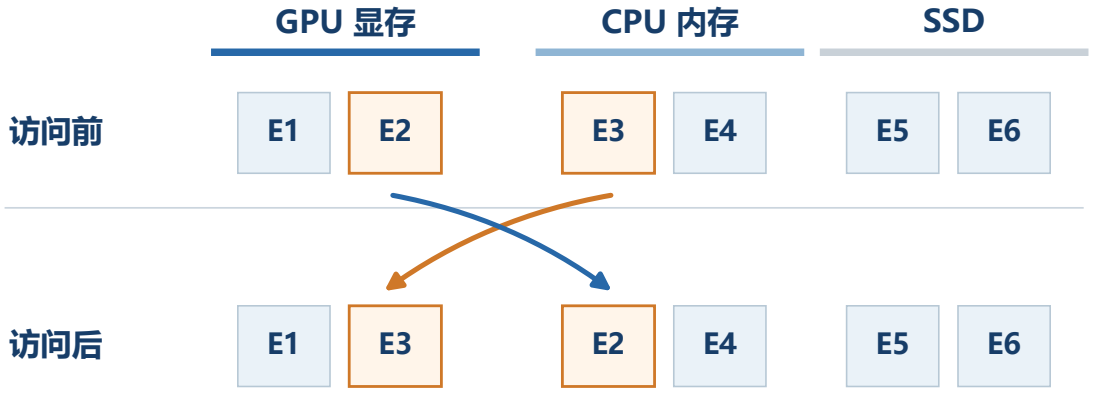
(a) 一次 CPU 内存访问如何更新缓存

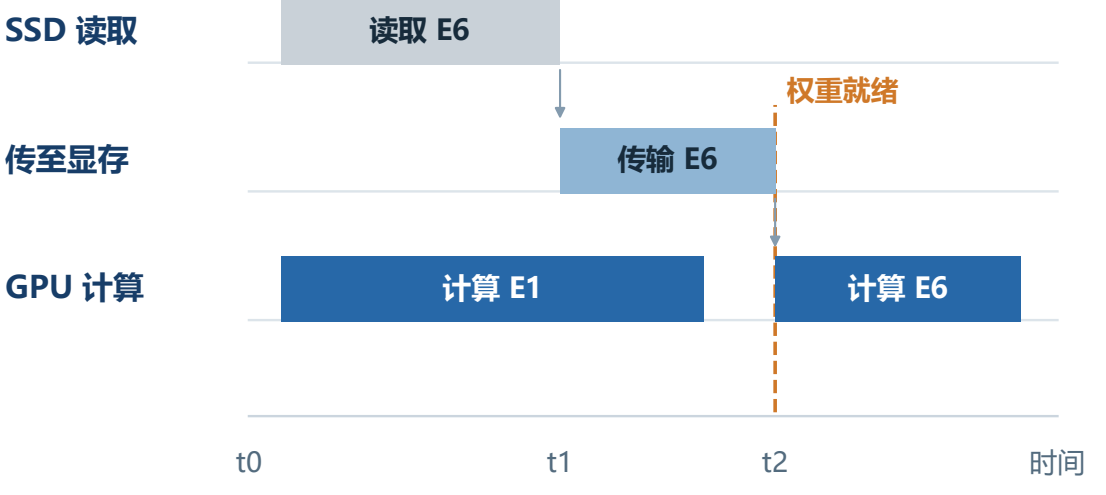
访问 E3 后，E3 进入显存；被替换的 E2 保留在 CPU 内存



E2 保留在 CPU 内存，后续访问无需再次读取 SSD。

(b) 所选专家何时可以计算

已在显存的 E1 先计算；E6 的权重到达后再执行



同一请求中，权重读取与已有专家的计算可以重叠。