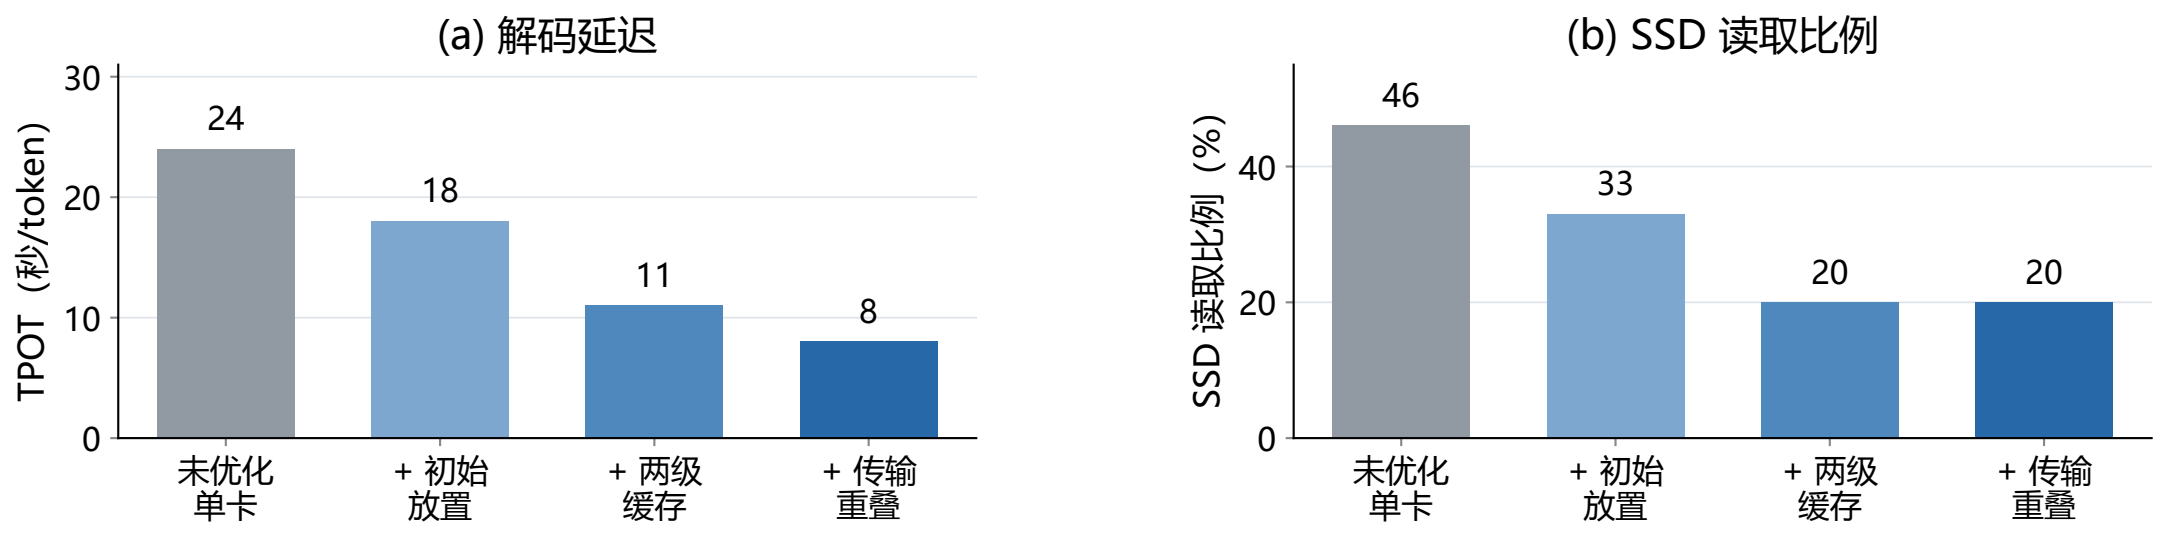
(a) 解码延迟
TPOT（秒/token）
30
20
10
0
24
18
11
8
未优化
单卡
+ 初始
放置
+ 两级
缓存
+ 传输
重叠
(b) SSD 读取比例
SSD 读取比例（%）
40
20
0
46
33
20
20
未优化
单卡
+ 初始
放置
+ 两级
缓存
+ 传输
重叠