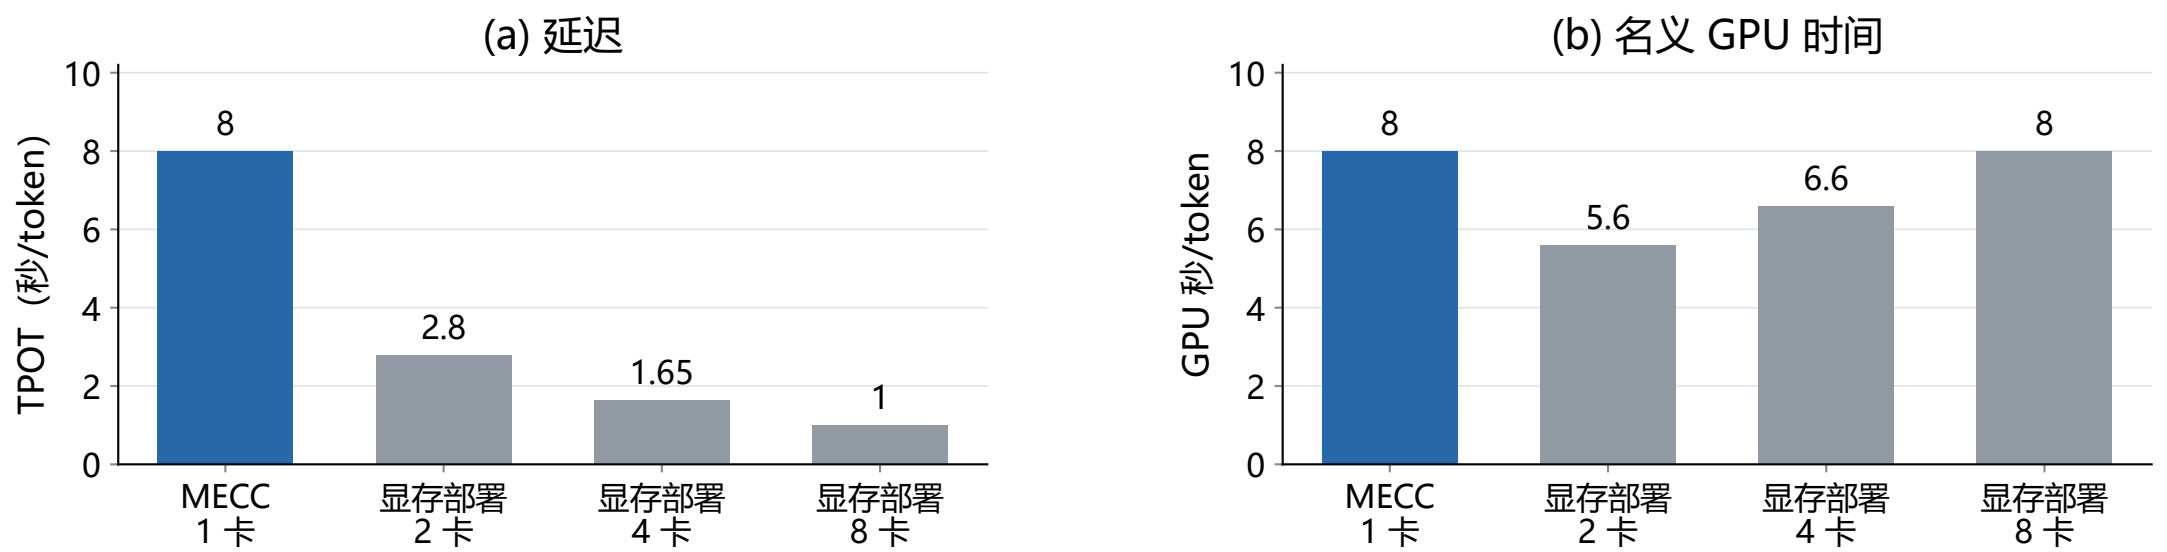
(a) 延迟
TPOT（秒/token）
10
8
6
4
2
0
8
2.8
1.65
1
MECC
1 卡
显存部署
2 卡
显存部署
4 卡
显存部署
8 卡
(b) 名义 GPU 时间
GPU 秒/token
10
8
6
4
2
0
8
5.6
6.6
8
MECC
1 卡
显存部署
2 卡
显存部署
4 卡
显存部署
8 卡