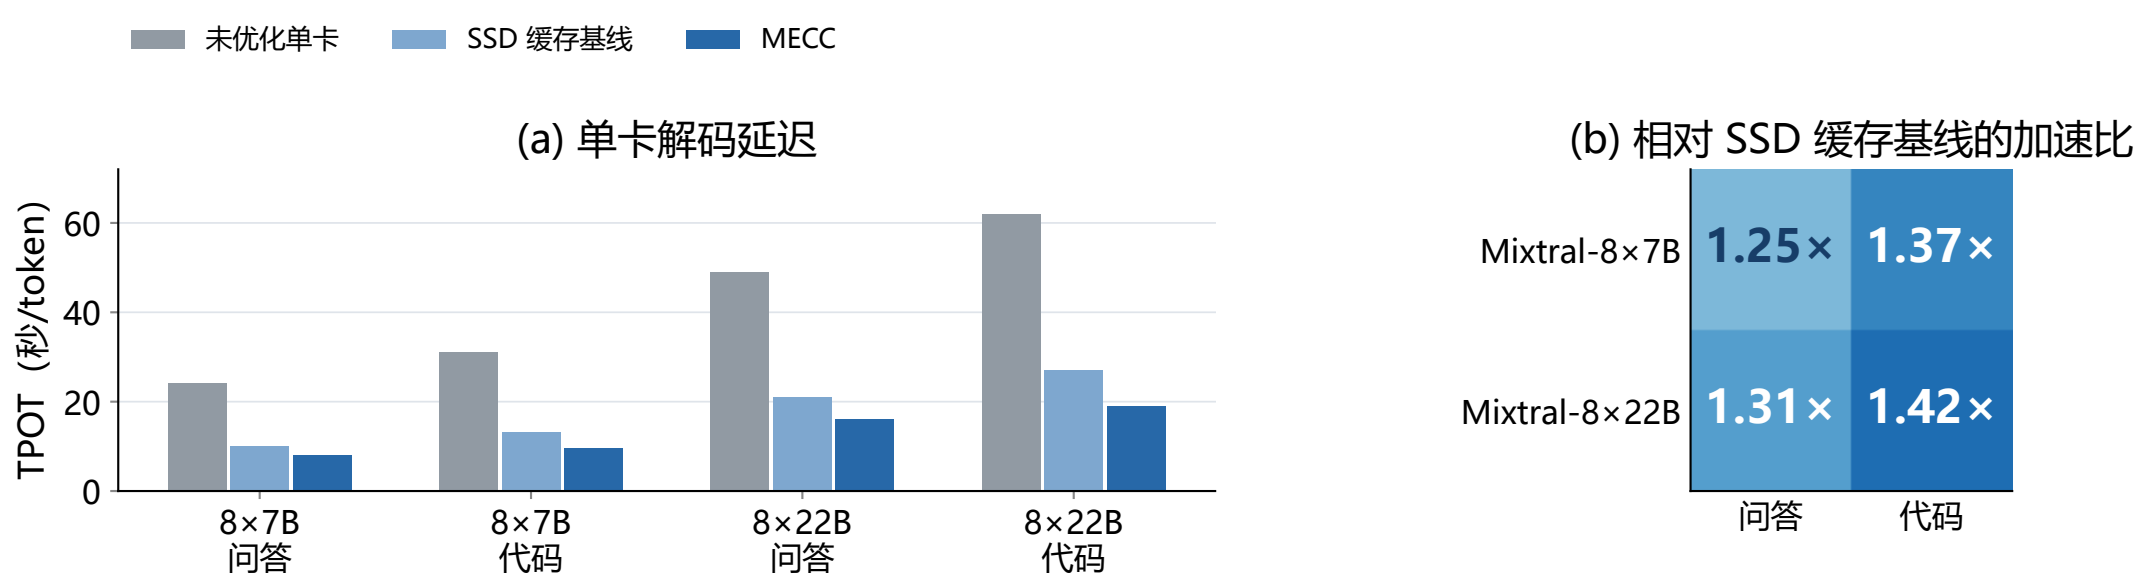
未优化单卡
SSD 缓存基线
MECC
(a) 单卡解码延迟
TPOT（秒/token）
0
20
40
60
8×7B 问答
8×7B 代码
8×22B 问答
8×22B 代码
(b) 相对 SSD 缓存基线的加速比
Mixtral-8×7B
Mixtral-8×22B
1.25×
1.37×
1.31×
1.42×
问答
代码