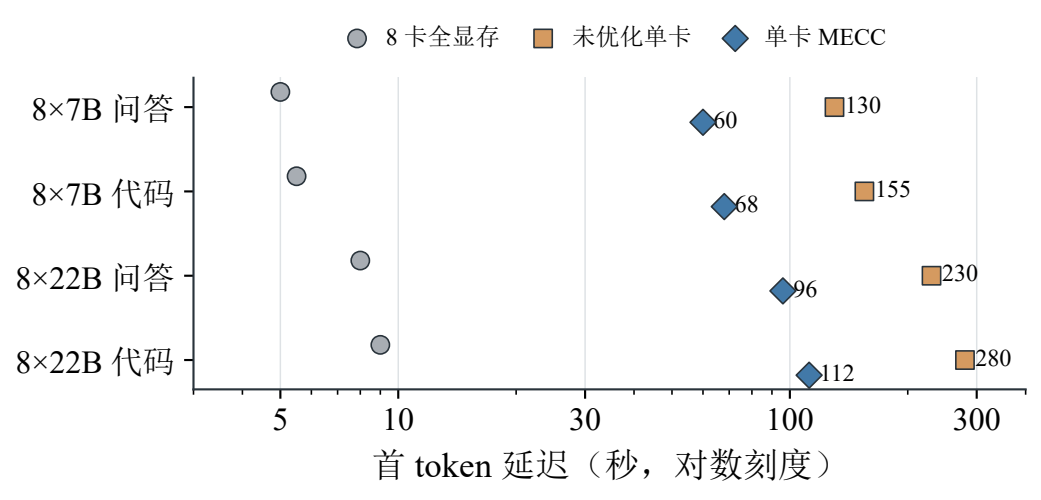
8 卡全显存
未优化单卡
单卡 MECC
8×7B 问答
8×7B 代码
8×22B 问答
8×22B 代码
60
130
68
155
96
230
112
280
5
10
30
100
300
首 token 延迟（秒，对数刻度）