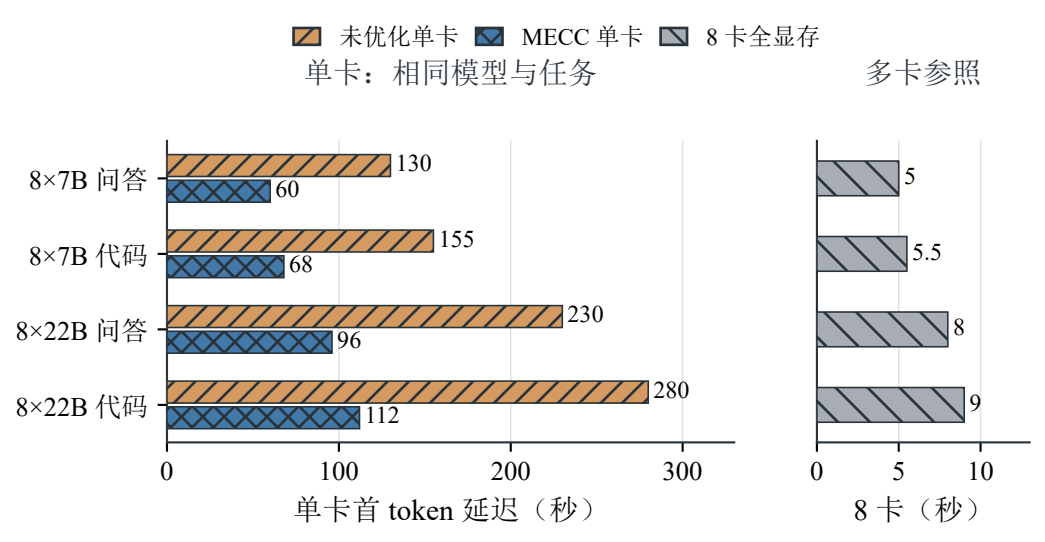
未优化单卡
MECC 单卡
8 卡全显存
单卡：相同模型与任务
多卡参照
8×7B 问答
8×7B 代码
8×22B 问答
8×22B 代码
130
60
155
68
230
96
280
112
0
100
200
300
单卡首 token 延迟（秒）
5
5.5
8
9
0
5
10
8 卡（秒）