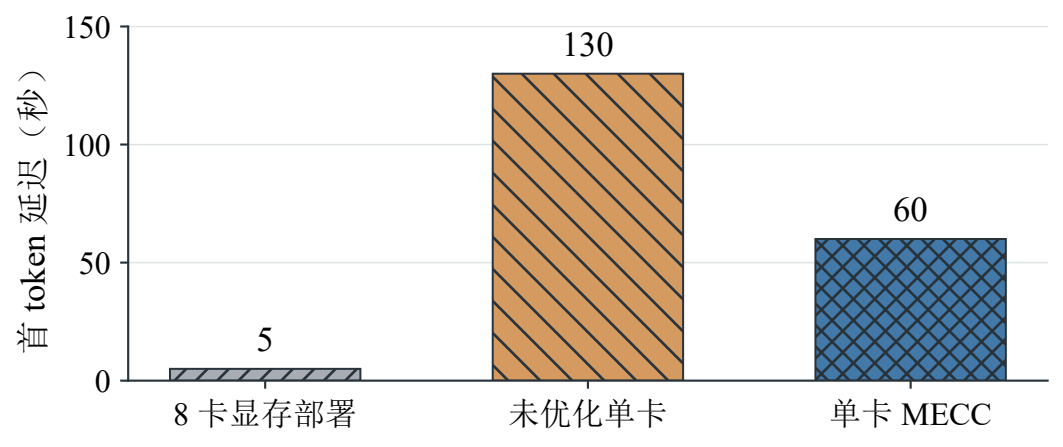
150
100
50
0
首 token 延迟（秒）
5
130
60
8 卡显存部署
未优化单卡
单卡 MECC