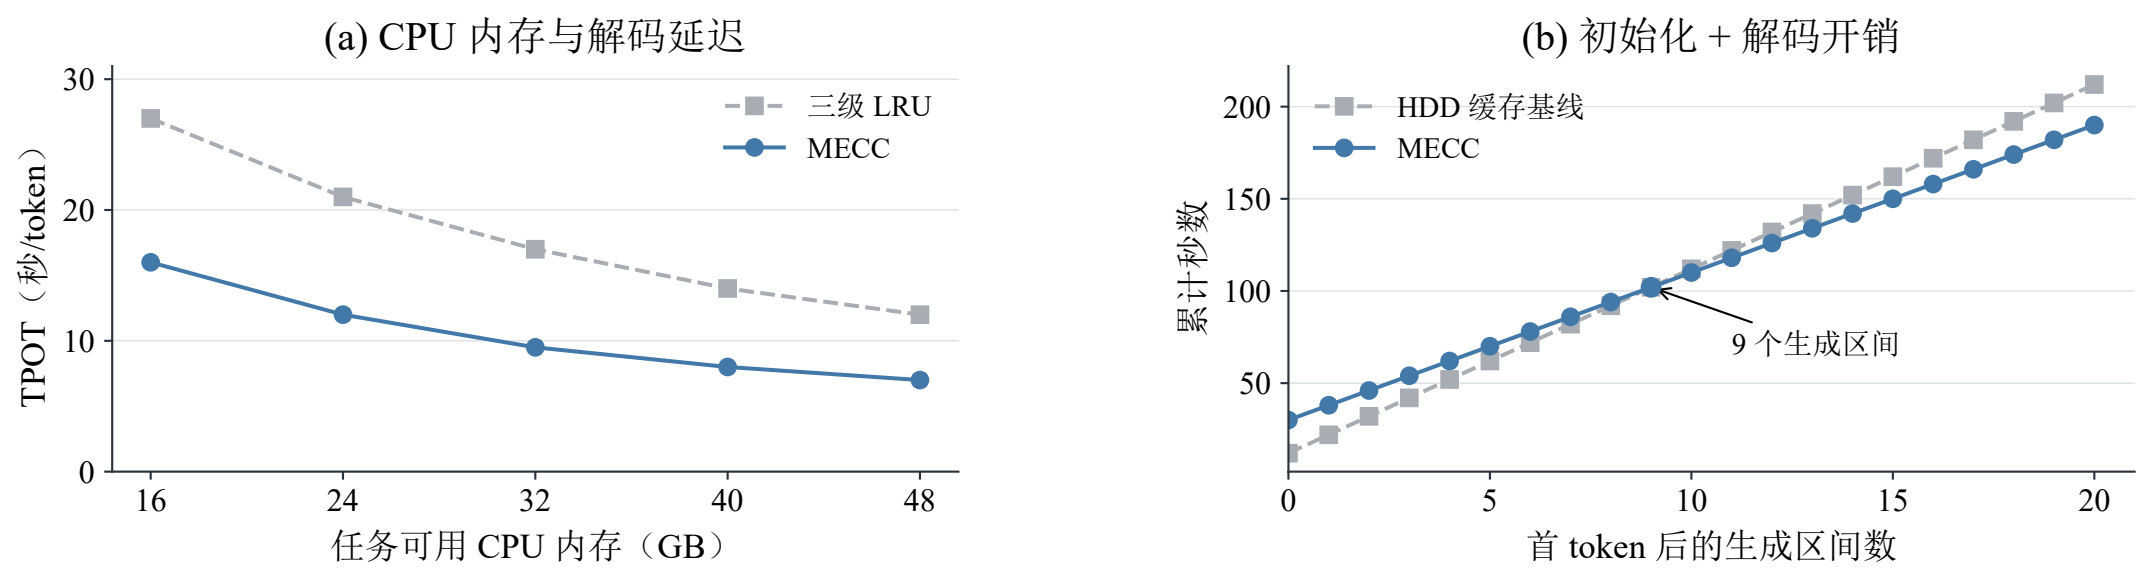
(a) CPU 内存与解码延迟
TPOT（秒/token）
30
20
10
0
16
24
32
40
48
任务可用 CPU 内存（GB）
三级 LRU
MECC
(b) 初始化 + 解码开销
累计秒数
200
150
100
50
0
5
10
15
20
首 token 后的生成区间数
HDD 缓存基线
MECC
9 个生成区间