# Research Problem: Sparse Access, Large State

- MoE 每次只激活少数专家，但全部专家都要随时可访问。
  专家权重可能放在 GPU 显存、CPU 内存或 SSD。
  选中 SSD 上的专家会产生读取等待；MECC 要减少这种等待。




关键代价：被路由选中的冷专家必须从 SSD 读取，生成因此等待。

# Related Work: What Remains to Establish

- **近期系统从画像引导、三级驻留、替换与调度等角度优化专家访问。**
  **MECC 研究有限请求时域内的初态与在线协同，目标是降低实际内存约束下的总代价。**

| 系统 | 核心控制机制 | 主要目标 | 核心决策对象 |
|---|---|---|---|
| Fiddler [1] | 离线专家热度；CPU/GPU 执行选择 | 异构执行延迟 | CPU/GPU 执行位置 |
| MoE-Lightning [2] | 预算约束策略搜索；传输流水 | 批量推理吞吐 | 批量与驻留比例 |
| SSD-LLaMA [3] | 原生三级驻留；动态保留 | SSD 专家交付 | I/O 路径与三级驻留 |
| FlashMoE [4] | 近期性/频率驱动的学习式替换 | 减少 SSD I/O | 专家缓存替换 |
| MoE-CORE [5] | 离线领域画像；历史替换与预取 | 协同卸载与驻留 | 逐层容量、驻留与预取 |
| ZipMoE [6] | 无损压缩；缓存亲和调度 | 容量与调度协同 | 权重表示与请求调度 |
| **MECC** | **预算计划；联合保留** | **有限时域总代价** | **有限时域初态与迁移** |

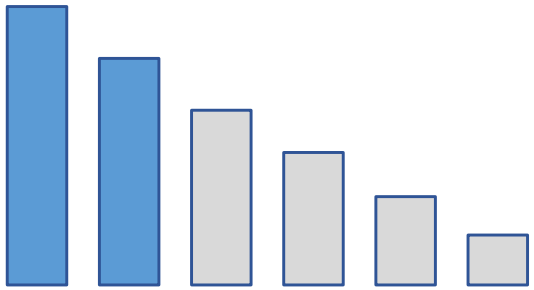
文献机制比较；本地 fp16 机制对照不等同于上述系统的官方实现。

**研究重点：先验计划与在线保留，在同实际资源约束下分别贡献多少？**

# MECC: Separate the Prior from the Policy

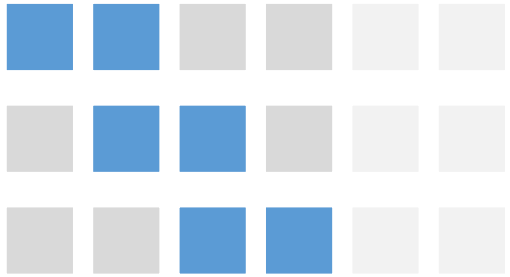
- MECC 将部署前的预算计划与运行中的联合保留放在同一框架中。
  我们分别检验启动段的画像效应、访问次序的复用效应，以及初态与在线规则的交互。

## ① 初始计划



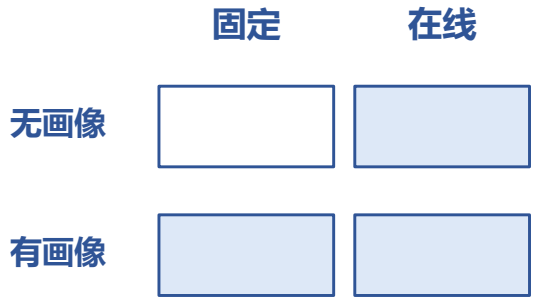
独立画像 → 初始驻留

## ② 在线保留



共同访问序列 → 驻留更新

## ③ 独立验证



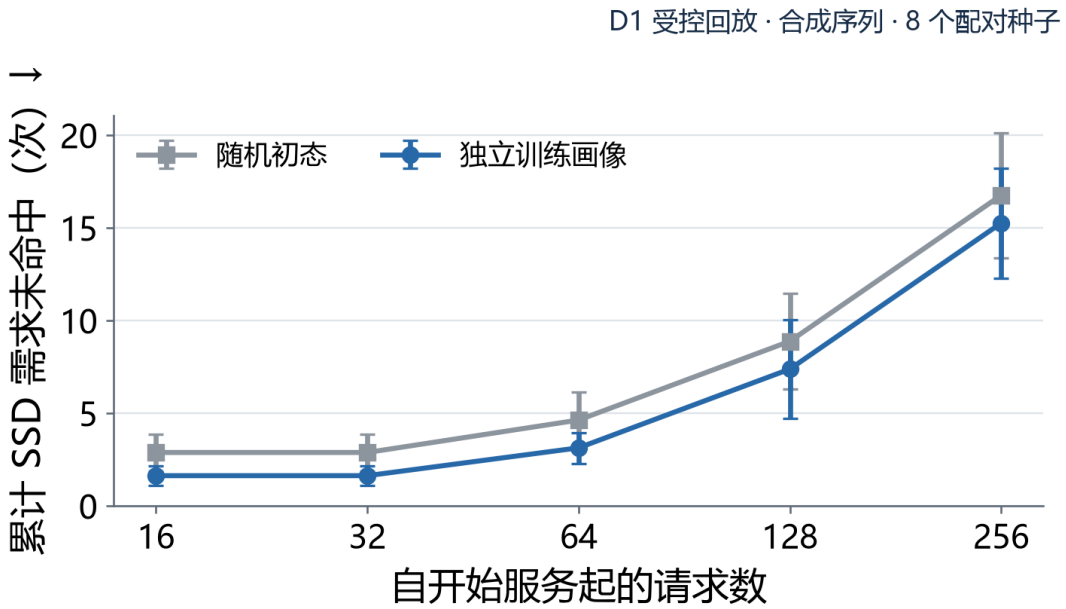

2×2 对照 → 识别增量

一个框架，三个可证伪问题；机制回放与真机性能分别验证。

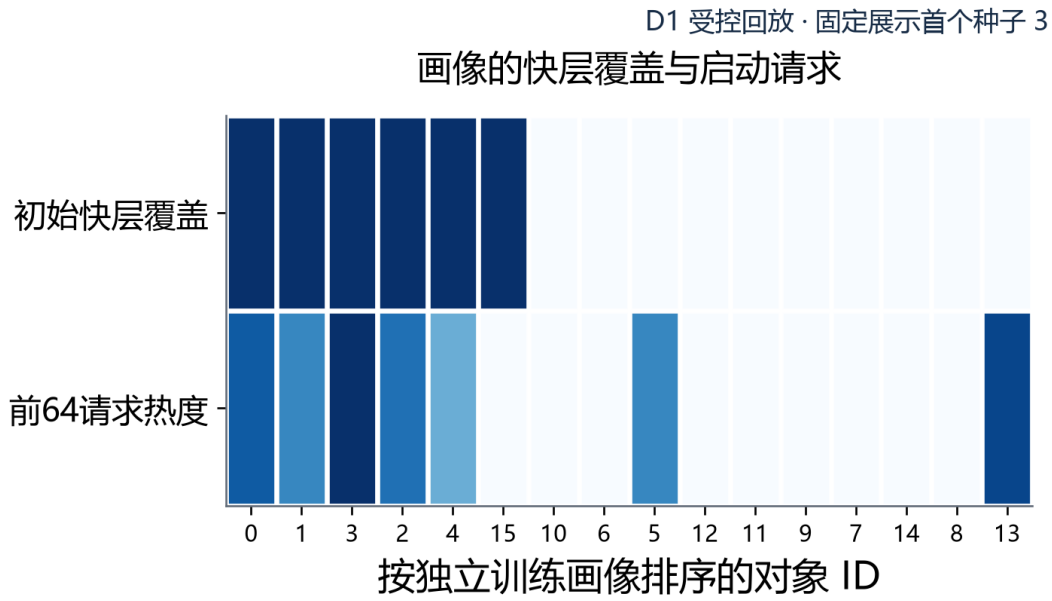
# Motivation I: Isolate the Initial-State Effect

- **在相同联合 LRU 下，独立画像将前 64 次请求的平均冷读从 4.625 次降至 3.125 次。累计差异主要在启动段形成；初始计划的价值因此与服务请求时域有关。**

## (a) 同一在线规则的启动段冷读




## (b) 初始覆盖与独立测试请求



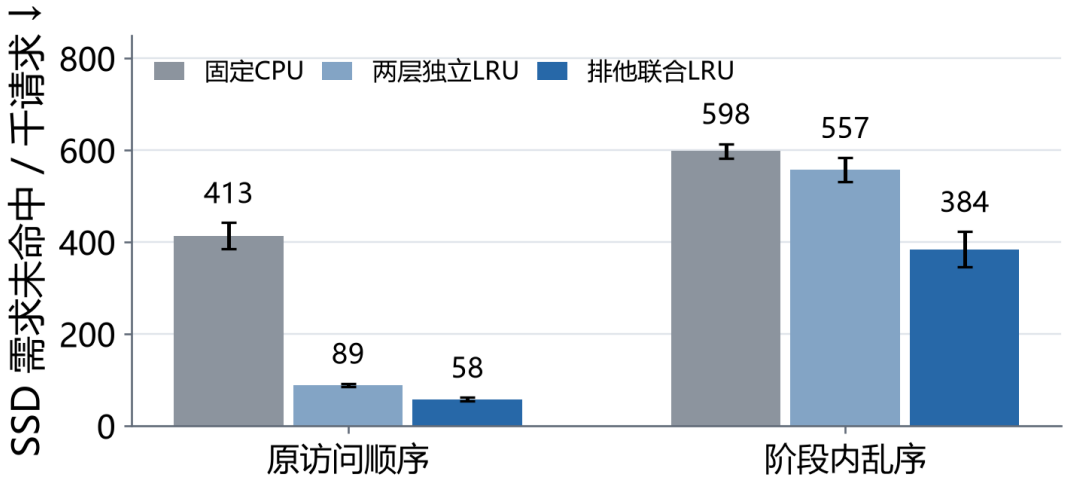

**动机 ①：启动段是离线先验发挥作用的重要窗口。**

# Motivation II: Frequency Is Not Enough

- **保持每阶段访问频次不变，阶段内乱序使联合 LRU 的冷读从 58 增至 384 次/千请求。**
  **访问次序改变了再访距离与可复用机会；单独的热度直方图不足以刻画缓存压力。**

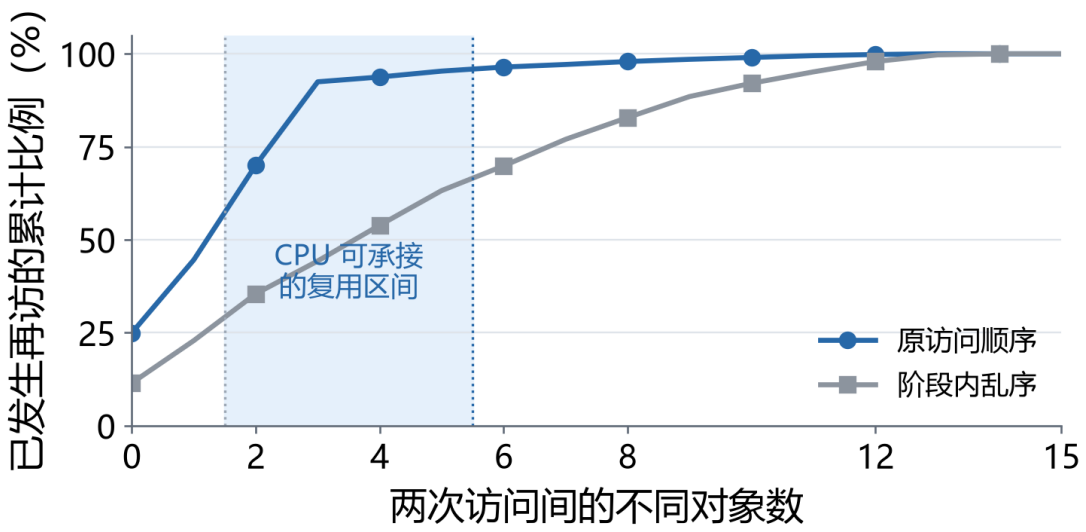
## (a) 保持边际频次，只改变时序

D1 受控回放 · 合成序列 · 8 个配对种子




## (b) 再访距离与快层复用区间

D1 受控回放 · 条件再访 CDF · 种子 3



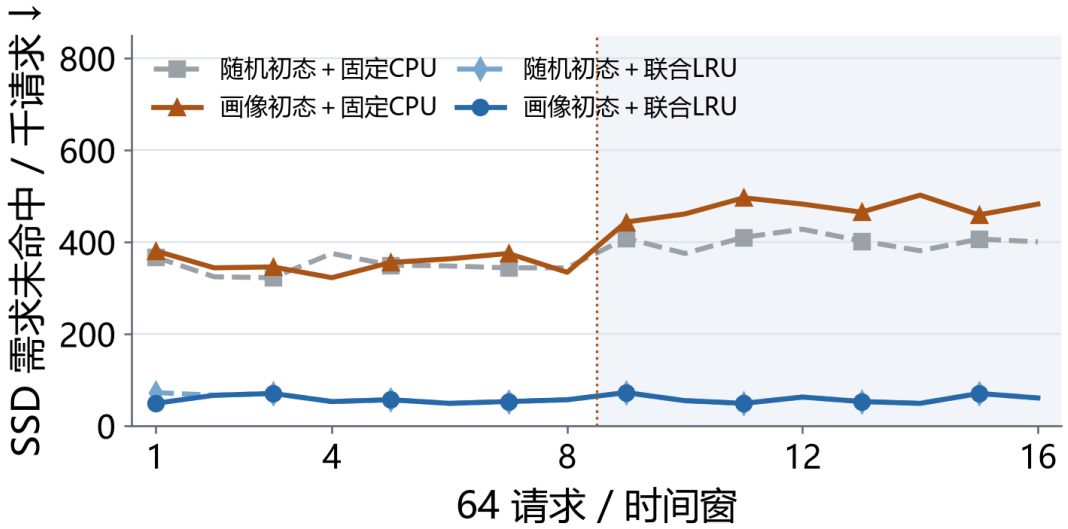

**动机 ②：访问频次决定热度，访问次序决定复用机会。**

# Motivation III: Test the Prior–Policy Interaction

- **人工阶段切换后，画像固定方案的冷读上升，而两种联合方案保持接近。**
  **初始先验与运行期保留作用于不同时间尺度；2×2 对照呈现了各自的作用。**

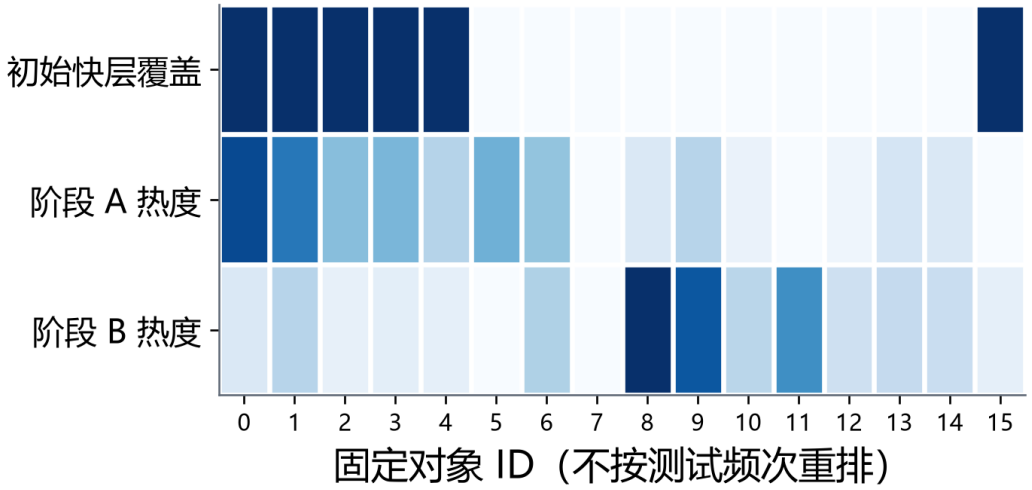
## (a) 初始画像 × 在线保留的 2×2 对照

D1 受控回放 · 合成序列 · 8 个配对种子




## (b) 固定对象 ID 下的阶段热度

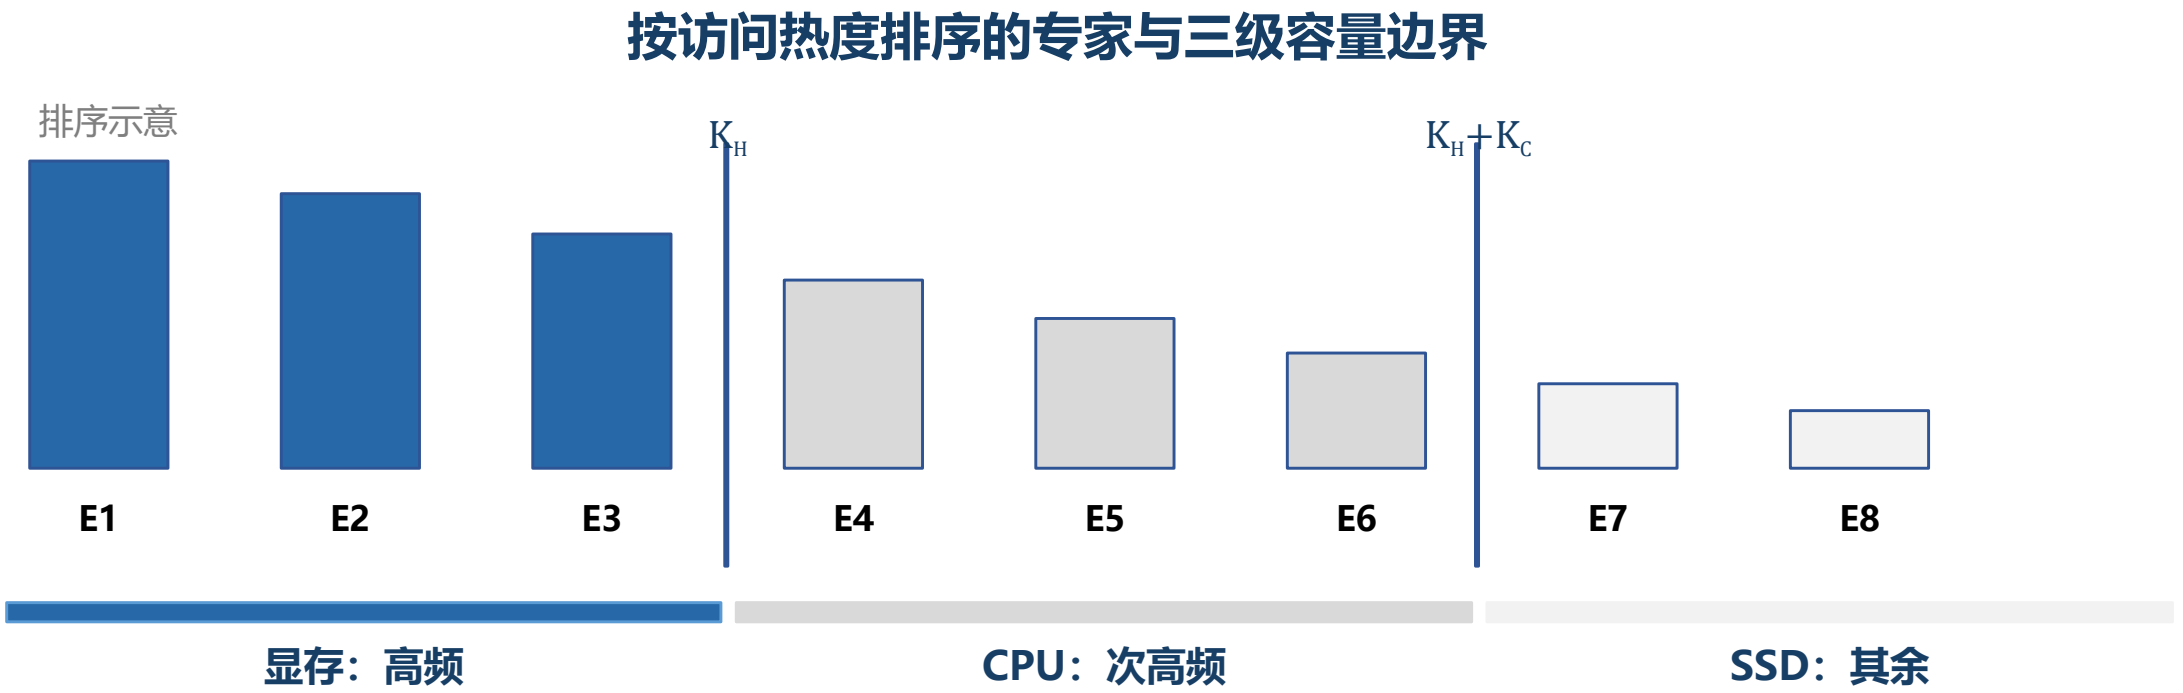
D1 受控回放 · 人工阶段切换 · 种子 3




**动机 ③：按两个时间尺度组织初始先验与在线反馈。**

# Insight I: Optimize the Finite Horizon

- 画像把有限快层空间优先配置给高概率对象，在请求开始时减少冷读。
  以服务请求数量为时域，将画像、编译与预热开销纳入初始化和推理的总代价。

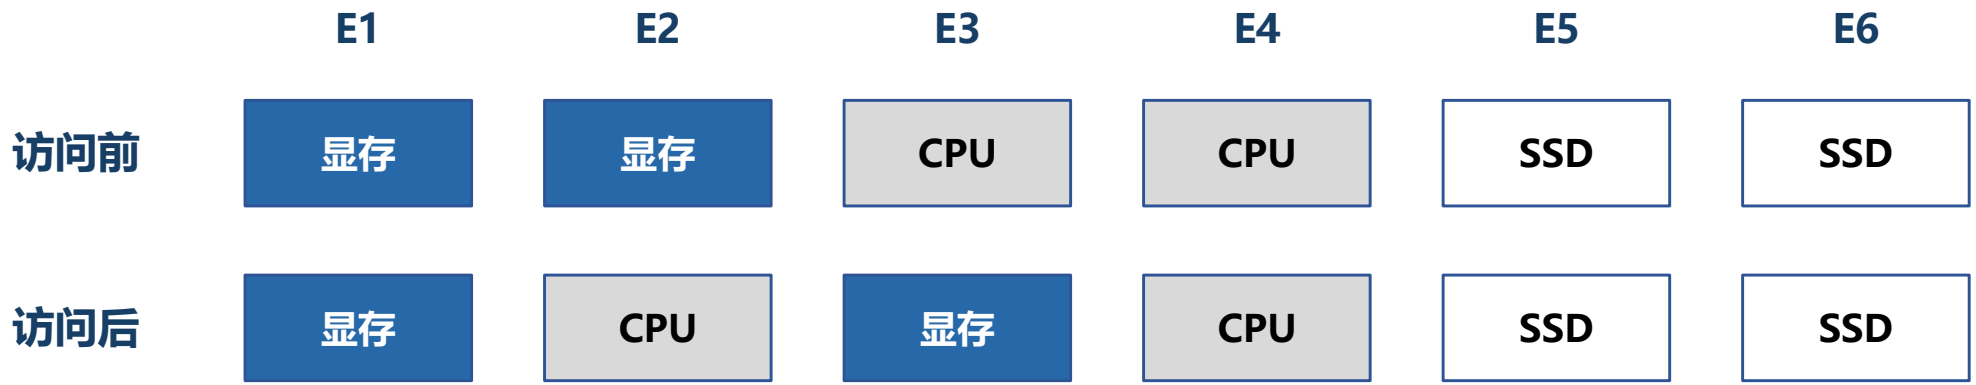



对应动机 ①：优先避免高概率请求承担昂贵的 SSD 冷读。

# Insight II: Measure Coverage and Reuse

- 专家被显存淘汰后，若在短距离内再访，CPU 保留能够承接这次请求。
  跨层去重扩大唯一对象覆盖；访问次序与驻留状态共同决定哪些冷读可以避免。

**一次 E3 访问前后：各专家所在的最快层级**




**E3 从 CPU 提升至显存；被替换的 E2 留在 CPU**

**对应动机 ②：让专家复用跨越显存淘汰事件。**

# Insight III: Quantify the Incremental Gain

- **画像初始化影响启动段，在线保留决定后续请求如何利用快层空间。**
  **通过两种时间尺度协同利用先验与真实访问，并将跨层迁移开销纳入总代价。**



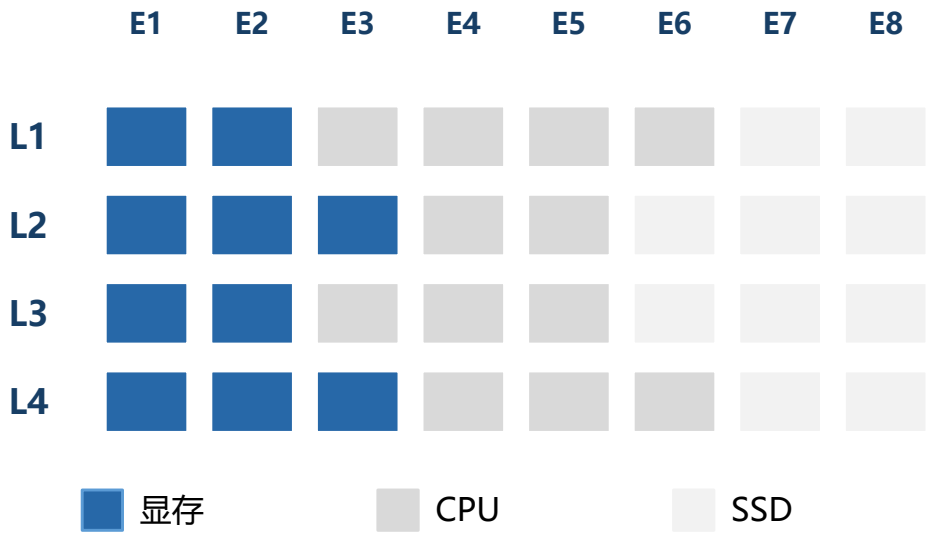

深色单元格表示当前热点或快层保留位置；专家身份与阶段均为机制示意。

**洞察 ③：把离线先验和在线反馈放在两个时间尺度上协同使用。**

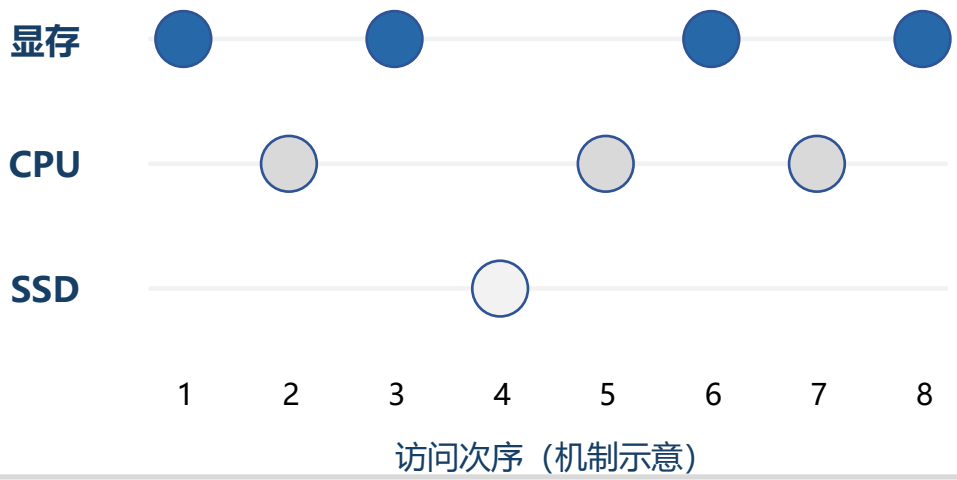
# System Overview: From Prior to Feedback

- 编译期把访问画像与单任务预算转成逐层驻留方案；运行期根据真实路由更新显存与 CPU 缓存。两部分共享同一个三级存储视图：SSD 保存完整权重，快层位置随专家访问改变。

## 编译期：专家 × 层级的初始驻留




## 运行期：每次访问实际命中哪一层

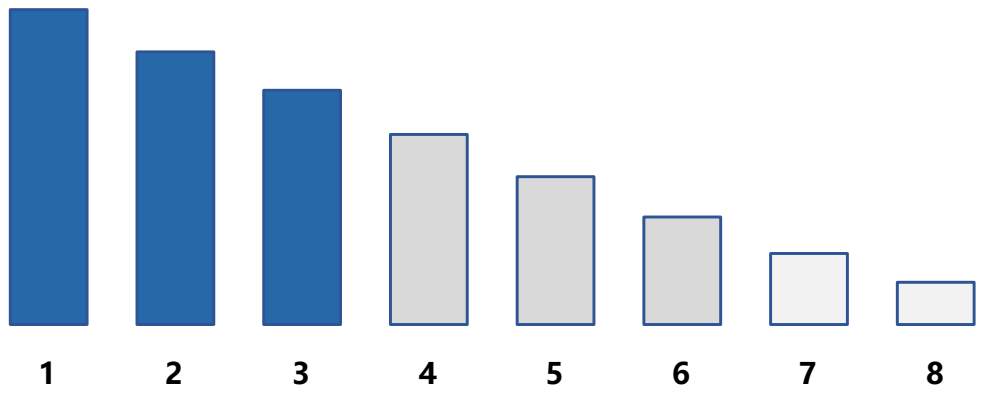



**编译期确定初始位置；运行期通过显存与 CPU 的联合保留持续纠偏。**

# Method I: Budget-Constrained Placement

- 编译器读取各层专家的访问画像、权重大小与单任务显存/CPU 预算。在给定独立容量上限下，按访问概率排序并确定两道容量边界，输出每层专家的初始三级驻留位置与预期冷读比例。

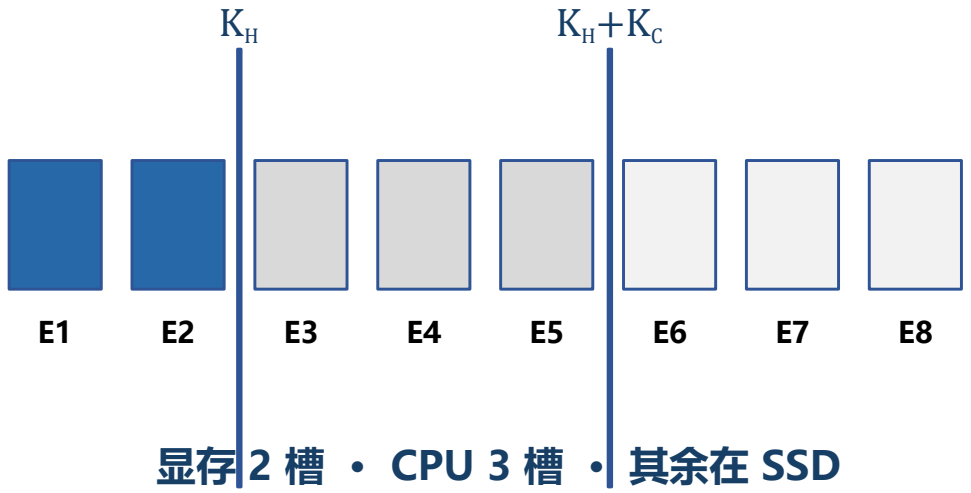
**访问画像：专家访问频率（示意）**




专家按访问概率降序排列

**优化目标：最小化预期取数代价**

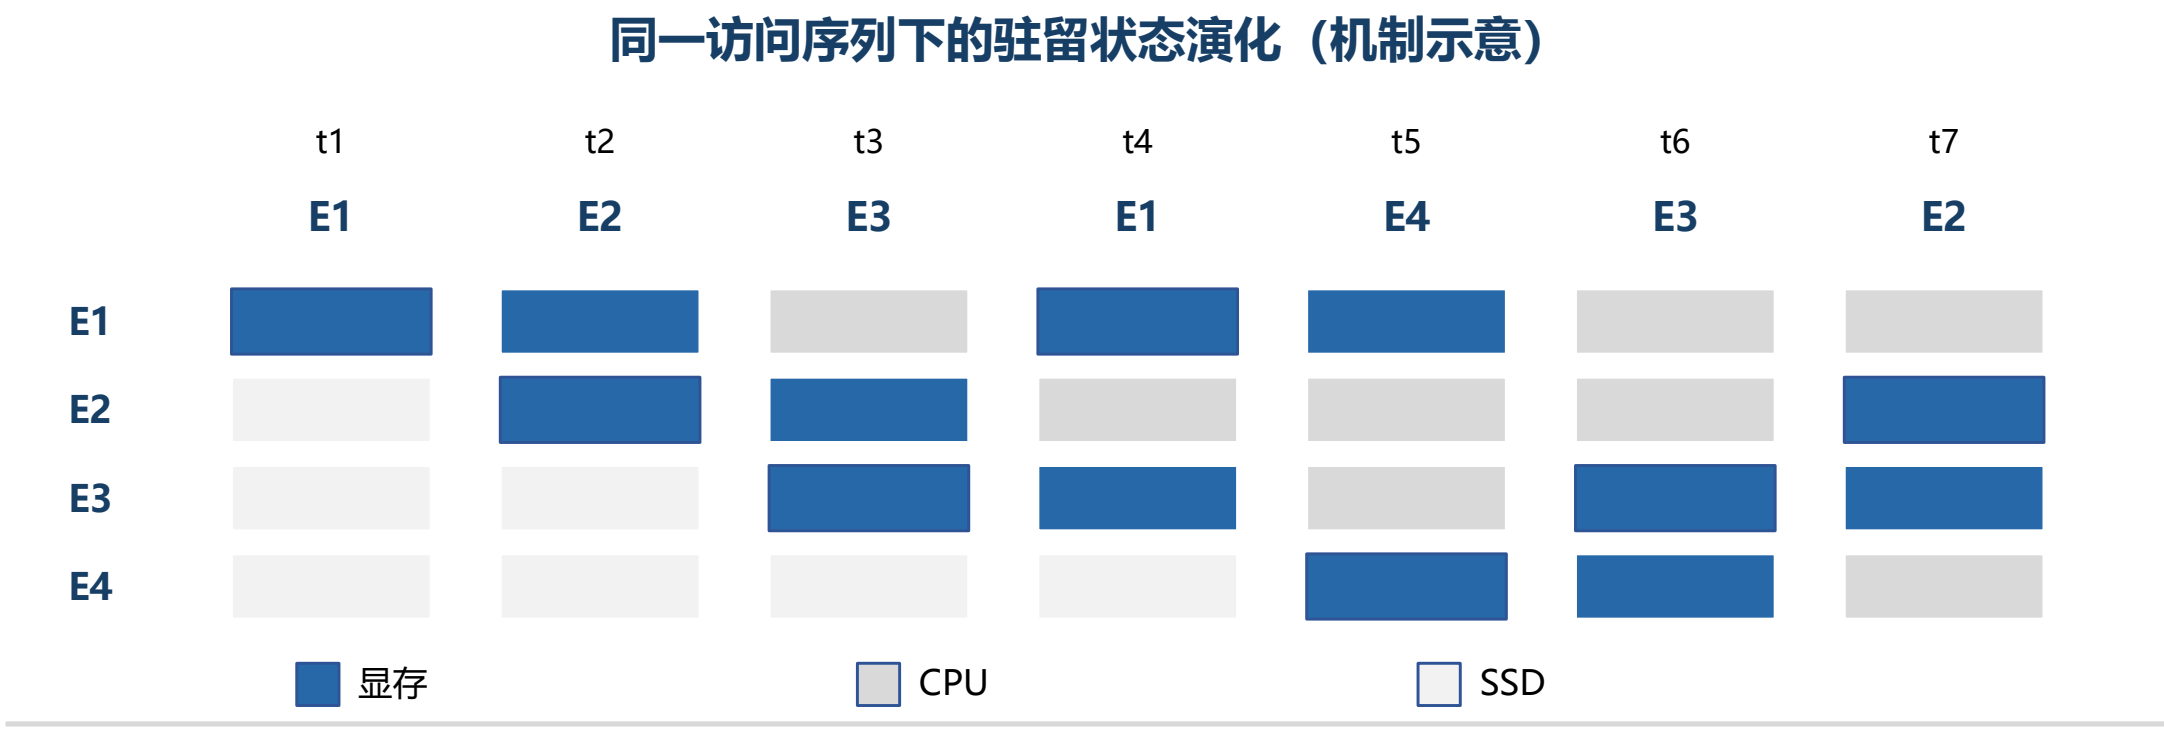
**编译产物：预算约束下的三级分配**




$$\mathbb{E}[T] = p_H T_H + p_C T_C + p_S T_S$$

# Method II: Joint HBM–CPU Retention

- 真实路由驱动专家访问：显存命中直接复用，CPU 命中提升到显存，两层未命中才读取 SSD。下图以显存 2 槽、CPU 2 槽演示联合保留；每列表示一次访问完成后各专家的最快驻留层级。

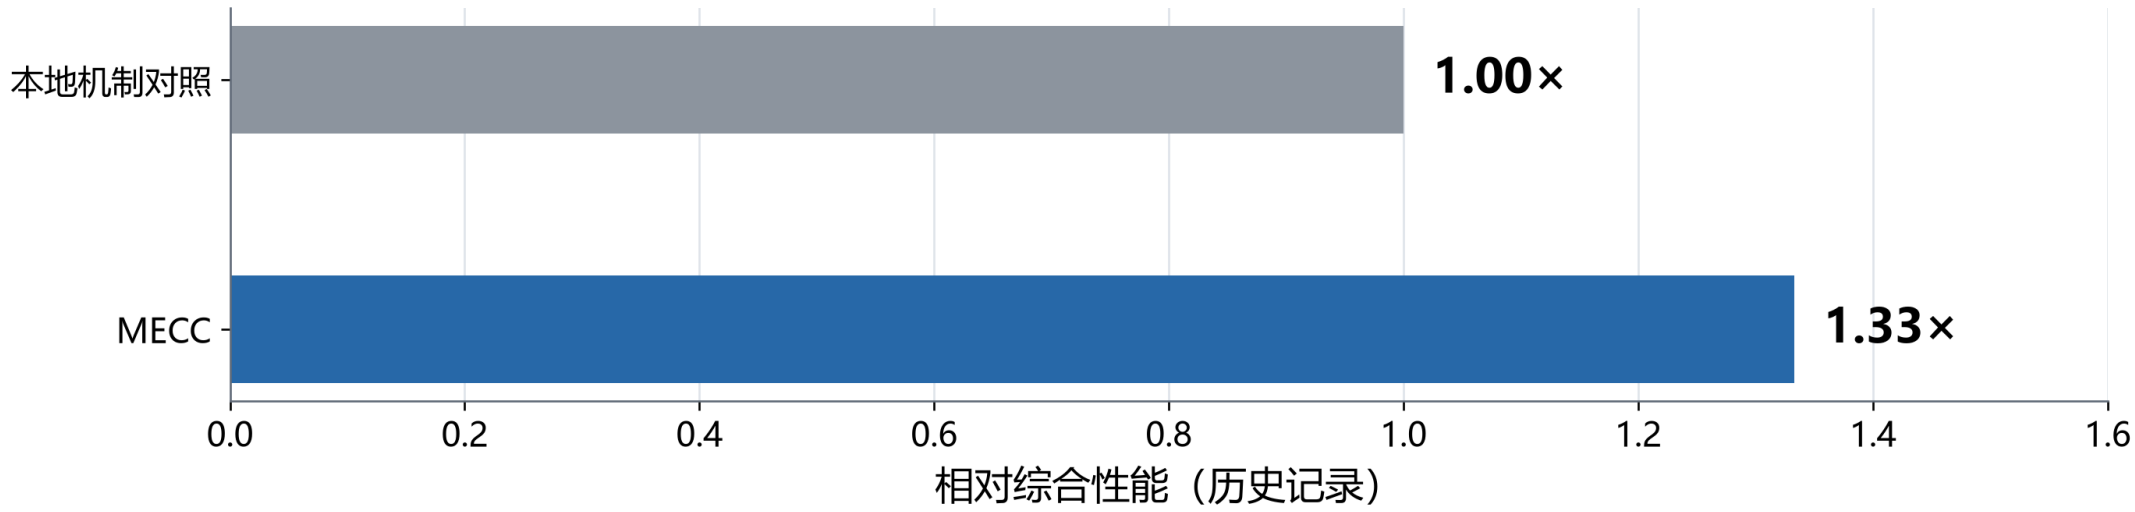



E1 与 E2 再访时由 CPU 承接；每次迁移均保持原专家权重与路由选择。

# Historical Observation: A Reference Point

- **历史 A100 Mixtral 实验记录中，相对本地机制对照的综合性能为 1.33×。**
  **该记录对齐了配置槽位；实际内存字节、质量等价与统计窗口仍需独立复核。**

历史 D2 记录 · 配置槽位对齐；物理字节与计数窗口待复核

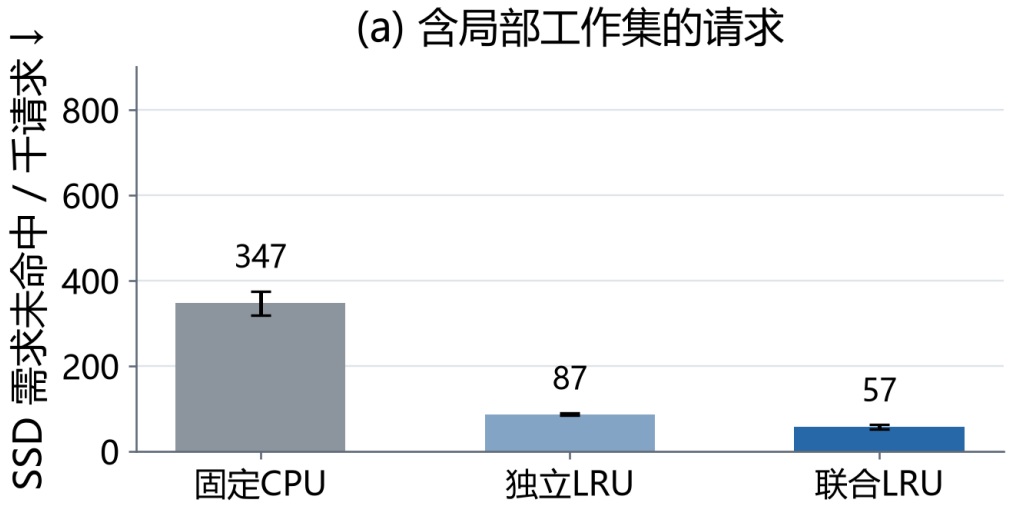


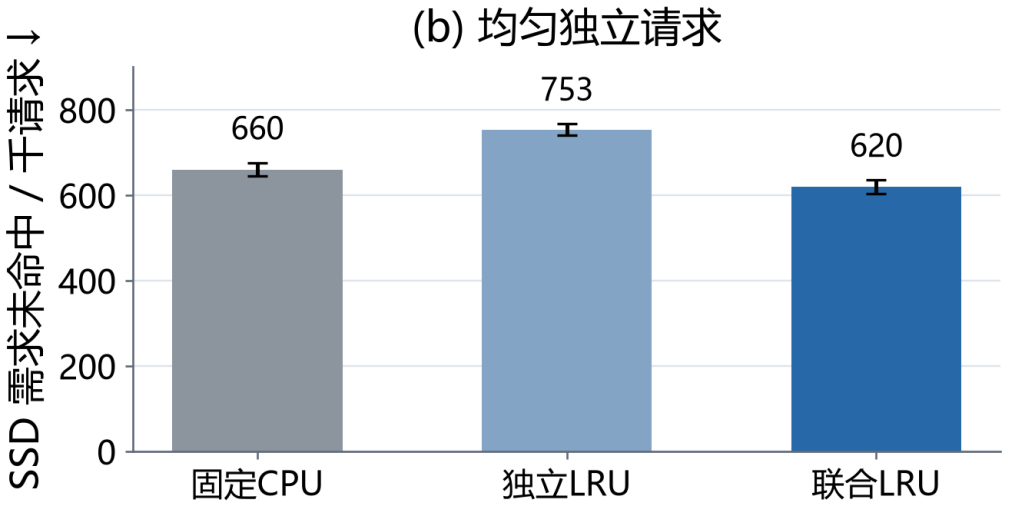

**历史观测为硬件复核提供锚点；编译器的独立收益由新增对照检验。**

# Controls: When Does the Mechanism Help?

- 局部工作集与均匀独立请求采用相同对象数和物理槽位；误差棒为合成种子标准差。
  保留无优势与较小画像效应，检验唯一覆盖、迁移开销和真实请求分布对收益的影响。

D1 受控回放 · 合成序列 · 8 个配对种子




**机制证据：可复现、可反驳；硬件结论还需真实访问序列与净端到端代价。**